



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Análisis y Visualización de Datos Masivos

Optimización de Carteras mediante Modelado Generativo y Teoría de la Información

Trabajo Fin de Estudios

presentado por: Daniel Machín González

Dirigido por: Jesús Cigales Canga

Ciudad: San Bartolomé

Fecha: May 7, 2026

Índice general

Resumen	v
Abstract	vi
1. Introducción	1
1.1. Motivación	1
1.2. Objetivos	2
1.3. Planteamiento del trabajo	3
1.4. Estructura del trabajo	3
2. Objetivos	4
3. Marco Teórico	5
4. Estado del Arte	6
4.1. El Modelo de Media-Varianza de Markowitz	6
4.2. Limitaciones de la Teoría Clásica	7
4.3. Fundamentos de la Teoría de la Información	8
4.4. Modelado Generativo	9
4.4.1. Autoencoders Variacionales (VAEs)	10
4.4.2. Redes Generativas Adversarias (GANs)	11
4.4.3. Estado del Arte Reciente: Modelos de Difusión	12
5. Objetivos Concretos y Metodología de Trabajo	13
5.1. Adquisición de Datos y Preprocesamiento de los Mismos	13
5.2. Arquitectura del Sistema Propuesto	14
5.3. Función de Pérdida y Criterios de Optimización	15
5.4. Generación y Selección de Pesos	17
5.5. Herramientas y Tecnologías Utilizadas	17
6. Marco Normativo y Protección de Datos	18
6.1. Identificación del Tratamiento de Datos	18
6.2. Cumplimiento del RGPD y la Ley Orgánica 3/2018 (LOPDGDD)	18

6.3. Consideraciones Éticas y Propiedad Intelectual	19
7. Código Fuente y Datos Analizados	20
8. Conclusiones	21
9. Limitaciones y Prospectiva	22
Referencias	23

Índice de figuras

5.1. Arquitectura híbrida VAE-GAN para la generación y optimización de carteras.	15
--	----

Índice de cuadros

Resumen

Tu resumen en español...

Abstract

Your abstract in English...

1. Introducción

El Mercado Financiero, entendido como el espacio en el cual se compran y se venden activos financieros (acciones, bonos, divisas, materias primas y criptomonedas principalmente), es el sujeto de estudio perfecto para poner en práctica el uso de tecnologías Big Data.

Las tecnologías Big Data se definen como las herramientas que permiten gestionar, almacenar y analizar conjuntos de datos masivos, que superan a la capacidad tradicional.

Desde los comienzos de la teoría económica moderna, se considera al Mercado Financiero como un sistema caótico. A diferencia de un sistema puramente aleatorio, un sistema caótico presenta patrones y reglas subyacentes que permiten hacer predicciones sobre el mismo.

El caos se caracteriza por la complejidad. En un sistema caótico, las variables presentan relaciones no lineales, a menudo difíciles de detectar a simple vista. Esto deriva en la impredecibilidad del sistema, puesto que pequeñas variaciones en las condiciones iniciales pueden llevar a resultados completamente diferentes.

El Mercado Financiero además es un sistema de nivel dos, por lo tanto, las propias predicciones que se realizan sobre el mismo influyen en los resultados que se obtienen.

En el presente trabajo, se propone abordar el problema de confeccionar una cartera de inversión, esto es, un subconjunto de los activos financieros disponibles, de la mejor manera posible.

(Markowitz, 1952) introduce el modelo de media-varianza como la mejor manera de gestionar la cartera de inversión. Este modelo se fundamenta en el principio del riesgo-rendimiento, buscando para un riesgo determinado, el cuál el inversor asume, maximizar el rendimiento esperado.

Con el uso de las tecnologías Big Data, en particular, con el uso de modelos generativos **Autoencoders Variacionales (VAEs)** y **Redes Generativas Adversarias (GANs)**, se propone una aproximación a la confección de carteras desde una perspectiva no lineal.

1.1. Motivación

La gestión de carteras de inversión ha estado dominada durante décadas por la Teoría de Cartera Moderna (MPT), introducida por (Markowitz, 1952). Este marco teórico se

fundamenta en la optimización media-varianza, bajo el supuesto de que los retornos de los activos financieros siguen una distribución normal. Sin embargo, la evidencia empírica en el análisis de datos masivos financieros demuestra que los mercados reales presentan características que este modelo no logra capturar: la curtosis excesiva (colas pesadas), la asimetría y la volatilidad estocástica.

En el contexto actual de Big Data, la incapacidad de los modelos lineales para gestionar la complejidad representa un riesgo sistémico. Los eventos de “extremo” ocurren con una frecuencia mayor en la realidad, lo que hace que la varianza sea una métrica de riesgo insuficiente. El uso de modelos generativos como las GANs (Salimans y cols., 2016) y los VAEs (Kingma y Welling, 2013) ofrece un nuevo paradigma para aprender la distribución subyacente de los datos, pero esta vez libre de modelos.

Frente a otras aproximaciones, como el uso de modelos de Machine Learning o Sistemas de Ecuaciones Diferenciales, los modelos generativos no son deterministas. Estos modelos se adaptan a los datos, siendo flexibles frente a cambios drásticos.

1.2. Objetivos

El objetivo general del trabajo es proponer un método de selección de carteras de inversión innovador, capaz de ofrecer una alternativa a las carteras confeccionadas por métodos clásicos y hacer frente a otros métodos modernos, así como a los resultados obtenidos por grandes fondos de inversión.

Para desarrollar el objetivo general, se proponen los siguientes objetivos específicos, que marcan los pasos a seguir:

1. Diseñar e implementar una arquitectura VAE para la reducción de dimensionalidad y búsqueda de relaciones subyacentes no lineales en datos de series históricas de los principales (a determinar) activos del S&P 500.
2. Entrenar una red GAN que sintetice escenarios de mercado preservando las cualidades encontradas en el espacio latente.
3. Validación de la calidad de los escenarios generados mediante la Divergencia de Kullback-Leibler como métrica de riesgo.
4. Comparar el rendimiento de la cartera resultante frente a carteras elegidas mediante otros métodos, en particular frente al método de media-varianza de Markowitz,

carteras equiponderadas y carteras elaboradas históricamente por grandes fondos de inversión.

1.3. Planteamiento del trabajo

La elección de esta arquitectura, como se exponía previamente, no busca predecir el precio futuro de los activos, sino generar diversos escenarios posibles para comprender el riesgo central subyacente de los mismos.

El presente Trabajo de Fin de Máster propone una metodología híbrida que integra el modelado generativo y la teoría de la información. El núcleo de la investigación se divide en tres fases:

1. Extracción de datos de series históricas del S&P 500. Se propone la creación de un pipeline de datos que permita la implementación de la arquitectura propuesta.
2. Uso de **Autoencoders Variacionales (VAEs)** para la reducción de dimensionalidad no lineal.
3. Desarrollo de una **Red Generativa Adversaria (GAN)** para sintetizar escenarios de mercado realistas.
4. Optimización de la cartera mediante la **Divergencia de Kullback-Leibler** como métrica de riesgo informativo.

1.4. Estructura del trabajo

La memoria se organiza de la siguiente manera: el Capítulo 2 revisa el estado del arte; el Capítulo 3 detalla la metodología y objetivos; el Capítulo 4 expone el marco normativo; el Capítulo 5 desarrolla de forma específica la contribución; el Capítulo 6 describe el código fuente y los datos analizados; el Capítulo 7 recoge las conclusiones; y el Capítulo 8 aborda limitaciones y prospectiva.

2. Objetivos

3. Marco Teórico

4. Estado del Arte

En este capítulo, se presenta una revisión de los principales enfoques existentes en la literatura para la optimización de carteras y el uso de técnicas de aprendizaje automático en finanzas. En primer lugar, se presentan los métodos clásicos basados en la media-varianza. A continuación, se introducen los enfoques de aprendizaje automático y aprendizaje profundo aplicados al análisis financiero. Finalmente, se presentan los modelos generativos, como una línea de investigación emergente con potencial para abordar las limitaciones de los enfoques tradicionales.

4.1. El Modelo de Media-Varianza de Markowitz

En 1952, Harry Markowitz introdujo el modelo de media-varianza para la optimización de carteras. En el modelo de (Markowitz, 1952), el autor toma la varianza como la medida del riesgo. Definiendo cada activo como una variable aleatoria, teniendo en consideración el retorno esperado para un tiempo determinado, así como la variabilidad medida a través de la varianza de dicho retorno. De forma pionera, se desmiente la idea de que el inversor deba limitarse a buscar el máximo retorno esperado a la hora de confeccionar su cartera. Si uno se guía únicamente por esta premisa, Markowitz nos muestra que no tiene en consideración el riesgo asociado a los activos seleccionados, así como la correlación entre los retornos de los mismos.

Es por ello que el artículo se centra en la optimización de carteras buscando aquellas combinaciones de activos que, para igual retorno esperado, minimicen la varianza, es decir, el riesgo. Por lo tanto, el problema de optimizar una cartera se reduce a encontrar máximos o mínimos dentro de una función de dos variables, fijando una de ellas. Teniendo en cuenta solo aquellas combinaciones de activos que se puedan realizar, las combinaciones deseadas forman lo que el autor denomina la frontera eficiente.

Se establece la idea de que el inversor debe confeccionar su cartera buscando como objetivo no solo el máximo retorno esperado, sino considerando el riesgo asociado y valorando positivamente por lo tanto la diversificación entre diversos activos para mitigar el riesgo.

Matemáticamente, el problema de optimización se puede formular como la maximización de la utilidad esperada, ponderando el retorno esperado frente al riesgo:

$$\max_w w^\top \mu - \frac{\lambda}{2} w^\top \Sigma w \quad \text{s.a.} \quad \mathbf{1}^\top w = 1 \quad (4.1)$$

En ella, el objetivo es determinar el vector de pesos (w) que maximiza la rentabilidad esperada de la cartera penalizada por su nivel de riesgo.

En ella, el objetivo es determinar el vector de pesos w que maximiza la rentabilidad esperada de la cartera penalizada por su nivel de riesgo.

El primer término, $w^\top \mu$, representa la rentabilidad esperada de la cartera. Matemáticamente, se trata del producto escalar entre el vector de pesos $w \in \mathbb{R}^n$ y el vector de retornos esperados $\mu \in \mathbb{R}^n$, lo que equivale a una combinación lineal de los retornos esperados de los activos ponderados por su peso en la cartera.

El segundo término, $\frac{\lambda}{2} w^\top \Sigma w$, introduce una penalización por riesgo. En este caso, $\Sigma \in \mathbb{R}^{n \times n}$ es la matriz de varianzas-covarianzas de los retornos, y la expresión cuadrática $w^\top \Sigma w$ representa la varianza de la cartera. El parámetro $\lambda > 0$ es el coeficiente de aversión al riesgo, que controla el equilibrio entre rentabilidad y riesgo: valores más altos de λ implican una mayor penalización del riesgo y, por tanto, una preferencia por carteras más conservadoras.

La restricción $\mathbf{1}^\top w = 1$ garantiza que la suma de los pesos sea igual a uno, lo que implica que se invierte la totalidad del capital disponible. Esta restricción define carteras totalmente invertidas y excluye la posibilidad de mantener capital sin asignar.

En conjunto, este problema establece un compromiso entre maximizar la rentabilidad esperada y minimizar la varianza, constituyendo la base de la teoría moderna de carteras.

4.2. Limitaciones de la Teoría Clásica

Markowitz fue pionero, sin embargo su modelo presenta limitaciones aparentes, que con las herramientas actuales de análisis de datos, se pueden superar.

El modelo asume que los retornos de los activos financieros siguen una distribución normal. Sin embargo, la evidencia empírica muestra que no siempre se puede asumir la normalidad en los retornos de los activos. Por otro lado, las correlaciones entre activos financieros no son estáticas, sino que varían a lo largo del tiempo.

En periodos de alta volatilidad, el modelo de Markowitz no es capaz de capturar los cambios en la correlación entre activos, lo que puede llevar a errores en la gestión de la cartera. Esta limitación es especialmente relevante, teniendo en cuenta que dichos

momentos son los que presentan una mayor oportunidad para el inversor.

El modelo es incapaz de considerar relaciones de orden superior, al asumir la varianza como medida de riesgo. Para capturar la distribución completa, es necesario ir más allá del método media-varianza.

En este trabajo, se propone una metodología híbrida, que combine las bases teóricas tradicionales con el modelado generativo y la potencia de cálculo moderna.

4.3. Fundamentos de la Teoría de la Información

La identificación del riesgo con la varianza, limita la capacidad de los modelos tradicionales para capturar relaciones no lineales entre activos. Como alternativa, se propone el uso de la teoría de la información, que propone un tratamiento heurístico del riesgo. Se propone el uso de la entropía como medida de la relación o explicabilidad de los rendimientos de un activo financiero mediante los de otros.

De manera intuitiva, la entropía es la magnitud que trata de medir la incertidumbre de un sistema. Es, por lo tanto, la cantidad de ruido que contiene el mismo. La entropía se define entonces como la medida de incertidumbre pura del mercado.

Siguiendo a (Cover y Thomas, 2006) y entendiendo el retorno de un activo como una variable aleatoria, la entropía se define como:

$$H(X) = - \sum_{i=1}^n p(x_i) \log p(x_i) \quad (4.2)$$

Esta ecuación define la Entropía de Shannon, la cual constituye la unidad de medida fundamental de la incertidumbre en la Teoría de la Información. En el contexto de este trabajo, su interpretación y componentes se detallan a continuación:

- $H(X)$ representa la entropía de la variable aleatoria X (los retornos del activo). No se debe interpretar como una medida de riesgo lineal, sino como una medida de dispersión de la información. Una entropía elevada indica que los retornos están muy distribuidos y son menos predecibles, mientras que una entropía baja sugiere una mayor concentración de la probabilidad en valores específicos.
- $p(x_i)$ es la función de masa de probabilidad del retorno x_i . Indica la probabilidad de que el activo presente un rendimiento específico.

- $\log p(x_i)$ es el logaritmo de la probabilidad de que el activo i tenga un retorno x_i . La elección del logaritmo es una cuestión técnica, permite que la medida sea aditiva. Matemáticamente, los eventos menos probables, aportan una mayor cantidad de información sorpresa a la sumatoria. La naturaleza del logaritmo y de la probabilidad, siendo un número entre 0 y 1, hace que el logaritmo sea una cantidad negativa.

A diferencia de la varianza, la entropía captura la complejidad estructural de la distribución de los retornos de un activo. Al maximizar la entropía en la selección de carteras, bajo el principio de Máxima Entropía, se busca una distribución que sea compatible con los datos observados pero que no asuma información adicional inexistente, reduciendo así el sesgo del modelo ante regímenes de mercado desconocidos.

Para medir la discrepancia entre dos distribuciones, se propone el uso de la divergencia de Kullback-Leibler (KLD), definida como:

$$D_{KL}(P \parallel Q) = \sum_{i=1}^n p(x_i) \log \frac{p(x_i)}{q(x_i)} \quad (4.3)$$

Donde $p(x_i)$ es la probabilidad de que el activo i tenga un retorno x_i en la distribución P , y $q(x_i)$ es la probabilidad de que el activo i tenga un retorno x_i en la distribución Q .

Como evolución de la correlación de (Markowitz, 1952), se propone el uso de la Información Mutua (MI), definida como:

$$I(X; Y) = H(X) + H(Y) - H(X, Y) \quad (4.4)$$

Donde $H(X)$ es la entropía de la variable X , $H(Y)$ es la entropía de la variable Y , y $H(X, Y)$ es la entropía conjunta de las variables X y Y .

La MI se puede entender como la medida de la relación o explicabilidad de los rendimientos de un activo financiero mediante los de otros.

Mientras que la correlación es una medida de la relación lineal entre dos variables, la MI es una medida de la relación no lineal, permitiendo detectar relaciones caóticas o complejas.

4.4. Modelado Generativo

Para superar las limitaciones de la Teoría Clásica a la hora de gestionar la complejidad subyacente a los mercados financieros, se propone el uso de modelos generativos.

Los modelos generativos permiten aprender directamente de la distribución subyacente de los datos, minimizando la dependencia de supuestos paraméricos rígidos. Este enfoque resulta especialmente útil para modelar colas pesadas, asimetrías y dependencias no lineales presentes en los precios de activos.

4.4.1. Autoencoders Variacionales (VAEs)

Los Autoencoders Variacionales (VAEs), introducidos por (Kingma y Welling, 2013), representan una evolución respecto a los autoencoders tradicionales, al transitar de un aprendizaje determinista a uno probabilístico. Mientras que un autoencoder convencional mapea los datos a un punto fijo en el espacio latente, el VAE mapea la entrada a una distribución de probabilidad, generalmente una Gaussiana multivariante.

La arquitectura se divide en dos componentes críticos: el Encoder (codificador) y el Decoder (decodificador). El codificador extrae una representación comprimida de los retornos financieros, definiendo los parámetros de la distribución latente: la media μ y la varianza σ . Para permitir el entrenamiento mediante retropropagación, se emplea el *reparameterization trick*, donde el vector latente z se calcula como:

$$z = \mu + \sigma \odot \epsilon, \quad \text{donde } \epsilon \sim \mathcal{N}(0, I) \quad (4.5)$$

Desde una perspectiva económica, esta estructura permite filtrar el ruido propio del mercado, reteniendo únicamente los factores latentes o “señales estructurales” que explican el comportamiento conjunto de los activos. La función de pérdida del VAE, conocida como ELBO (Evidence Lower Bound), equilibra la precisión de la reconstrucción de los datos con un término de regularización basado en la divergencia de Kullback-Leibler, garantizando que el espacio latente sea continuo y estructurado, evitando así el sobreajuste a eventos ruidosos transitorios.

La ecuación del ELBO es la siguiente:

$$\mathcal{L}(\theta, \phi; \mathbf{x}) = \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x}|\mathbf{z})] - D_{KL}(q_\phi(\mathbf{z}|\mathbf{x}) \parallel p(\mathbf{z})) \quad (4.6)$$

La ecuación anterior se descompone en dos términos fundamentales que rigen el aprendizaje del modelo:

- $\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x}|\mathbf{z})]$ (**Término de Reconstrucción**): Representa la log-verosimilitud esperada de los datos. En el contexto financiero, mide la capacidad del decodificador

para reconstruir los retornos originales $\mathbf{x}$ a partir de las muestras del espacio latente $\mathbf{z}$. Un valor alto indica que el modelo preserva la información esencial del mercado.

- $D_{KL}(q_\phi(\mathbf{z}|\mathbf{x}) \parallel p(\mathbf{z}))$ (**Regularizador de Divergencia KL**): Actúa como una penalización que mide la discrepancia entre la distribución posterior aprendida por el codificador y una distribución *prior* (generalmente una Normal unitaria $\mathcal{N}(0, I)$). Este término garantiza que el espacio latente sea continuo y regular, evitando el colapso de la información y permitiendo la generación de nuevos escenarios coherentes.

En definitiva, en su intento por engañar al decodificador, el codificador aprende la estructura latente del mercado, modelando factores no observables y reduciendo la dimensionalidad del problema.

4.4.2. Redes Generativas Adversarias (GANs)

Las Redes Generativas Adversarias (GANs), propuestas por (Salimans y cols., 2016), introducen un paradigma de aprendizaje basado en la teoría de juegos. A diferencia de otros modelos, las GANs no maximizan una verosimilitud explícita, sino que establecen una competición entre dos redes neuronales: el Generador (G) y el Discriminador (D).

En el contexto financiero, el Generador intenta sintetizar series temporales de retornos que sean estadísticamente indistinguibles de los reales, mientras que el Discriminador se entrena para identificar si una muestra proviene del conjunto de datos histórico (p_{data}) o si ha sido creada artificialmente (p_g). Este proceso se formaliza mediante una función de valor minimax $V(D, G)$:

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))] \quad (4.7)$$

La gran ventaja de las GANs para la optimización de carteras radica en su capacidad para capturar momentos de orden superior (asimetría y curtosis) sin necesidad de definirlos manualmente. Al alcanzar un equilibrio de Nash, el generador es capaz de producir escenarios de “estrés” realistas que no están presentes de forma idéntica en el pasado, pero que son estadísticamente posibles, proporcionando una base mucho más robusta para el cálculo del riesgo que la simple matriz de covarianza. No es necesario asumir ninguna distribución en concreto, sino que se modelan directamente los datos observados, siendo esto particularmente útil para escenarios extremos. Sin embargo, su entrenamiento presenta

desafíos como el *mode collapse*, lo que justifica en este trabajo el uso de una arquitectura híbrida con VAE para estabilizar el aprendizaje.

4.4.3. Estado del Arte Reciente: Modelos de Difusión

En los últimos dos años, el modelado generativo ha experimentado un cambio de paradigma hacia los Score-based Diffusion Models. Tal como proponen (Aghapour, Bayraktar, y Yuan, 2025), estos modelos pueden superar algunas de las inestabilidades de las GANs al aprender a revertir un proceso de difusión estocástica.

El principio fundamental consiste en destruir gradualmente la estructura de los retornos financieros añadiendo ruido Gaussiano hasta obtener ruido blanco, para después entrenar una red neuronal que aprenda a revertir el proceso de difusión. Este enfoque permite una generación de escenarios estable y diversificada.

(Aghapour y cols., 2025) demuestra que, al aplicar modelos de difusión a problemas de selección dinámica de carteras, es posible a priori obtener resultados que batan sistemáticamente a los índices de referencia (como el S&P 500) y a las carteras de Markowitz tradicionales. Esta metodología es innovadora, siendo estos estudios relativamente recientes. Permite modelar la evolución temporal de los activos con una fidelidad aparentemente superior, capturando la dependencia temporal y el agrupamiento de volatilidad (*volatility clustering*) de manera orgánica y no paramétrica.

5. Objetivos Concretos y Metodología de Trabajo

En este capítulo, se presentan los objetivos concretos y la metodología de trabajo seguida para la realización del presente trabajo de investigación. Se detalla el diseño experimental y la lógica de construcción de la arquitectura híbrida VAE-GAN. Asimismo, se presentan los fundamentos teóricos que justifican el empleo de dichas aproximaciones. Se describe el proceso de preprocesamiento de datos, la formalización matemática de las funciones de pérdida y el protocolo de validación para la selección de carteras.

5.1. Adquisición de Datos y Preprocesamiento de los Mismos

Parte fundamental para realizar el experimento que se propone es la adquisición de datos reales para poder llevar a cabo un estudio relevante.

Empleando la herramienta `yfinance` se creará un pipeline de datos para adquirir datos de series históricas de los últimos 10 años de los principales activos del S&P 500.

Se emplearán estos datos por su relevancia. El mercado estadounidense es sin duda el más importante en cuanto a capitalización de mercado. Este índice agrupa a las 500 mayores empresas de Estados Unidos. Con alta diversificación, un rendimiento histórico anual compuesto de más del 11 % y las empresas más grandes y con mayores beneficios del mundo, se considera un escenario fundamental para cualquier inversor independientemente del tamaño de su cartera y su aversión al riesgo.

Para el preprocesado, se ha aplicado una normalización Min-Max tras un tratamiento de valores atípicos (*outliers*). Este escalado al rango $[0, 1]$ es crítico para asegurar la estabilidad numérica de las funciones de activación de las redes neuronales y evitar la explosión del gradiente durante el entrenamiento del VAE y la GAN.

Asimismo, se llevarán a cabo todas las transformaciones que sean pertinentes para poder llevar a cabo los objetivos del trabajo.

Se procurará establecer la trazabilidad de los datos, para asegurar que los mismos son de fuentes confiables.

5.2. Arquitectura del Sistema Propuesto

Una vez habiendo extraído los datos, se elaborará una estructura en línea con lo expuesto en los apartados previos.

La arquitectura propuesta para el modelo se articula en tres módulos independientes:

- Extracción de características con Autoencoders Variacionales (VAEs) para la reducción de la dimensionalidad de forma no lineal. El VAE proyecta los datos históricos hacia un espacio latente de menor dimensión. Este proceso permite eliminar ruido, reteniendo únicamente las características persistentes.
- Generación de escenarios: Redes Generativas Adversarias (GANs) para sintetizar escenarios de mercado realistas, la GAN entrena sobre el espacio latente sintetizando vectores de retornos que preservan las dependencias no lineales y los momentos estadísticos de orden superior.
- Optimización de la cartera mediante la Divergencia de Kullback-Leibler como métrica de riesgo informativo. Se sustituye el uso de la varianza como medida de riesgo por la Divergencia KL como métrica del mismo. Se optimiza la cartera para que sea más robusta frente a la entropía del mercado.

De manera intuitiva, el modelo filtra el ruido empleando el VAE, añadiendo ganancia de información a través del espacio latente e infiriendo relaciones no lineales entre los activos, así como mejorando la reactividad a condiciones de alta volatilidad. Los GANs sintetizan escenarios realistas de mercado para comprobar la robustez de la cartera.

El mercado financiero es un sistema caótico, en el cuál existe una gran cantidad de variables interconectadas de maneras que van mucho más allá de la linealidad. Además, es un sistema de nivel dos, por lo tanto, las propias predicciones que se realizan sobre el mismo influyen en los resultados que se obtienen. El VAE pretende encontrar el espacio donde realmente viven las variables que mueven el mercado. Este planteamiento es superior al de métodos lineales como el PCA, pues el mercado no es un sistema lineal.

El Espacio Latente Z es el lugar donde las interconexiones entre variables se ponen de manifiesto.




Figura 5.1: Arquitectura híbrida VAE-GAN para la generación y optimización de carteras.

El VAE toma datos históricos de retornos reales para encontrar las variables latentes asociadas a los mismos, modelando las relaciones subyacentes que realmente mueven conjuntamente los valores de activos diferentes. El Generador recibe este espacio latente, y trabajando con el Discriminador es capaz de crear variaciones gracias a la introducción de ruido. Con este modelo, podemos crear escenarios sintéticos tan similares a la realidad que no se puedan distinguir de verdaderos retornos históricos. Esto permite realizar la optimización final sobre datos probables, generando un conjunto de pesos para una cartera óptima.

5.3. Función de Pérdida y Criterios de Optimización

Siguiendo el enfoque propuesto por (Kingma y Welling, 2013), el objetivo del modelo VAE es maximizar la verosimilitud marginal de los datos observados. Dado un conjunto de datos $x_{i=1}^N$, la verosimilitud marginal se descompone como la suma sobre las observaciones individuales:

$$\log p_{\theta}(x^{(1)}, \dots, x^{(N)}) = \sum_{i=1}^N \log p_{\theta}(x^{(i)}) \quad (5.1)$$

Sin embargo, el cálculo directo de $\log p_{\theta}(x^{(i)})$ resulta intratable debido a la integración sobre las variables latentes. Para abordar este problema, se introduce una distribución aproximada $q_{\phi}(z|x)$, lo que permite descomponer la log-verosimilitud como:

$$\log p_{\theta}(x^{(i)}) = D_{KL}(q_{\phi}(z|x^{(i)}) \| p_{\theta}(z|x^{(i)})) + \mathcal{L}(\theta, \phi; x^{(i)}) \quad (5.2)$$

Dado que la divergencia de Kullback-Leibler es siempre no negativa, el término $\mathcal{L}(\theta, \phi; x^{(i)})$ constituye una cota inferior variacional (Evidence Lower Bound, ELBO):

$$\log p_\theta(x^{(i)}) \geq \mathcal{L}(\theta, \phi; x^{(i)}) \quad (5.3)$$

Esta cota puede expresarse como:

$$\mathcal{L}(\theta, \phi; x^{(i)}) = \mathbb{E}_{q_\phi(z|x^{(i)})} [\log p_\theta(x^{(i)}, z) - \log q_\phi(z|x^{(i)})] \quad (5.4)$$

o, de forma equivalente, separando sus componentes principales:

$$\mathcal{L}(\theta, \phi; x^{(i)}) = -D_{KL}(q_\phi(z|x^{(i)}) \| p(z)) + \mathbb{E}_{q_\phi(z|x^{(i)})} [\log p_\theta(x^{(i)}|z)] \quad (5.5)$$

Esta formulación revela dos términos fundamentales:

- Un término de regularización, que fuerza la distribución latente aproximada $q_\phi(z|x)$ a mantenerse cercana a la probabilidad a priori $p(z)$.
- Un término de reconstrucción, que mide la capacidad del modelo generativo para reproducir los datos observados a partir de las variables latentes.

El proceso de entrenamiento consiste en maximizar esta cota inferior respecto a los parámetros del modelo generativo θ y los parámetros variacionales ϕ .

No obstante, la optimización presenta dificultades prácticas. En particular, el cálculo del gradiente respecto a ϕ mediante estimadores Monte Carlo directos presenta alta varianza, lo que dificulta la convergencia y hace inviable su uso en la práctica. Para superar esta limitación, se introduce el truco de reparametrización, que permite expresar la variable latente como una transformación determinista de una variable aleatoria auxiliar:

$$z = \mu_\phi(x) + \sigma_\phi(x) \cdot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I) \quad (5.6)$$

Esta reformulación permite trasladar la fuente de aleatoriedad fuera de la red neuronal, haciendo posible aplicar técnicas estándar de optimización basadas en gradiente (backpropagation) con estimadores de baja varianza.

En conjunto, este marco convierte el problema de inferencia variacional en uno de optimización eficiente, permitiendo el entrenamiento conjunto del encoder y el decoder dentro de una arquitectura diferenciable end-to-end.

En secciones posteriores se describen cada una de las etapas, así como la validación final de la cartera mediante la comparación con diferentes modelos de elaboración de carteras.

5.4. Generación y Selección de Pesos

Una vez estructurado el Espacio Latente, se procede a la generación de escenarios sintéticos. Para ello, se emplea la arquitectura adversarial de las Redes Generativas Antagónicas. En este enfoque, se introduce un marco de entrenamiento adversario en el que dos redes neuronales compiten entre sí, el Generador (G) y el Discriminador (D). El Generador se encarga de generar escenarios sintéticos que sean indistinguibles de los datos reales, mientras que el Discriminador se encarga de distinguir entre los datos reales y los sintéticos. El Generador se entrena para maximizar la probabilidad de error del Discriminador, mientras que este último se entrena para maximizar la probabilidad de distinguir entre los datos reales y los sintéticos.

El Discriminador sustituye pues en el enfoque moderno a lo que (Markowitz, 1952) denominaba como el juicio del hombre práctico. El Generador entrena para buscar escenarios que sean indistinguibles de la realidad, utilizando la estructura latente previamente establecida así como ruido aleatorio introducido en la entrada.

Por lo tanto, tenemos un juego minimax de suma cero donde el objetivo es alcanzar un equilibrio de Nash. En este escenario, el Generador (G) busca maximizar la probabilidad de error del Discriminador (D), mientras que este último se optimiza para distinguir con precisión entre la distribución de datos reales p_{data} y la distribución sintética p_g .

5.5. Herramientas y Tecnologías Utilizadas

6. Marco Normativo y Protección de Datos

Se analiza el entorno legal y ético aplicable, con especial énfasis en el Reglamento General de Protección de Datos (RGPD) para el uso de datos masivos y las directrices éticas sobre el uso de la Inteligencia Artificial en el sector financiero.

6.1. Identificación del Tratamiento de Datos

En el desarrollo del presente Trabajo de Fin de Máster, el tratamiento de datos se limita estrictamente a series temporales de precios de activos financieros públicos procedentes del índice S&P 500. Se hace constar que no se han utilizado, procesado ni almacenado datos de carácter personal de terceros identificados o identificables, cumpliendo con el principio de minimización de datos.

6.2. Cumplimiento del RGPD y la Ley Orgánica 3/2018 (LOPDGDD)

A pesar de la naturaleza pública de los datos financieros, el proyecto se alinea con el Reglamento General de Protección de Datos (RGPD) y la Ley Orgánica 3/2018 en los siguientes términos:

- **Finalidad:** Los datos son tratados con el fin exclusivo de investigación académica y desarrollo de modelos de aprendizaje profundo.
- **Seguridad:** El procesamiento de los datos se realiza en un entorno local, garantizando la integridad de los mismos y evitando cualquier fuga de información que pudiera afectar a la infraestructura del sistema.
- **Análisis de Riesgo:** Dado que no existe tratamiento de datos de personas físicas, el riesgo para los derechos y libertades de las personas es nulo.

6.3. Consideraciones Éticas y Propiedad Intelectual

El acceso a los datos se ha realizado mediante la API de Yahoo Finance, respetando los términos y condiciones de uso para fines educativos y de investigación. El código fuente desarrollado y los escenarios sintéticos generados por la arquitectura VAE-GAN son de autoría propia, garantizando la transparencia en el proceso de generación de información. Sin embargo, como suele ocurrir con este tipo de modelos, la elección de los activos puede carecer de explicabilidad aparente.

Se hace constar que la elección de unos activos determinados frente a otros puede no ser explicable mediante lógicas económicas o financieras fundamentales, basadas en las métricas principales en este caso de las empresas seleccionadas. Se recomienda la comprensión profunda de la naturaleza del mercado.

Incluso con la capacidad de construir un modelo sólido, no se puede aseverar que la cartera vaya realmente a cumplir con las expectativas de rentabilidad calculadas.

7. Código Fuente y Datos Analizados

8. Conclusiones

9. Limitaciones y Prospectiva

Referencias

- Aghapour, A., Bayraktar, E., y Yuan, F. (2025). Solving dynamic portfolio selection problems via score-based diffusion models. *arXiv preprint arXiv:2507.09916*. (Valida el uso de modelos de difusión para batir al S&P 500 y al modelo de Markowitz.)
- Cover, T. M., y Thomas, J. A. (2006). *Elements of information theory* (2nd ed.). John Wiley & Sons.
- Kingma, D. P., y Welling, M. (2013). Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*.
- Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91.
- Salimans, T., Goodfellow, I., Zaremba, W., Cheung, V., Radford, A., Chen, X., y Chen, X. (2016). Improved techniques for training gans. En D. Lee, M. Sugiyama, U. Luxburg, I. Guyon, y R. Garnett (Eds.), *Advances in neural information processing systems* (Vol. 29). Curran Associates, Inc. Descargado de https://proceedings.neurips.cc/paper_files/paper/2016/file/8a3363abe792db2d8761d6403605aeb7-Paper.pdf