



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Análisis y Visualización de Datos Masivos

Generación de Escenarios Sintéticos para Optimización de Carteras del S&P 500 mediante Arquitecturas VAE-GAN

Trabajo Fin de Estudios

presentado por: Daniel Machín González

Dirigido por: Jesús Cigales Canga

Ciudad: San Bartolomé

Fecha: June 6, 2026

Índice general

Resumen	v
Abstract	vi
1. Introducción	1
1.1. Motivación	2
1.2. Planteamiento del trabajo	2
1.3. Estructura del trabajo	3
2. Objetivos	4
2.1. Objetivo general	4
2.2. Objetivos específicos	4
2.3. Alcance y delimitación del trabajo	5
3. Marco Teórico	7
3.1. Teoría moderna de carteras	7
3.2. Modelo de media-varianza de Markowitz	8
3.3. Riesgo financiero y hechos estilizados	9
3.4. Limitaciones de la varianza como medida de riesgo	9
3.5. Teoría de la información	10
3.6. Entropía, divergencia KL e información mutua	11
3.7. Inteligencia artificial, aprendizaje automático y aprendizaje profundo	12
3.8. Modelos generativos profundos	13
3.9. Autoencoders Variacionales	13
3.10. Redes Generativas Adversarias y Wasserstein GAN	14
3.11. Modelos de difusión	15
4. Estado del Arte	17
4.1. Optimización clásica de carteras	17
4.2. Aprendizaje automático y deep learning en gestión de carteras	18
4.3. Modelos generativos para series financieras	18
4.4. Modelos de difusión para selección dinámica de carteras	19
4.5. Síntesis crítica y hueco de investigación	20

5. Metodología	22
5.1. Diseño general del experimento	22
5.2. Adquisición de datos	22
5.3. Preprocesamiento de los datos	23
5.4. Arquitectura VAE-GAN propuesta	23
5.5. Generación de escenarios sintéticos	25
5.6. Función de pérdida y criterios de optimización	25
5.7. Optimización y selección de pesos	27
5.8. Benchmarks de comparación	27
6. Herramientas y tecnologías	28
7. Marco normativo, ética y protección de datos	29
7.1. Identificación del Tratamiento de Datos	29
7.2. Cumplimiento del RGPD y la Ley Orgánica 3/2018 (LOPDGDD)	29
7.3. Consideraciones Éticas y Propiedad Intelectual	30
8. Planificación del trabajo	31
9. Conclusiones preliminares	32
Referencias	33

Índice de figuras

5.1. Arquitectura híbrida VAE-GAN para la generación y optimización de carteras.	24
--	----

Índice de cuadros

Resumen

Tu resumen en español...

Abstract

Your abstract in English...

1. Introducción

El mercado financiero, entendido como el espacio en el cual se compran y se venden activos financieros (acciones, bonos, divisas, materias primas y criptomonedas principalmente), constituye un ámbito de estudio especialmente adecuado para poner en práctica el uso de tecnologías Big Data.

Las tecnologías Big Data se definen como las herramientas que permiten gestionar, almacenar y analizar conjuntos de datos masivos que superan la capacidad de tratamiento tradicional.

Desde los comienzos de la teoría económica moderna, se ha considerado el mercado financiero como un sistema caótico. A diferencia de un sistema puramente aleatorio, un sistema caótico presenta patrones y reglas subyacentes que permiten realizar determinadas predicciones sobre su comportamiento.

El caos se caracteriza por la complejidad. En un sistema caótico, las variables presentan relaciones no lineales, a menudo difíciles de detectar a simple vista. Esto deriva en la impredecibilidad del sistema, puesto que pequeñas variaciones en las condiciones iniciales pueden llevar a resultados completamente diferentes.

Además, el mercado financiero puede entenderse como un sistema de segundo orden, dado que las propias predicciones que se realizan sobre él pueden influir en los resultados que se obtienen.

En el presente trabajo se propone abordar el problema de confeccionar una cartera de inversión, esto es, un subconjunto de los activos financieros disponibles, de forma eficiente.

(Markowitz, 1952) introduce el modelo de media-varianza como una de las aproximaciones clásicas para la gestión de carteras de inversión. Este modelo se fundamenta en el principio riesgo-rendimiento, buscando maximizar el rendimiento esperado para un determinado nivel de riesgo asumido por el inversor.

Con el uso de tecnologías Big Data y, en particular, con el uso de modelos generativos como los **Autoencoders Variacionales (VAEs)** y las **Redes Generativas Adversarias (GANs)**, se propone una aproximación a la confección de carteras desde una perspectiva no lineal.

1.1. Motivación

La gestión de carteras de inversión ha estado dominada durante décadas por la Teoría de Cartera Moderna (MPT), introducida por (Markowitz, 1952). Este marco teórico se fundamenta en la optimización media-varianza, bajo el supuesto de que los retornos de los activos financieros siguen una distribución normal. Sin embargo, la evidencia empírica en el análisis de datos masivos financieros demuestra que los mercados reales presentan características que este modelo no logra capturar: la curtosis excesiva (colas pesadas), la asimetría y la volatilidad estocástica.

En el contexto actual de Big Data, la incapacidad de los modelos lineales para gestionar la complejidad representa una limitación relevante. Los eventos extremos ocurren con una frecuencia mayor en la realidad de la que predeciría un modelo normal, lo que hace que la varianza sea una métrica de riesgo insuficiente. El uso de modelos generativos como las GANs (Salimans y cols., 2016) y los VAEs (Kingma y Welling, 2013) ofrece un nuevo paradigma para aprender la distribución subyacente de los datos sin imponer una forma paramétrica rígida.

Frente a otras aproximaciones, como el uso de modelos de Machine Learning o sistemas de ecuaciones diferenciales, los modelos generativos permiten trabajar desde una perspectiva probabilística. Estos modelos se adaptan a los datos y ofrecen flexibilidad frente a cambios drásticos.

1.2. Planteamiento del trabajo

La elección de esta arquitectura, como se exponía previamente, no busca predecir el precio futuro de los activos, sino generar diversos escenarios posibles para comprender el riesgo subyacente de los mismos.

El presente Trabajo de Fin de Máster propone una metodología híbrida que integra el modelado generativo y la teoría de la información. El núcleo de la investigación se divide en cuatro fases:

1. Extracción de datos de series históricas del S&P 500. Se propone la creación de un pipeline de datos que permita la implementación de la arquitectura propuesta.
2. Uso de **Autoencoders Variacionales (VAEs)** para la reducción de dimensionalidad no lineal.

3. Desarrollo de una **Red Generativa Adversaria (GAN)** para sintetizar escenarios de mercado realistas.
4. Optimización de la cartera mediante la **Divergencia de Kullback-Leibler** como métrica de riesgo informativo.

1.3. Estructura del trabajo

La memoria se organiza de la siguiente manera: el Capítulo 2 presenta los objetivos del trabajo, diferenciando entre el objetivo general, los objetivos específicos y el alcance de la investigación. El Capítulo 3 desarrolla el marco teórico, introduciendo la teoría moderna de carteras, el modelo de media-varianza de Markowitz, la teoría de la información y los principales modelos generativos considerados. El Capítulo 4 revisa el estado del arte, analizando los enfoques existentes en optimización de carteras, aprendizaje automático aplicado a finanzas y modelado generativo de series financieras. El Capítulo 5 describe la metodología propuesta, incluyendo la adquisición y el preprocesamiento de datos, la arquitectura VAE-GAN, la generación de escenarios sintéticos y los criterios de comparación. El Capítulo 6 recoge las herramientas y tecnologías empleadas. El Capítulo 7 expone el marco normativo, ético y de protección de datos. El Capítulo 8 presenta la planificación del trabajo. Finalmente, el Capítulo 9 recoge las conclusiones del estudio.

2. Objetivos

2.1. Objetivo general

El objetivo principal del trabajo es diseñar una metodología para la optimización de carteras basada en la generación de escenarios sintéticos mediante técnicas de inteligencia artificial.

En concreto, la metodología propuesta se orienta al análisis de retornos financieros de activos pertenecientes al S&P 500, empleando una arquitectura híbrida VAE-GAN. El propósito es estudiar si la generación de escenarios sintéticos puede proporcionar una base alternativa para la construcción de carteras, especialmente frente a enfoques clásicos basados en supuestos lineales y medidas de riesgo tradicionales.

Para ello, se plantea comparar los resultados obtenidos mediante la metodología propuesta con carteras construidas a partir del modelo de media-varianza de Markowitz y con una cartera equiponderada. De este modo, se busca evaluar si el uso de modelos generativos puede aportar información adicional en el proceso de asignación de pesos, especialmente en contextos donde los retornos financieros presentan colas pesadas, asimetrías y dependencias no lineales.

2.2. Objetivos específicos

A continuación, se detallan los objetivos específicos que guiarán el desarrollo del trabajo:

- Revisar la teoría moderna de carteras y el modelo de media-varianza de Markowitz como base clásica de la optimización de carteras.
- Analizar las limitaciones de la varianza y de la matriz de covarianzas como medidas suficientes para representar el riesgo financiero.
- Estudiar conceptos relevantes de la teoría de la información, como la entropía, la divergencia de Kullback-Leibler y la información mutua, en relación con el análisis de distribuciones de retornos.
- Revisar los fundamentos de los modelos generativos profundos, especialmente VAE, GAN, WGAN y modelos de difusión.

- Construir un pipeline de adquisición de datos financieros de activos pertenecientes al S&P 500.
- Preprocesar los datos financieros para su uso posterior, incluyendo el tratamiento de precios ajustados, cálculo de log-retornos, limpieza de datos y normalización.
- Diseñar una arquitectura VAE para obtener una representación latente de la distribución de retornos financieros.
- Diseñar una arquitectura GAN o WGAN para la generación de escenarios sintéticos de mercado.
- Evaluar la calidad de los escenarios generados mediante métricas estadísticas e informativas.
- Comparar las carteras obtenidas mediante la metodología propuesta con carteras construidas mediante el modelo de Markowitz, una cartera equiponderada y el índice S&P 500 como benchmark.

2.3. Alcance y delimitación del trabajo

Este trabajo tiene un carácter académico y experimental. No pretende ofrecer una recomendación de inversión ni una propuesta de asignación de capital a valores concretos. Tampoco busca predecir de forma puntual los precios futuros de determinados activos financieros. Su objetivo se centra en estudiar la generación de escenarios sintéticos de retornos y su posible utilización dentro de un proceso de optimización de carteras.

El ámbito de aplicación se limita a un conjunto de activos financieros pertenecientes al S&P 500. La selección final de activos dependerá de la disponibilidad, calidad y completitud de los datos históricos, así como de la capacidad de procesamiento disponible para entrenar los modelos propuestos.

Asimismo, el trabajo estará condicionado por la frecuencia temporal de los datos utilizados y por las decisiones adoptadas en el preprocesamiento, tales como el cálculo de retornos, el tratamiento de valores ausentes, la normalización y la división entre conjuntos de entrenamiento y evaluación.

Los resultados obtenidos deberán interpretarse como evidencia experimental dentro del marco definido en este trabajo. En ningún caso deben entenderse como garantía de

rendimiento futuro ni como recomendación financiera aplicable directamente a decisiones reales de inversión.

3. Marco Teórico

En este capítulo se presentan los fundamentos conceptuales sobre los que se apoya el presente Trabajo de Fin de Máster. En primer lugar, se introducen los principios básicos de la teoría moderna de carteras y el modelo de media-varianza de Markowitz. A continuación, se analizan algunas de sus principales limitaciones, especialmente en lo relativo al uso de la varianza como medida de riesgo. Posteriormente, se presentan conceptos fundamentales de la teoría de la información, así como su utilidad para comparar distribuciones y medir incertidumbre. Finalmente, se introducen los modelos generativos profundos, con especial atención a los Autoencoders Variacionales, las Redes Generativas Adversarias y los modelos de difusión.

3.1. Teoría moderna de carteras

La teoría moderna de carteras constituye uno de los marcos fundamentales para la gestión cuantitativa de inversiones. Su aportación principal consiste en formalizar la relación entre rentabilidad esperada y riesgo, mostrando que la selección de activos no debe basarse únicamente en maximizar el rendimiento esperado, sino también en considerar la variabilidad de dichos rendimientos y la relación entre los distintos activos que componen la cartera.

Desde esta perspectiva, una cartera de inversión puede entenderse como una combinación ponderada de activos financieros. Cada activo aporta una rentabilidad esperada y un nivel de riesgo, pero el riesgo total de la cartera no depende únicamente del riesgo individual de cada activo, sino también de la forma en que sus retornos se relacionan entre sí. Esta idea introduce el papel central de la diversificación: combinar activos imperfectamente correlacionados puede reducir el riesgo global de la cartera sin renunciar necesariamente a rentabilidad esperada.

La teoría moderna de carteras establece, por tanto, que el inversor debe buscar combinaciones eficientes de activos. Estas combinaciones son aquellas que, para un determinado nivel de riesgo, maximizan la rentabilidad esperada o, de forma equivalente, que para una rentabilidad esperada dada minimizan el riesgo asumido. El conjunto de estas carteras recibe el nombre de frontera eficiente.

3.2. Modelo de media-varianza de Markowitz

(Markowitz, 1952) introduce el modelo de media-varianza para la optimización de carteras. Este modelo supuso un cambio relevante frente a enfoques previos basados únicamente en la búsqueda del máximo retorno esperado, ya que incorpora explícitamente el riesgo asociado a los activos seleccionados y la correlación entre sus retornos.

En el modelo de Markowitz, cada activo financiero se representa como una variable aleatoria caracterizada por su retorno esperado y por la variabilidad de dicho retorno. La cartera se define mediante un vector de pesos, donde cada componente representa la proporción del capital invertida en cada activo. La rentabilidad esperada de la cartera se obtiene como una combinación lineal ponderada de los retornos esperados de los activos, mientras que el riesgo se mide a través de la varianza de la cartera.

Matemáticamente, el problema de optimización puede formularse como la maximización de una función objetivo que pondera la rentabilidad esperada frente al riesgo:

$$\max_w \left\{ w^\top \mu - \frac{\lambda}{2} w^\top \Sigma w \right\} \quad \text{s.a.} \quad \mathbf{1}^\top w = 1 \quad (3.1)$$

donde $\mu \in \mathbb{R}^n$ es el vector de retornos esperados de los activos, $w \in \mathbb{R}^n$ representa el vector de pesos de la cartera, $\Sigma \in \mathbb{R}^{n \times n}$ es la matriz de varianzas-covarianzas de los retornos y $\lambda > 0$ es el coeficiente de aversión al riesgo del inversor.

El primer término, $w^\top \mu$, representa la rentabilidad esperada de la cartera. Matemáticamente, se trata del producto escalar entre el vector de pesos y el vector de retornos esperados, lo que equivale a calcular la rentabilidad esperada total como suma ponderada de las rentabilidades individuales de los activos.

El segundo término, $\frac{\lambda}{2} w^\top \Sigma w$, introduce una penalización por riesgo. La expresión cuadrática $w^\top \Sigma w$ representa la varianza de la cartera, incorporando tanto la volatilidad individual de cada activo como las covarianzas entre activos. El parámetro λ controla el equilibrio entre rentabilidad y riesgo: cuanto mayor es su valor, mayor es la penalización asociada al riesgo y, por tanto, más conservadora será la cartera resultante.

La restricción $\mathbf{1}^\top w = 1$ garantiza que la suma de los pesos sea igual a uno, es decir, que se invierta la totalidad del capital disponible. En conjunto, este problema establece el compromiso fundamental de la teoría moderna de carteras: maximizar la rentabilidad esperada y, al mismo tiempo, controlar el riesgo asumido.

3.3. Riesgo financiero y hechos estilizados

El riesgo financiero puede entenderse como la incertidumbre asociada a la evolución futura del valor de los activos financieros. En el marco clásico de Markowitz, este riesgo se identifica principalmente con la varianza de los retornos. Sin embargo, los mercados financieros reales presentan propiedades estadísticas que no siempre pueden describirse adecuadamente mediante una distribución normal ni mediante relaciones lineales entre activos.

Entre estas propiedades destacan las colas pesadas, la asimetría, la volatilidad estocástica y los cambios en las correlaciones entre activos a lo largo del tiempo (Takahashi, Chen, y Tanaka-Ishii, 2019). Las colas pesadas indican que los eventos extremos ocurren con mayor frecuencia de la que predeciría una distribución normal. La asimetría refleja que las pérdidas y ganancias no necesariamente se distribuyen de forma simétrica. La volatilidad estocástica y el agrupamiento de volatilidad muestran que los periodos de alta volatilidad tienden a concentrarse en el tiempo.

Estas características son especialmente relevantes en la gestión de carteras, ya que afectan directamente a la estimación del riesgo. En periodos de estrés financiero, las correlaciones entre activos pueden aumentar de forma significativa, reduciendo los beneficios esperados de la diversificación. Por ello, una aproximación basada únicamente en medias, varianzas y covarianzas puede resultar insuficiente para capturar la complejidad de los mercados financieros.

3.4. Limitaciones de la varianza como medida de riesgo

Aunque el modelo de Markowitz fue pionero y sigue constituyendo una referencia fundamental en la optimización de carteras, presenta limitaciones importantes. Una de las principales es la identificación del riesgo con la varianza de los retornos. Esta elección implica asumir que las desviaciones positivas y negativas respecto a la media son tratadas de la misma forma, aunque desde el punto de vista del inversor las pérdidas suelen ser más relevantes que las ganancias inesperadas.

Además, el uso de la varianza como medida de riesgo resulta especialmente restrictivo cuando los retornos financieros no siguen una distribución normal. En presencia de colas pesadas, asimetrías o eventos extremos, la varianza puede infraestimar el riesgo real de la

cartera. Del mismo modo, la matriz de covarianzas solo captura relaciones lineales entre activos, por lo que puede no ser suficiente para representar dependencias no lineales o cambios estructurales en el mercado.

Otra limitación relevante es la sensibilidad del modelo a la estimación de sus parámetros. Pequeñas variaciones en los retornos esperados o en la matriz de covarianzas pueden generar diferencias significativas en los pesos óptimos de la cartera. Esto resulta especialmente problemático en mercados financieros, donde los parámetros estimados a partir de datos históricos pueden no mantenerse estables en el futuro.

Estas limitaciones motivan la búsqueda de enfoques alternativos capaces de capturar una descripción más rica de la distribución de retornos. En lugar de resumir el comportamiento de los activos únicamente mediante media y varianza, resulta necesario considerar herramientas que permitan aproximar la distribución completa y modelar relaciones no lineales entre activos.

3.5. Teoría de la información

La teoría de la información proporciona un marco matemático para estudiar la incertidumbre, la dependencia y la transmisión de información en sistemas aleatorios (Cover y Thomas, 2006). En el contexto de este trabajo, resulta especialmente relevante porque permite analizar distribuciones de probabilidad y cuantificar diferencias entre ellas.

Mientras que el enfoque clásico de media-varianza resume el comportamiento de los retornos mediante momentos de primer y segundo orden, la teoría de la información permite introducir medidas más generales de incertidumbre y discrepancia distribucional. Esto resulta útil cuando se trabaja con modelos generativos, ya que dichos modelos no buscan únicamente estimar una media o una matriz de covarianzas, sino aproximar la distribución subyacente de los datos.

Desde esta perspectiva, conceptos como la entropía, la divergencia de Kullback-Leibler y la información mutua permiten estudiar aspectos distintos del comportamiento de los activos financieros. La entropía mide el grado de incertidumbre de una variable aleatoria; la divergencia KL permite comparar dos distribuciones de probabilidad; y la información mutua permite cuantificar dependencias entre variables, incluyendo relaciones no lineales.

3.6. Entropía, divergencia KL e información mutua

Siguiendo a Cover y Thomas (Cover y Thomas, 2006), la entropía de Shannon mide la incertidumbre asociada a una variable aleatoria discreta. Si se entiende el retorno de un activo como una variable aleatoria X , su entropía puede definirse como:

$$H(X) = - \sum_{i=1}^n p(x_i) \log(p(x_i)) \quad (3.2)$$

donde $H(X)$ representa la entropía de la variable aleatoria X y $p(x_i)$ es la probabilidad asociada al valor x_i . En términos intuitivos, una entropía elevada indica que la distribución está más dispersa y, por tanto, que existe mayor incertidumbre sobre el resultado de la variable. Por el contrario, una entropía baja indica que la probabilidad está más concentrada en ciertos valores, lo que implica menor incertidumbre.

El término $\log p(x_i)$ refleja la información asociada a cada evento. Dado que las probabilidades toman valores entre cero y uno, su logaritmo es negativo; por ello, la expresión incorpora un signo negativo para que la entropía sea una cantidad no negativa. Los eventos menos probables aportan una mayor cantidad de información cuando ocurren, lo que permite interpretar la entropía como una medida agregada de incertidumbre.

Para medir la discrepancia entre dos distribuciones de probabilidad se emplea la divergencia de Kullback-Leibler, definida como:

$$D_{KL}(P \parallel Q) = \sum_{i=1}^n p(x_i) \log \left(\frac{p(x_i)}{q(x_i)} \right) \quad (3.3)$$

donde P y Q son dos distribuciones de probabilidad, $p(x_i)$ representa la probabilidad del valor x_i bajo la distribución P , y $q(x_i)$ representa la probabilidad del mismo valor bajo la distribución Q . La divergencia KL mide cuánta información se pierde cuando se utiliza la distribución Q para aproximar la distribución P .

En el contexto de este trabajo, esta medida resulta especialmente útil para comparar la distribución empírica de los retornos financieros con la distribución generada por un modelo generativo. Si la divergencia entre ambas distribuciones es reducida, puede interpretarse que los escenarios sintéticos generados reproducen de forma más fiel las propiedades estadísticas de los datos reales.

Otro concepto relevante es la información mutua, que permite medir la dependencia entre dos variables aleatorias. Se define como:

$$I(X;Y) = H(X) + H(Y) - H(X,Y) \quad (3.4)$$

donde $H(X)$ y $H(Y)$ representan las entropías marginales de las variables X e Y , y $H(X,Y)$ representa su entropía conjunta. La información mutua mide la reducción de incertidumbre sobre una variable al conocer la otra.

En el análisis financiero, la información mutua puede interpretarse como una medida de dependencia entre los retornos de distintos activos. A diferencia de la correlación, que mide únicamente relaciones lineales, la información mutua permite capturar dependencias más generales, incluyendo relaciones no lineales. Por este motivo, puede resultar útil para complementar el análisis tradicional basado en matrices de covarianzas.

3.7. Inteligencia artificial, aprendizaje automático y aprendizaje profundo

La inteligencia artificial engloba un conjunto amplio de técnicas orientadas a desarrollar sistemas capaces de realizar tareas que requieren algún tipo de aprendizaje, razonamiento o adaptación. Dentro de este campo, el aprendizaje automático se centra en métodos que permiten a los modelos aprender patrones a partir de datos, sin necesidad de programar explícitamente todas las reglas de decisión.

El aprendizaje profundo constituye una rama del aprendizaje automático basada en redes neuronales con múltiples capas. Su principal ventaja reside en la capacidad de aprender representaciones complejas y no lineales a partir de grandes volúmenes de datos. Esta característica resulta especialmente relevante en finanzas, donde los mercados presentan alta dimensionalidad, ruido, relaciones no lineales y cambios de régimen.

En este trabajo, el interés principal no se encuentra en utilizar modelos de aprendizaje profundo para predecir directamente el precio futuro de los activos, sino en emplearlos para modelar distribuciones de retornos y generar escenarios sintéticos. Esta diferencia es relevante: mientras que un modelo predictivo busca estimar un valor futuro concreto, un modelo generativo busca aprender la estructura estadística de los datos para producir nuevas muestras coherentes con la distribución observada.

3.8. Modelos generativos profundos

Los modelos generativos profundos son modelos de aprendizaje automático cuyo objetivo es aprender la distribución subyacente de los datos para generar nuevas observaciones con propiedades similares a las reales. En lugar de limitarse a predecir una etiqueta o un valor, estos modelos buscan capturar la estructura probabilística de los datos.

Este enfoque resulta especialmente útil en el análisis financiero, ya que permite trabajar con distribuciones complejas sin imponer de forma explícita supuestos paramétricos rígidos. En particular, los modelos generativos pueden ser útiles para representar colas pesadas, asimetrías, dependencias no lineales y escenarios de mercado que no aparecen de forma idéntica en el conjunto histórico, pero que son estadísticamente plausibles.

En el contexto de la optimización de carteras, los modelos generativos permiten desplazar el foco desde la estimación de parámetros concretos, como la media y la matriz de covarianzas, hacia la aproximación de la distribución completa de retornos. Una vez aprendida dicha distribución, es posible generar escenarios sintéticos sobre los que evaluar la robustez de distintas asignaciones de cartera.

3.9. Autoencoders Variacionales

Los Autoencoders Variacionales, introducidos por Kingma y Welling (Kingma y Welling, 2013), representan una extensión probabilística de los autoencoders tradicionales. Mientras que un autoencoder convencional aprende una representación determinista de los datos en un espacio latente, un VAE aprende una distribución de probabilidad sobre dicho espacio latente, habitualmente parametrizada mediante una distribución normal multivariante.

La arquitectura de un VAE se compone de dos elementos principales: un codificador o encoder y un decodificador o decoder. El codificador transforma la entrada en los parámetros de una distribución latente, normalmente una media μ y una desviación típica σ . A partir de estos parámetros se obtiene una muestra latente z , que posteriormente es utilizada por el decodificador para reconstruir la entrada original.

Para permitir el entrenamiento mediante retropropagación, se emplea el truco de reparametrización. En lugar de muestrear directamente desde la distribución latente, el vector z se expresa como una transformación determinista de una variable aleatoria auxiliar:

$$z = \mu + \sigma \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I) \quad (3.5)$$

Desde una perspectiva financiera, esta estructura puede interpretarse como una forma de obtener una representación latente de los retornos, reduciendo la dimensionalidad del problema y tratando de capturar factores no observables que influyen en el comportamiento conjunto de los activos.

La función objetivo del VAE se conoce como ELBO, Evidence Lower Bound, y combina dos términos principales: un término de reconstrucción y un término de regularización basado en la divergencia de Kullback-Leibler. Puede expresarse como:

$$\mathcal{L}(\theta, \phi; x) = \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x | z)] - D_{KL}(q_\phi(z | x) \parallel p(z)) \quad (3.6)$$

El primer término mide la capacidad del modelo para reconstruir los datos observados a partir de las variables latentes. En el contexto de este trabajo, representa la capacidad del decodificador para reproducir la estructura esencial de los retornos financieros. El segundo término actúa como regularizador, forzando a que la distribución latente aprendida se mantenga próxima a una distribución prior, generalmente una normal estándar. Esto favorece un espacio latente continuo y estructurado, facilitando la generación de nuevos escenarios coherentes.

En conjunto, el VAE permite aprender una representación comprimida y probabilística de los datos financieros. Esta representación puede ser útil para filtrar parte del ruido presente en las series de retornos y conservar patrones latentes relevantes para la posterior generación de escenarios.

3.10. Redes Generativas Adversarias y Wasserstein GAN

Las Redes Generativas Adversarias, introducidas por (Goodfellow y cols., 2014), introducen un marco de aprendizaje generativo basado en la interacción entre dos redes neuronales: un generador y un discriminador. El generador transforma un vector de ruido en una muestra sintética, mientras que el discriminador intenta distinguir entre muestras reales y muestras generadas.

El entrenamiento se formula como un juego adversarial. El generador trata de producir muestras cada vez más realistas, mientras que el discriminador mejora su capacidad para

identificar si una observación procede de los datos reales o del modelo generativo. Esta interacción se expresa mediante una función objetivo minimax:

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log (1 - D(G(z)))] \quad (3.7)$$

En el contexto financiero, el generador puede interpretarse como un modelo capaz de producir escenarios sintéticos de retornos, mientras que el discriminador evalúa si dichos escenarios son estadísticamente distinguibles de los retornos históricos. La principal ventaja de este enfoque es que no requiere especificar explícitamente una distribución paramétrica para los datos, sino que aprende directamente a partir de las observaciones.

Las GANs resultan atractivas para la optimización de carteras porque pueden capturar características de la distribución que no quedan recogidas por la media y la covarianza, como asimetrías, curtosis o dependencias no lineales. Sin embargo, su entrenamiento puede ser inestable y presentar problemas como el *mode collapse*, situación en la que el generador produce una variedad limitada de muestras.

Como respuesta a estas limitaciones, las Wasserstein GAN introducen una formulación alternativa basada en la distancia de Wasserstein entre distribuciones (Arjovsky, Chintala, y Bottou, 2017). Esta aproximación mejora la estabilidad del entrenamiento y proporciona una señal de optimización más informativa cuando la distribución generada todavía se encuentra lejos de la distribución real. Por este motivo, las WGAN constituyen una extensión relevante dentro del modelado generativo aplicado a datos financieros.

3.11. Modelos de difusión

Los modelos de difusión constituyen una familia reciente de modelos generativos basados en la idea de añadir ruido de forma progresiva a los datos hasta transformar la distribución original en una distribución simple, habitualmente ruido gaussiano. Posteriormente, el modelo aprende el proceso inverso, es decir, cómo eliminar gradualmente el ruido para reconstruir muestras coherentes con la distribución original.

En términos generales, el proceso se divide en dos fases. En la fase directa, los datos se degradan progresivamente mediante la adición de ruido. En la fase inversa, una red neuronal aprende a revertir ese proceso, generando nuevas observaciones a partir de ruido inicial. Esta formulación permite obtener muestras diversas y estables, lo que ha hecho que

los modelos de difusión se hayan convertido en una línea destacada dentro del modelado generativo.

Aplicados al ámbito financiero, estos modelos pueden utilizarse para generar trayectorias sintéticas de retornos o precios que preserven ciertas propiedades estadísticas de los datos reales. Aunque en este trabajo la arquitectura principal se centra en modelos VAE-GAN, los modelos de difusión se incluyen en el marco teórico por su relevancia reciente en la generación de escenarios y en problemas dinámicos de selección de carteras.

4. Estado del Arte

En este capítulo se revisan los principales trabajos y líneas de investigación relacionados con la optimización de carteras y el uso de modelos de aprendizaje automático y modelado generativo en finanzas. A diferencia del marco teórico, cuyo objetivo es presentar los conceptos fundamentales, el estado del arte se centra en identificar qué enfoques han sido propuestos previamente, qué limitaciones presentan y en qué punto se sitúa la contribución planteada en este trabajo.

4.1. Optimización clásica de carteras

La optimización clásica de carteras tiene como punto de partida el trabajo de Markowitz, quien introduce el modelo de media-varianza como una formulación matemática para la selección de carteras de inversión (Markowitz, 1952). La aportación fundamental de este enfoque consiste en establecer que la elección de activos no debe basarse únicamente en la maximización del retorno esperado, sino también en el control del riesgo asociado a la cartera.

El modelo de Markowitz permite obtener combinaciones eficientes de activos a partir de la relación entre rentabilidad esperada y varianza. En este marco, una cartera será preferible si, para un determinado nivel de riesgo, ofrece una mayor rentabilidad esperada, o si, para una rentabilidad esperada dada, presenta una menor varianza. Esta idea da lugar al concepto de frontera eficiente, que constituye uno de los fundamentos de la teoría moderna de carteras.

No obstante, aunque el modelo de media-varianza continúa siendo una referencia esencial en la literatura financiera, presenta limitaciones relevantes. En particular, resume el comportamiento de los activos mediante momentos de primer y segundo orden, es decir, medias, varianzas y covarianzas. Esta simplificación puede resultar insuficiente cuando los retornos financieros presentan colas pesadas, asimetrías, volatilidad cambiante o dependencias no lineales.

Estas limitaciones han motivado el desarrollo de enfoques alternativos, tanto desde la estadística financiera tradicional como desde el aprendizaje automático. En este trabajo, el modelo de Markowitz se considera como referencia clásica frente a la cual comparar la metodología basada en escenarios sintéticos generados mediante modelos profundos.

4.2. Aprendizaje automático y deep learning en gestión de carteras

El aprendizaje automático ha introducido nuevas aproximaciones para el análisis de datos financieros, especialmente en contextos donde las relaciones entre variables son complejas, no lineales y difíciles de modelar mediante técnicas paramétricas tradicionales. En el ámbito de la gestión de carteras, estas técnicas se han aplicado principalmente a la predicción de precios, la estimación de retornos, la clasificación de activos y la construcción de señales de inversión.

Sin embargo, una parte importante de estos enfoques se centra en predecir directamente la evolución futura de los precios o retornos. Esta estrategia presenta dificultades importantes, ya que los mercados financieros son sistemas altamente ruidosos y sensibles a cambios de régimen. Además, una predicción puntual de precios no equivale directamente a una decisión de inversión, sino que requiere una capa adicional de lógica para convertir dicha predicción en pesos de cartera.

En este contexto, el aprendizaje profundo aporta la capacidad de modelar relaciones no lineales y trabajar con datos de alta dimensionalidad. Las redes neuronales profundas permiten aprender representaciones complejas de los datos, lo que resulta especialmente relevante en finanzas, donde los activos pueden presentar relaciones dinámicas, dependencias no lineales y comportamientos distintos en función del régimen de mercado.

A pesar de ello, el enfoque de este trabajo no consiste en utilizar aprendizaje profundo para predecir directamente precios futuros, sino en emplearlo para modelar distribuciones de retornos y generar escenarios sintéticos. Esta distinción es relevante, ya que desplaza el problema desde la predicción puntual hacia la generación de posibles trayectorias o escenarios de mercado sobre los que evaluar la robustez de una cartera.

4.3. Modelos generativos para series financieras

Los modelos generativos han ganado relevancia en el análisis de series financieras debido a su capacidad para aprender distribuciones complejas directamente a partir de los datos. A diferencia de los modelos clásicos, que requieren especificar de forma explícita una distribución o una estructura paramétrica, los modelos generativos permiten aproximar la distribución subyacente y producir nuevas muestras con propiedades similares a las

observadas.

En el caso de las series financieras, esta capacidad resulta especialmente útil porque los retornos de los activos presentan propiedades que no siempre quedan recogidas por modelos gaussianos o lineales. Entre estas propiedades se encuentran las colas pesadas, la asimetría, la dependencia temporal, el agrupamiento de volatilidad y los cambios en las correlaciones entre activos. Por este motivo, el modelado generativo constituye una línea de investigación relevante para la generación de escenarios financieros sintéticos.

Dentro de esta familia de modelos, las Redes Generativas Adversarias, propuestas originalmente por (Goodfellow y cols., 2014), han sido utilizadas para sintetizar series temporales financieras y reproducir propiedades estadísticas observadas en los mercados. En este enfoque, el generador aprende a producir muestras sintéticas, mientras que el discriminador evalúa si dichas muestras proceden de la distribución real o de la distribución generada. Este procedimiento permite construir escenarios que no aparecen de forma idéntica en el conjunto histórico, pero que pueden resultar estadísticamente plausibles.

Los Autoencoders Variacionales también resultan relevantes en este contexto, ya que permiten aprender una representación latente y probabilística de los datos. En el caso de los retornos financieros, el espacio latente puede interpretarse como una representación comprimida de factores no observables que influyen en el comportamiento conjunto de los activos. Esta característica justifica su uso como componente previo o complementario en arquitecturas híbridas de generación de escenarios.

A partir de estas ideas, el presente trabajo plantea una arquitectura híbrida VAE-GAN. El VAE se orienta a obtener una representación latente de los retornos financieros, mientras que la GAN se emplea para generar escenarios sintéticos a partir de dicha representación. Esta combinación busca aprovechar la capacidad del VAE para estructurar el espacio latente y la capacidad de la GAN para producir muestras realistas.

4.4. Modelos de difusión para selección dinámica de carteras

En los últimos años, los modelos de difusión han adquirido una relevancia creciente dentro del modelado generativo. Estos modelos se basan en aprender un proceso inverso de eliminación de ruido, permitiendo generar nuevas observaciones a partir de una distribución inicial simple, normalmente ruido gaussiano. Su principal atractivo reside en la estabilidad del proceso generativo y en su capacidad para producir muestras diversas.

En el ámbito financiero, los modelos de difusión han comenzado a explorarse como herramientas para la generación de escenarios y la selección dinámica de carteras. En particular, Aghapour, Bayraktar y Yuan proponen el uso de modelos de difusión para abordar problemas de selección dinámica de carteras (Aghapour, Bayraktar, y Yuan, 2025). Este enfoque resulta relevante para el presente trabajo porque comparte la idea de utilizar modelos generativos para simular posibles escenarios de mercado y tomar decisiones de asignación de activos.

Según los resultados reportados por estos autores, los modelos de difusión pueden ofrecer resultados competitivos frente a índices de referencia como el S&P 500 y frente a carteras construidas mediante enfoques tradicionales de Markowitz. Esta línea de investigación es todavía reciente, pero muestra el potencial del modelado generativo para superar algunas de las limitaciones de los modelos clásicos, especialmente cuando se trabaja con mercados dinámicos, dependencia temporal y cambios en la volatilidad.

Aunque el presente trabajo no se centra directamente en modelos de difusión, su inclusión en el estado del arte permite situar la propuesta VAE-GAN dentro de una tendencia más amplia: el uso de modelos generativos profundos para construir escenarios sintéticos y mejorar los procesos de optimización de carteras.

4.5. Síntesis crítica y hueco de investigación

La revisión anterior permite identificar una evolución clara en las técnicas aplicadas a la optimización de carteras. En primer lugar, la teoría clásica de Markowitz establece una formulación matemática sólida basada en el equilibrio entre rentabilidad esperada y riesgo. Sin embargo, su dependencia de la media, la varianza y la matriz de covarianzas limita su capacidad para capturar distribuciones no gaussianas, colas pesadas y relaciones no lineales entre activos.

En segundo lugar, las técnicas de aprendizaje automático y aprendizaje profundo han ampliado las posibilidades de análisis financiero, permitiendo modelar relaciones más complejas a partir de datos históricos. No obstante, muchos de estos enfoques se han centrado en la predicción puntual de precios o retornos, lo que no resuelve directamente el problema de la construcción de carteras robustas bajo incertidumbre.

En tercer lugar, los modelos generativos ofrecen una alternativa especialmente adecuada para este contexto, ya que permiten aprender distribuciones de datos y generar

escenarios sintéticos. Esta capacidad resulta útil para analizar la robustez de una cartera no solo bajo el escenario histórico observado, sino también bajo posibles escenarios generados que preserven propiedades estadísticas relevantes del mercado.

El hueco de investigación que aborda este trabajo se sitúa precisamente en la conexión entre generación de escenarios sintéticos y optimización de carteras. La propuesta consiste en estudiar una arquitectura híbrida VAE-GAN aplicada a retornos financieros del S&P 500, con el objetivo de generar escenarios de mercado y comparar la cartera resultante con enfoques clásicos como Markowitz y carteras equiponderadas.

5. Metodología

5.1. Diseño general del experimento

En este capítulo se presenta la metodología de trabajo seguida para la realización del presente trabajo de investigación. Se detalla el diseño experimental y la lógica de construcción de la arquitectura híbrida VAE-GAN. Asimismo, se describe el proceso de adquisición y preprocesamiento de datos, la formalización matemática de las funciones de pérdida y el protocolo de validación para la selección de carteras.

La metodología propuesta se estructura en varias etapas. En primer lugar, se adquieren datos históricos de activos pertenecientes al S&P 500 mediante la herramienta *yfinance*. En segundo lugar, se realiza el preprocesamiento de los datos para obtener una representación adecuada de los retornos financieros. Posteriormente, se emplea una arquitectura híbrida VAE-GAN para extraer una representación latente de los datos y generar escenarios sintéticos de mercado. Finalmente, se plantea la optimización de la cartera y la comparación con distintos modelos de referencia.

5.2. Adquisición de datos

Una parte fundamental del experimento propuesto es la adquisición de datos reales que permitan llevar a cabo un estudio relevante.

Empleando la herramienta *yfinance*, se creará un pipeline de datos para adquirir series históricas de los últimos 10 años de los principales activos del S&P 500.

Se emplearán estos datos por su relevancia. El mercado estadounidense es uno de los más importantes en cuanto a capitalización de mercado. Este índice agrupa a 500 de las mayores empresas de Estados Unidos y constituye una referencia ampliamente utilizada en el análisis financiero. Por su diversificación y representatividad, se considera un escenario adecuado para estudiar metodologías de optimización de carteras.

Asimismo, se procurará establecer la trazabilidad de los datos, con el fin de asegurar que proceden de fuentes confiables y que el proceso de adquisición pueda ser reproducible.

5.3. Preprocesamiento de los datos

Tras la adquisición de los datos, se llevarán a cabo las transformaciones necesarias para poder desarrollar los objetivos del trabajo. Este preprocesamiento permitirá adaptar las series históricas al formato requerido por los modelos generativos y por el proceso posterior de optimización.

En primer lugar, se trabajará con precios ajustados, de forma que se tengan en cuenta eventos corporativos como dividendos o desdoblamientos de acciones. A partir de estas series se calcularán los retornos financieros, que constituirán la entrada principal del modelo.

Para el preprocesado, se aplicará una normalización Min-Max tras un tratamiento de valores atípicos (*outliers*). Este escalado al rango $[0, 1]$ resulta relevante para asegurar la estabilidad numérica de las funciones de activación de las redes neuronales y reducir el riesgo de inestabilidad durante el entrenamiento del VAE y la GAN.

Asimismo, se realizará una revisión de valores ausentes o inconsistentes, así como las transformaciones adicionales que sean necesarias para garantizar que los datos puedan ser utilizados de forma adecuada dentro del pipeline experimental.

5.4. Arquitectura VAE-GAN propuesta

Una vez extraídos y preprocesados los datos, se elaborará una estructura en línea con lo expuesto en los apartados previos.

La arquitectura propuesta para el modelo se articula en tres módulos principales:

- Extracción de características con Autoencoders Variacionales (VAEs) para la reducción de la dimensionalidad de forma no lineal. El VAE proyecta los datos históricos hacia un espacio latente de menor dimensión. Este proceso permite reducir parte del ruido, reteniendo las características persistentes de los datos.

““

- Generación de escenarios mediante Redes Generativas Adversarias (GANs). La GAN entrena sobre el espacio latente y sintetiza vectores de retornos orientados a preservar dependencias no lineales y momentos estadísticos de orden superior.
- Optimización de la cartera mediante el uso de medidas informacionales, como la

Divergencia de Kullback-Leibler, como criterio complementario al análisis clásico del riesgo. De este modo, se plantea evaluar la robustez de la cartera frente a escenarios generados por el modelo. ““

De manera intuitiva, el modelo emplea el VAE para obtener una representación latente de los datos, incorporando información sobre relaciones no lineales entre los activos. A partir de dicho espacio latente, la GAN sintetiza escenarios de mercado que permiten analizar la robustez de distintas asignaciones de cartera.

El mercado financiero presenta una gran cantidad de variables interconectadas de formas que van más allá de la linealidad. Por ello, el VAE se utiliza para aproximar un espacio latente en el que se representen relaciones subyacentes entre los activos. Este planteamiento resulta adecuado frente a métodos estrictamente lineales como el PCA, dado que los mercados financieros no presentan necesariamente una estructura lineal.

El espacio latente Z representa, por tanto, una codificación comprimida de la información relevante contenida en los datos de entrada.




Figura 5.1: Arquitectura híbrida VAE-GAN para la generación y optimización de carteras.

El VAE toma datos históricos de retornos reales para obtener variables latentes asociadas a los mismos, modelando relaciones subyacentes entre distintos activos. El Generador recibe este espacio latente y, trabajando junto con el Discriminador, introduce variaciones mediante ruido aleatorio. Con este modelo, se busca crear escenarios sintéticos suficientemente similares a los retornos históricos para que resulten útiles en el proceso de optimización. Esto permite realizar la optimización final sobre un conjunto ampliado de escenarios probables, generando un conjunto de pesos para la cartera.

5.5. Generación de escenarios sintéticos

Una vez estructurado el espacio latente, se procede a la generación de escenarios sintéticos. Para ello, se emplea la arquitectura adversarial de las Redes Generativas Adversarias. En este enfoque, se introduce un marco de entrenamiento adversario en el que dos redes neuronales compiten entre sí: el Generador (G) y el Discriminador (D).

El Generador se encarga de generar escenarios sintéticos que sean indistinguibles de los datos reales, mientras que el Discriminador se encarga de distinguir entre los datos reales y los sintéticos. El Generador se entrena para maximizar la probabilidad de error del Discriminador, mientras que este último se entrena para maximizar la probabilidad de distinguir entre los datos reales y los sintéticos.

El Generador entrena para buscar escenarios que sean indistinguibles de la realidad, utilizando la estructura latente previamente establecida, así como ruido aleatorio introducido en la entrada.

Por lo tanto, se plantea un juego minimax de suma cero donde el objetivo es alcanzar un equilibrio de Nash. En este escenario, el Generador (G) busca maximizar la probabilidad de error del Discriminador (D), mientras que este último se optimiza para distinguir con precisión entre la distribución de datos reales p_{data} y la distribución sintética p_g .

5.6. Función de pérdida y criterios de optimización

Siguiendo el enfoque propuesto por (Kingma y Welling, 2013), el objetivo del modelo VAE es maximizar la verosimilitud marginal de los datos observados. Dado un conjunto de datos $x^{(i)}_{i=1}^N$, la verosimilitud marginal se descompone como la suma sobre las observaciones individuales:

$$\log p_{\theta}(x^{(1)}, \dots, x^{(N)}) = \sum_{i=1}^N \log p_{\theta}(x^{(i)}) \quad (5.1)$$

Sin embargo, el cálculo directo de $\log p_{\theta}(x^{(i)})$ resulta intratable debido a la integración sobre las variables latentes. Para abordar este problema, se introduce una distribución aproximada $q_{\phi}(z|x)$, lo que permite descomponer la log-verosimilitud como:

$$\log p_{\theta}(x^{(i)}) = D_{KL} \left(q_{\phi}(z|x^{(i)}), p_{\theta}(z|x^{(i)}) \right) + \mathcal{L}(\theta, \phi; x^{(i)}) \quad (5.2)$$

Dado que la divergencia de Kullback-Leibler es siempre no negativa, el término $\mathcal{L}(\theta, \phi; x^{(i)})$ constituye una cota inferior variacional (Evidence Lower Bound, ELBO):

$$\log p_\theta(x^{(i)}) \geq \mathcal{L}(\theta, \phi; x^{(i)}) \quad (5.3)$$

Esta cota puede expresarse como:

$$\mathcal{L}(\theta, \phi; x^{(i)}) = \mathbb{E} * q * \phi(z|x^{(i)}) \left[\log p_\theta(x^{(i)}, z) - \log q_\phi(z|x^{(i)}) \right] \quad (5.4)$$

o, de forma equivalente, separando sus componentes principales:

$$\mathcal{L}(\theta, \phi; x^{(i)}) = -D_{KL} \left(q_\phi(z|x^{(i)}), p(z) \right) + \mathbb{E} * q * \phi(z|x^{(i)}) \left[\log p_\theta(x^{(i)}|z) \right] \quad (5.5)$$

Esta formulación revela dos términos fundamentales:

- Un término de regularización, que fuerza la distribución latente aproximada $q_\phi(z|x)$ a mantenerse cercana a la probabilidad a priori $p(z)$.
- Un término de reconstrucción, que mide la capacidad del modelo generativo para reproducir los datos observados a partir de las variables latentes.

El proceso de entrenamiento consiste en maximizar esta cota inferior respecto a los parámetros del modelo generativo θ y los parámetros variacionales ϕ .

No obstante, la optimización presenta dificultades prácticas. En particular, el cálculo del gradiente respecto a ϕ mediante estimadores Monte Carlo directos presenta alta varianza, lo que dificulta la convergencia y hace inviable su uso en la práctica. Para superar esta limitación, se introduce el truco de reparametrización, que permite expresar la variable latente como una transformación determinista de una variable aleatoria auxiliar:

$$z = \mu_\phi(x) + \sigma_\phi(x) \cdot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I) \quad (5.6)$$

Esta reformulación permite trasladar la fuente de aleatoriedad fuera de la red neuronal, haciendo posible aplicar técnicas estándar de optimización basadas en gradiente (*backpropagation*) con estimadores de baja varianza.

En conjunto, este marco convierte el problema de inferencia variacional en uno de optimización eficiente, permitiendo el entrenamiento conjunto del encoder y el decoder dentro de una arquitectura diferenciable end-to-end.

5.7. Optimización y selección de pesos

Tras la generación de escenarios sintéticos, se procede a la fase de optimización y selección de pesos de la cartera. El objetivo de esta etapa es obtener un vector de pesos w que permita construir una cartera robusta bajo los escenarios generados por el modelo.

La optimización final se realiza sobre escenarios sintéticos generados a partir de la estructura latente aprendida. De este modo, la selección de pesos no depende únicamente de la muestra histórica observada, sino también de escenarios alternativos que preservan ciertas propiedades estadísticas de los retornos reales.

En esta fase se plantea incorporar medidas informacionales, como la Divergencia de Kullback-Leibler, como criterio complementario para evaluar la distancia entre la distribución empírica y la distribución generada. Esta idea permite conectar el proceso de optimización con el marco de teoría de la información desarrollado en capítulos anteriores.

5.8. Benchmarks de comparación

La validación final de la cartera se realizará mediante la comparación con diferentes modelos de elaboración de carteras. En particular, se plantea comparar la metodología propuesta con enfoques clásicos de referencia.

El primer benchmark será el modelo de media-varianza de Markowitz, por constituir la referencia clásica en optimización de carteras. El segundo benchmark será una cartera equiponderada, en la que todos los activos seleccionados reciben el mismo peso. Adicionalmente, se podrá utilizar el índice S&P 500 como referencia de mercado.

La comparación se realizará atendiendo a métricas financieras y estadísticas que permitan evaluar el comportamiento relativo de cada aproximación. Entre ellas se considerarán el retorno obtenido, la volatilidad, la estabilidad de los pesos y la robustez de la cartera frente a distintos escenarios de mercado.

6. Herramientas y tecnologías

A continuación, se describen las principales herramientas y tecnologías empleadas en el desarrollo del presente trabajo de investigación. Se detallan los lenguajes de programación, las librerías y *frameworks* utilizados, así como los recursos computacionales necesarios.

En primer lugar, se destaca el uso de LaTeX para la redacción del presente documento, dado que permite estructurar adecuadamente la memoria, gestionar referencias bibliográficas y representar expresiones matemáticas de forma precisa.

Para la adquisición de datos se ha empleado la herramienta *yfinance*, que permite acceder a series históricas de precios de activos financieros y construir el conjunto de datos necesario para el desarrollo experimental del trabajo.

Python es el lenguaje de programación elegido para el análisis de los datos y la implementación de la metodología propuesta. La manipulación y transformación de los datos se realizará mediante las librerías *pandas* y *NumPy*. Para el desarrollo de los modelos se emplearán librerías de aprendizaje profundo como *PyTorch* y/o *TensorFlow*. Asimismo, para la visualización de resultados se utilizará *matplotlib*.

Para el control de versiones se ha empleado Git, utilizando la plataforma GitHub para el almacenamiento remoto del código, la documentación asociada y el seguimiento de los cambios realizados durante el desarrollo del trabajo.

7. Marco normativo, ética y protección de datos

Se analiza el entorno legal y ético aplicable, con especial énfasis en el Reglamento General de Protección de Datos (RGPD) para el uso de datos masivos y las directrices éticas sobre el uso de la Inteligencia Artificial en el sector financiero.

7.1. Identificación del Tratamiento de Datos

En el desarrollo del presente Trabajo de Fin de Máster, el tratamiento de datos se limita estrictamente a series temporales de precios de activos financieros públicos procedentes del índice S&P 500. Se hace constar que no se han utilizado, procesado ni almacenado datos de carácter personal de terceros identificados o identificables, cumpliendo con el principio de minimización de datos.

7.2. Cumplimiento del RGPD y la Ley Orgánica 3/2018 (LOPDGDD)

A pesar de la naturaleza pública de los datos financieros, el proyecto se alinea con el Reglamento General de Protección de Datos (RGPD) y la Ley Orgánica 3/2018 en los siguientes términos:

- **Finalidad:** Los datos son tratados con el fin exclusivo de investigación académica y desarrollo de modelos de aprendizaje profundo.
- **Seguridad:** El procesamiento de los datos se realiza en un entorno local, garantizando la integridad de los mismos y evitando cualquier fuga de información que pudiera afectar a la infraestructura del sistema.
- **Análisis de Riesgo:** Dado que no existe tratamiento de datos de personas físicas, el riesgo para los derechos y libertades de las personas es nulo.

7.3. Consideraciones Éticas y Propiedad Intelectual

El acceso a los datos se ha realizado mediante la API de Yahoo Finance, respetando los términos y condiciones de uso para fines educativos y de investigación. El código fuente desarrollado y los escenarios sintéticos generados por la arquitectura VAE-GAN son de autoría propia, garantizando la transparencia en el proceso de generación de información. Sin embargo, como suele ocurrir con este tipo de modelos, la elección de los activos puede carecer de explicabilidad aparente.

Se hace constar que la elección de unos activos determinados frente a otros puede no ser explicable mediante lógicas económicas o financieras fundamentales, basadas en las métricas principales en este caso de las empresas seleccionadas. Se recomienda la comprensión profunda de la naturaleza del mercado.

Incluso con la capacidad de construir un modelo sólido, no se puede aseverar que la cartera vaya realmente a cumplir con las expectativas de rentabilidad calculadas.

8. Planificación del trabajo

9. Conclusiones preliminares

Referencias

- Aghapour, A., Bayraktar, E., y Yuan, F. (2025). Solving dynamic portfolio selection problems via score-based diffusion models. *arXiv preprint arXiv:2507.09916*. (Valida el uso de modelos de difusión para batir al S&P 500 y al modelo de Markowitz.)
- Arjovsky, M., Chintala, S., y Bottou, L. (2017). Wasserstein gan. *arXiv preprint arXiv:1701.07875*.
- Cover, T. M., y Thomas, J. A. (2006). *Elements of information theory* (2nd ed.). John Wiley & Sons.
- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... Bengio, Y. (2014). Generative adversarial nets. En *Advances in neural information processing systems* (Vol. 27).
- Kingma, D. P., y Welling, M. (2013). Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*.
- Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91.
- Salimans, T., Goodfellow, I., Zaremba, W., Cheung, V., Radford, A., Chen, X., y Chen, X. (2016). Improved techniques for training gans. En D. Lee, M. Sugiyama, U. Luxburg, I. Guyon, y R. Garnett (Eds.), *Advances in neural information processing systems* (Vol. 29). Curran Associates, Inc. Descargado de https://proceedings.neurips.cc/paper_files/paper/2016/file/8a3363abe792db2d8761d6403605aeb7-Paper.pdf
- Takahashi, S., Chen, Y., y Tanaka-Ishii, K. (2019). Modeling financial time series with generative adversarial networks. *Physica A: Statistical Mechanics and its Applications*, 527, 121261.