



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Análisis y Visualización de Datos Masivos

Optimización de Carteras mediante Modelado Generativo y Teoría de la Información

Trabajo Fin de Estudios

presentado por: Daniel Machín González

Dirigido por: Jesús Cigales Canga

Ciudad: San Bartolomé

Fecha: April 7, 2026

Índice general

Resumen	IV
Abstract	v
1. Introducción	1
1.1. Motivación	1
1.2. Planteamiento del trabajo	1
1.3. Estructura del trabajo	2
2. Estado del Arte	3
3. Metodología	4
3.1. Arquitectura del Modelo Generativo Híbrido	4
3.1.1. Implementación del VAE para la Extracción de Características La- tentes	4
3.1.2. Síntesis de Escenarios mediante GANs	4
3.1.3. Optimización de Cartera y Medida de Riesgo	5
4. Marco Normativo	6
Referencias	7

Índice de figuras

Índice de cuadros

Resumen

Tu resumen en español...

Abstract

Your abstract in English...

1. Introducción

1.1. Motivación

La gestión de carteras de inversión ha estado dominada durante décadas por la Teoría de Cartera Moderna (MPT), introducida por (Markowitz, 1952). Este marco teórico se fundamenta en la optimización media-varianza, bajo el supuesto de que los retornos de los activos financieros siguen una distribución normal. Sin embargo, la evidencia empírica en el análisis de datos masivos financieros demuestra que los mercados reales presentan características que este modelo no logra capturar: la curtosis excesiva (colas pesadas), la asimetría y la volatilidad estocástica.

En el contexto actual de Big Data, la incapacidad de los modelos lineales para gestionar la complejidad representa un riesgo sistémico. Los eventos de .extremo. ocurren con una frecuencia mayor en la realidad, lo que hace que la varianza sea una métrica de riesgo insuficiente. El uso de modelos generativos como las GANs (?, ?) y los VAEs (Kingma y Welling, 2013) ofrece un nuevo paradigma para aprender la distribución subyacente de los datos sin supuestos previos.

1.2. Planteamiento del trabajo

El presente Trabajo de Fin de Máster propone una metodología híbrida que integra el modelado generativo y la teoría de la información. El núcleo de la investigación se divide en tres fases:

1. Uso de **Autoencoders Variacionales (VAEs)** para la reducción de dimensionalidad no lineal.
2. Desarrollo de una **Red Generativa Adversaria (GAN)** para sintetizar escenarios de mercado realistas.
3. Optimización de la cartera mediante la **Divergencia de Kullback-Leibler** como métrica de riesgo informativo.

1.3. Estructura del trabajo

La memoria se organiza de la siguiente manera: el Capítulo 2 revisa el estado del arte; el Capítulo 3 detalla la metodología y objetivos; el Capítulo 4 expone el marco normativo y los capítulos posteriores desarrollan la contribución técnica y resultados.

2. Estado del Arte

3. Metodología

3.1. Arquitectura del Modelo Generativo Híbrido

La propuesta central de este trabajo se basa en una arquitectura secuencial que combina la capacidad de compresión de los Autoencoders Variacionales (VAE) con la potencia de síntesis de las Redes Generativas Adversarias (GAN).

3.1.1. Implementación del VAE para la Extracción de Características Latentes

Siguiendo la formulación original de (Kingma y Welling, 2013), el primer bloque del modelo consiste en un codificador probabilístico $q_\phi(z|x)$ y un decodificador $p_\theta(x|z)$. En el contexto de retornos financieros masivos, el VAE cumple la función de filtrar el ruido inherente del mercado.

El objetivo es maximizar la cota inferior de la evidencia (ELBO), definida como:

$$\mathcal{L}(\theta, \phi; x) = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] - D_{KL}(q_\phi(z|x) \parallel p(z)) \quad (3.1)$$

Este segundo término, la **Divergencia de Kullback-Leibler**, es donde conectamos con la teoría de la información de (Cover y Thomas, 2006). Actúa como un regularizador que obliga al espacio latente a seguir una distribución normal unitaria, facilitando el muestreo posterior.

3.1.2. Síntesis de Escenarios mediante GANs

Una vez obtenido el espacio latente simplificado, se entrena una GAN siguiendo las técnicas de mejora propuestas por (?, ?). El uso de GANs en series temporales financieras permite capturar los “estilizados” del mercado, como el *volatility clustering* y las colas pesadas, aspectos que el modelo de (Markowitz, 1952) no considera.

Para evitar la inestabilidad en el entrenamiento (como el *mode collapse*), evaluaremos el uso de la **Wasserstein GAN (WGAN)** propuesta por (Arjovsky, Chintala, y Bottou, 2017). La ventaja fundamental es que la WGAN utiliza la distancia de *Earth Mover* en lugar de la divergencia JS tradicional, lo que proporciona gradientes más suaves y una métrica de convergencia real que se correlaciona con la calidad de las muestras generadas.

3.1.3. Optimización de Cartera y Medida de Riesgo

El paso final integra los escenarios generados en un proceso de optimización. Utilizaremos la divergencia de Kullback-Leibler para medir cuánto se desvía nuestra cartera propuesta de la distribución de “escenarios de estrés” sintetizados por la GAN. Este enfoque permite una gestión del riesgo basada en la entropía, ofreciendo una visión más holística que la simple varianza.

4. Marco Normativo

Referencias

- Arjovsky, M., Chintala, S., y Bottou, L. (2017). Wasserstein gan. *arXiv preprint arXiv:1701.07875*.
- Cover, T. M., y Thomas, J. A. (2006). *Elements of information theory* (2nd ed.). John Wiley & Sons.
- Kingma, D. P., y Welling, M. (2013). Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*.
- Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91.