



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Análisis y Visualización de Datos Masivos

Optimización de Carteras mediante Modelado Generativo y Teoría de la Información

Trabajo Fin de Estudios

presentado por: Daniel Machín González

Dirigido por: Jesús Cigales Canga

Ciudad: San Bartolomé

Fecha: April 19, 2026

Índice general

Resumen	v
Abstract	vi
1. Introducción	1
1.1. Motivación	1
1.2. Objetivos	2
1.3. Planteamiento del trabajo	2
1.4. Estructura del trabajo	3
2. Estado del Arte	4
2.1. El Modelo de Media-Varianza de Markowitz	4
2.2. Limitaciones de la Teoría Clásica	5
2.3. Fundamentos de la Teoría de la Información	5
2.4. Modelado Generativo	6
2.4.1. Autoencoders Variacionales (VAEs)	6
2.4.2. Redes Generativas Adversarias (GANs)	7
3. Objetivos Concretos y Metodología de Trabajo	8
3.1. Definición del Problema y Métricas de Evaluación	8
3.2. Arquitectura del Sistema Propuesto	8
3.3. Función de Pérdida y Criterios de Optimización	10
3.4. Generación y Selección de Pesos	11
3.5. Elección de Datos y Preprocesamiento	12
4. Marco Normativo y Protección de Datos	13
4.1. Identificación del Tratamiento de Datos	13
4.2. Cumplimiento del RGPD y la Ley Orgánica 3/2018 (LOPDGDD)	13
4.3. Consideraciones Éticas y Propiedad Intelectual	14
5. Desarrollo Específico de la Contribución	15
5.1. Implementación de la Arquitectura Híbrida	15
5.2. Proceso de Entrenamiento y Estabilización	15

5.3. Generación de Escenarios y Optimización de Cartera	15
6. Código Fuente y Datos Analizados	16
7. Conclusiones	17
8. Limitaciones y Prospectiva	18
Referencias	19

Índice de figuras

3.1. Arquitectura híbrida VAE-GAN para la generación y optimización de carteras.	9
--	---

Índice de cuadros

Resumen

Tu resumen en español...

Abstract

Your abstract in English...

1. Introducción

El Mercado Financiero, entendido como el espacio en el cual se compran y se venden activos financieros (acciones, bonos, divisas, materias primas y criptomonedas principalmente), es el sujeto de estudio perfecto para poner en práctica el uso de tecnologías Big Data.

Las tecnologías Big Data se definen como las herramientas que permiten gestionar, almacenar y analizar conjuntos de datos masivos, que superan a la capacidad tradicional.

Desde los comienzos de la teoría económica moderna, se considera al Mercado Financiero como un sistema caótico. A diferencia de un sistema puramente aleatorio, un sistema caótico presenta patrones y reglas subyacentes que permiten hacer predicciones sobre el mismo.

El caos se caracteriza por la complejidad. En un sistema caótico, las variables presentan relaciones no lineales, a menudo difíciles de detectar a simple vista. Esto deriva en la impredecibilidad del sistema, puesto que pequeñas variaciones en las condiciones iniciales pueden llevar a resultados completamente diferentes.

El Mercado Financiero además es un sistema de nivel dos, por lo tanto, las propias predicciones que se realizan sobre el mismo influyen en los resultados que se obtienen.

En el presente trabajo, se propone abordar el problema de confeccionar una cartera de inversión, esto es, un subconjunto de los activos financieros disponibles, de la mejor manera posible.

(Markowitz, 1952) introduce el modelo de media-varianza como la mejor manera de gestionar la cartera de inversión. Este modelo se fundamenta en el principio del riesgo-rendimiento, buscando para un riesgo determinado, el cuál el inversor asume, maximizar el rendimiento esperado.

Con el uso de las tecnologías Big Data, en particular, con el uso de modelos generativos **Autoencoders Variacionales (VAEs)** y **Redes Generativas Adversarias (GANs)**, se propone una aproximación a la confección de carteras desde una perspectiva no lineal.

1.1. Motivación

La gestión de carteras de inversión ha estado dominada durante décadas por la Teoría de Cartera Moderna (MPT), introducida por (Markowitz, 1952). Este marco teórico se

fundamenta en la optimización media-varianza, bajo el supuesto de que los retornos de los activos financieros siguen una distribución normal. Sin embargo, la evidencia empírica en el análisis de datos masivos financieros demuestra que los mercados reales presentan características que este modelo no logra capturar: la curtosis excesiva (colas pesadas), la asimetría y la volatilidad estocástica.

En el contexto actual de Big Data, la incapacidad de los modelos lineales para gestionar la complejidad representa un riesgo sistémico. Los eventos de “extremo” ocurren con una frecuencia mayor en la realidad, lo que hace que la varianza sea una métrica de riesgo insuficiente. El uso de modelos generativos como las GANs (Salimans y cols., 2016) y los VAEs (Kingma y Welling, 2013) ofrece un nuevo paradigma para aprender la distribución subyacente de los datos sin supuestos previos.

1.2. Objetivos

Los objetivos de este trabajo son los siguientes:

1. Diseñar e implementar una arquitectura VAE para la reducción de dimensionalidad y búsqueda de relaciones subyacentes no lineales en datos de series históricas del S&P 500.
2. Entrenar una red GAN que sintetice escenarios de mercado preservando las cualidades encontradas en el espacio latente.
3. Validación de la calidad de los escenarios generados mediante la Divergencia de Kullback-Leibler como métrica de riesgo.
4. Comparar el rendimiento de la cartera resultante con el modelo de Markowitz mediante el ratio de Sharpe y métricas de error de reconstrucción.

1.3. Planteamiento del trabajo

El presente Trabajo de Fin de Máster propone una metodología híbrida que integra el modelado generativo y la teoría de la información. El núcleo de la investigación se divide en tres fases:

1. Uso de **Autoencoders Variacionales (VAEs)** para la reducción de dimensionalidad no lineal.

2. Desarrollo de una **Red Generativa Adversaria (GAN)** para sintetizar escenarios de mercado realistas.
3. Optimización de la cartera mediante la **Divergencia de Kullback-Leibler** como métrica de riesgo informativo.

1.4. Estructura del trabajo

La memoria se organiza de la siguiente manera: el Capítulo 2 revisa el estado del arte; el Capítulo 3 detalla la metodología y objetivos; el Capítulo 4 expone el marco normativo; el Capítulo 5 desarrolla de forma específica la contribución; el Capítulo 6 describe el código fuente y los datos analizados; el Capítulo 7 recoge las conclusiones; y el Capítulo 8 aborda limitaciones y prospectiva.

2. Estado del Arte

En este capítulo, se presenta una revisión de los principales enfoques existentes en la literatura para la optimización de carteras y el uso de técnicas de aprendizaje automático en finanzas. En primer lugar, se presentan los métodos clásicos basados en la media-varianza. A continuación, se introducen los enfoques de aprendizaje automático y aprendizaje profundo aplicados al análisis financiero. Finalmente, se presentan los modelos generativos, como una línea de investigación emergente con potencial para abordar las limitaciones de los enfoques tradicionales.

2.1. El Modelo de Media-Varianza de Markowitz

En 1952, Harry Markowitz introdujo el modelo de media-varianza para la optimización de carteras. En el modelo de (Markowitz, 1952), el autor toma la varianza como la medida del riesgo. Definiendo cada activo como una variable aleatoria, teniendo en consideración el retorno esperado para un tiempo determinado, así como la variabilidad medida a través de la varianza de dicho retorno. De forma pionera, se desmiente la idea de que el inversor deba limitarse a buscar el máximo retorno esperado a la hora de confeccionar su cartera. Si uno se guía únicamente por esta premisa, Markowitz nos muestra que no tiene en consideración el riesgo asociado a los activos seleccionados, así como la correlación entre los retornos de los mismos.

Es por ello que el artículo se centra en la optimización de carteras buscando aquellas combinaciones de activos que, para igual retorno esperado, minimicen la varianza, es decir, el riesgo. Por lo tanto, el problema de optimizar una cartera se reduce a encontrar máximos o mínimos dentro de una función de dos variables, fijando una de ellas. Teniendo en cuenta solo aquellas combinaciones de activos que se puedan realizar, las combinaciones deseadas forman lo que el autor denomina la frontera eficiente.

Matemáticamente, el problema de optimización se puede formular como la maximización de la utilidad esperada, ponderando el retorno esperado frente al riesgo:

$$\max_w w^\top \mu - \frac{\lambda}{2} w^\top \Sigma w \quad \text{s.a.} \quad \mathbf{1}^\top w = 1 \quad (2.1)$$

Donde $\mu \in \mathbb{R}^n$ es el vector de retornos esperados, $w \in \mathbb{R}^n$ representa los pesos de los activos en la cartera, $\Sigma \in \mathbb{R}^{n \times n}$ es la matriz de varianzas-covarianzas y $\lambda > 0$ es el

coeficiente de aversión al riesgo del inversor.

2.2. Limitaciones de la Teoría Clásica

Markowitz fue pionero, sin embargo su modelo presenta limitaciones aparentes, que con las herramientas actuales de análisis de datos, se pueden superar.

El modelo asume que los retornos de los activos financieros siguen una distribución normal. Sin embargo, la evidencia empírica muestra que no siempre se puede asumir la normalidad en los retornos de los activos. Por otro lado, las correlaciones entre activos financieros no son estáticas, sino que varían a lo largo del tiempo.

En periodos de alta volatilidad, el modelo de Markowitz no es capaz de capturar los cambios en la correlación entre activos, lo que puede llevar a errores en la gestión de la cartera.

Esta limitación es especialmente relevante, teniendo en cuenta que dichos momentos son los que presentan una mayor oportunidad para el inversor.

En este trabajo, se propone una metodología híbrida, que combine las bases teóricas tradicionales con el modelado generativo y la potencia de cálculo moderna.

2.3. Fundamentos de la Teoría de la Información

La identificación del riesgo con la varianza, limita la capacidad de los modelos tradicionales para capturar relaciones no lineales entre activos.

Como alternativa, se propone el uso de la teoría de la información, que propone un tratamiento heurístico del riesgo. Se propone el uso de la entropía como medida de la relación o explicabilidad de los rendimientos de un activo financiero mediante los de otros.

La entropía se define entonces como la medida de incertidumbre pura del mercado.

Siguiendo a (Cover y Thomas, 2006) y entendiendo el retorno de un activo como una variable aleatoria, la entropía se define como:

$$H(X) = - \sum_{i=1}^n p(x_i) \log p(x_i) \quad (2.2)$$

Donde $p(x_i)$ es la probabilidad de que el activo i tenga un retorno x_i .

Para medir la discrepancia entre dos distribuciones, se propone el uso de la divergencia de Kullback-Leibler (KLD), definida como:

$$D_{KL}(P \parallel Q) = \sum_{i=1}^n p(x_i) \log \frac{p(x_i)}{q(x_i)} \quad (2.3)$$

Donde $p(x_i)$ es la probabilidad de que el activo i tenga un retorno x_i en la distribución P , y $q(x_i)$ es la probabilidad de que el activo i tenga un retorno x_i en la distribución Q .

Como evolución de la correlación de (Markowitz, 1952), se propone el uso de la Información Mutua (MI), definida como:

$$I(X; Y) = H(X) + H(Y) - H(X, Y) \quad (2.4)$$

Donde $H(X)$ es la entropía de la variable X , $H(Y)$ es la entropía de la variable Y , y $H(X, Y)$ es la entropía conjunta de las variables X y Y .

La MI se puede entender como la medida de la relación o explicabilidad de los rendimientos de un activo financiero mediante los de otros.

Mientras que la correlación es una medida de la relación lineal entre dos variables, la MI es una medida de la relación no lineal, permitiendo detectar relaciones caóticas o complejas.

2.4. Modelado Generativo

Para superar las limitaciones de la Teoría Clásica a la hora de gestionar la complejidad subyacente a los mercados financieros, se propone el uso de modelos generativos.

Los modelos generativos permiten aprender directamente de la distribución subyacente de los datos, minimizando la dependencia de supuestos paraméricos rígidos. Este enfoque resulta especialmente útil para modelar colas pesadas, asimetrías y dependencias no lineales presentes en los precios de activos.

2.4.1. Autoencoders Variacionales (VAEs)

Los Autoencoders Variacionales (VAEs), introducidos por (Kingma y Welling, 2013), son un tipo de modelos generativos que reconstruyen la distribución de los datos empleando métodos probabilísticos para aprender un espacio latente comprimido y estructurado.

El concepto fundamental de los VAEs es que la distribución de los datos se puede explicar mediante un espacio de menor dimensión formado por factores ocultos que capturan relaciones subyacentes en los datos originales.

Desde el punto de vista económico, los VAEs permiten imbuir al modelo de selección de activos con componentes no lineales, permitiendo capturar relaciones complejas entre activos.

2.4.2. Redes Generativas Adversarias (GANs)

Las Redes Generativas Adversarias (GANs), introducidas en (Salimans y cols., 2016), son un paradigma de modelos generativos que aprenden a generar datos realistas mediante un proceso de aprendizaje adversario.

El concepto fundamental de las GANs, es que el generador (G) aprende a generar datos realistas mediante un proceso de aprendizaje adversario con el discriminador (D).

El entrenamiento de las GANs se define como un juego minimax de suma cero donde el objetivo es alcanzar un equilibrio de Nash. En este escenario, el Generador (G) busca maximizar la probabilidad de error del Discriminador (D), mientras que este último se optimiza para distinguir con precisión entre la distribución de datos reales p_{data} y la distribución sintética p_g .

3. Objetivos Concretos y Metodología de Trabajo

En este capítulo, se presentan los objetivos concretos y la metodología de trabajo seguida para la realización del presente trabajo de investigación. Se detalla el diseño experimental y la lógica de construcción de la arquitectura híbrida VAE-GAN. Asimismo, se presentan los fundamentos teóricos que justifican el empleo de dichas aproximaciones. Se describe el proceso de preprocesamiento de datos, la formalización matemática de las funciones de pérdida y el protocolo de validación para la selección de carteras.

3.1. Definición del Problema y Métricas de Evaluación

(Markowitz, 1952) cierra su introducción a la teoría de la cartera moderna afirmando que en el uso de la regla de esperanza-varianza, el inversor debe, en su opinión, combinar procedimientos estadísticos y el juicio del hombre práctico.

En el presente trabajo, se propone no solo ampliar el objetivo del inversor, considerando la entropía como medida del riesgo capaz de revelar relaciones no lineales entre activos, sino que también se propone ampliar las herramientas de evaluación del mercado.

El objetivo de este informe es generar escenarios sintéticos mediante técnicas de aprendizaje profundo, de modo que se minimice la D_{KL} entre la distribución de los retornos históricos (reales) y la distribución de los retornos generados (sintéticos). Esto garantiza que el modelo no solo optimiza el rendimiento, sino que replica fielmente la estructura estadística del mercado.

3.2. Arquitectura del Sistema Propuesto

La arquitectura propuesta para el modelo se articula en tres módulos independientes:

- Extracción de características con Autoencoders Variacionales (VAEs) para la reducción de la dimensionalidad de forma no lineal. El VAE proyecta los datos históricos hacia un espacio latente de menor dimensión. Este proceso permite eliminar ruido, reteniendo únicamente las características persistentes.

- Generación de escenarios: Redes Generativas Adversarias (GANs) para sintetizar escenarios de mercado realistas, la GAN entrena sobre el espacio latente sintetizando vectores de retornos que preservan las dependencias no lineales y los momentos estadísticos de orden superior.
- Optimización de la cartera mediante la Divergencia de Kullback-Leibler como métrica de riesgo informativo. Se sustituye el uso de la varianza como medida de riesgo por la Divergencia KL como métrica del mismo. Se optimiza la cartera para que sea más robusta frente a la entropía del mercado.

De manera intuitiva, el modelo filtra el ruido empleando el VAE, añadiendo ganancia de información a través del espacio latente e infiriendo relaciones no lineales entre los activos, así como mejorando la reactividad a condiciones de alta volatilidad. Los GANs sintetizan escenarios realistas de mercado para comprobar la robustez de la cartera.

El mercado financiero es un sistema caótico, en el cuál existe una gran cantidad de variables interconectadas de maneras que van mucho más allá de la linealidad. Además, es un sistema de nivel dos, por lo tanto, las propias predicciones que se realizan sobre el mismo influyen en los resultados que se obtienen. El VAE pretende encontrar el espacio donde realmente viven las variables que mueven el mercado. Este planteamiento es superior al de métodos lineales como el PCA, pues el mercado no es un sistema lineal.

El Espacio Latente Z es el lugar donde las interconexiones entre variables se ponen de manifiesto.




Figura 3.1: Arquitectura híbrida VAE-GAN para la generación y optimización de carteras.

El VAE toma datos históricos de retornos reales para encontrar las variables latentes asociadas a los mismos, modelando las relaciones subyacentes que realmente mueven conjuntamente los valores de activos diferentes. El Generador recibe este espacio latente, y trabajando con el Discriminador es capaz de crear variaciones gracias a la introducción de ruido. Con este modelo, podemos crear escenarios sintéticos tan similares a la realidad que no se puedan distinguir de verdaderos retornos históricos. Esto permite realizar la optimización final sobre datos probables, generando un conjunto de pesos para una cartera óptima.

3.3. Función de Pérdida y Criterios de Optimización

Siguiendo el enfoque propuesto por (Kingma y Welling, 2013), el objetivo del modelo VAE es maximizar la verosimilitud marginal de los datos observados. Dado un conjunto de datos $x_{i=1}^N$, la verosimilitud marginal se descompone como la suma sobre las observaciones individuales:

$$\log p_{\theta}(x^{(1)}, \dots, x^{(N)}) = \sum_{i=1}^N \log p_{\theta}(x^{(i)}) \quad (3.1)$$

Sin embargo, el cálculo directo de $\log p_{\theta}(x^{(i)})$ resulta intratable debido a la integración sobre las variables latentes. Para abordar este problema, se introduce una distribución aproximada $q_{\phi}(z|x)$, lo que permite descomponer la log-verosimilitud como:

$$\log p_{\theta}(x^{(i)}) = D_{KL}(q_{\phi}(z|x^{(i)}) \| p_{\theta}(z|x^{(i)})) + \mathcal{L}(\theta, \phi; x^{(i)}) \quad (3.2)$$

Dado que la divergencia de Kullback-Leibler es siempre no negativa, el término $\mathcal{L}(\theta, \phi; x^{(i)})$ constituye una cota inferior variacional (Evidence Lower Bound, ELBO):

$$\log p_{\theta}(x^{(i)}) \geq \mathcal{L}(\theta, \phi; x^{(i)}) \quad (3.3)$$

Esta cota puede expresarse como:

$$\mathcal{L}(\theta, \phi; x^{(i)}) = \mathbb{E}_{q_{\phi}(z|x^{(i)})} [\log p_{\theta}(x^{(i)}, z) - \log q_{\phi}(z|x^{(i)})] \quad (3.4)$$

o, de forma equivalente, separando sus componentes principales:

$$\mathcal{L}(\theta, \phi; x^{(i)}) = -D_{KL}(q_{\phi}(z|x^{(i)}) \| p(z)) + \mathbb{E}_{q_{\phi}(z|x^{(i)})} [\log p_{\theta}(x^{(i)}|z)] \quad (3.5)$$

Esta formulación revela dos términos fundamentales:

- Un término de regularización, que fuerza la distribución latente aproximada $q_\phi(z|x)$ a mantenerse cercana a la probabilidad a priori $p(z)$.
- Un término de reconstrucción, que mide la capacidad del modelo generativo para reproducir los datos observados a partir de las variables latentes.

El proceso de entrenamiento consiste en maximizar esta cota inferior respecto a los parámetros del modelo generativo θ y los parámetros variacionales ϕ .

No obstante, la optimización presenta dificultades prácticas. En particular, el cálculo del gradiente respecto a ϕ mediante estimadores Monte Carlo directos presenta alta varianza, lo que dificulta la convergencia y hace inviable su uso en la práctica. Para superar esta limitación, se introduce el truco de reparametrización, que permite expresar la variable latente como una transformación determinista de una variable aleatoria auxiliar:

$$z = \mu_\phi(x) + \sigma_\phi(x) \cdot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I) \quad (3.6)$$

Esta reformulación permite trasladar la fuente de aleatoriedad fuera de la red neuronal, haciendo posible aplicar técnicas estándar de optimización basadas en gradiente (backpropagation) con estimadores de baja varianza.

En conjunto, este marco convierte el problema de inferencia variacional en uno de optimización eficiente, permitiendo el entrenamiento conjunto del encoder y el decoder dentro de una arquitectura diferenciable end-to-end.

3.4. Generación y Selección de Pesos

Una vez estructurado el Espacio Latente, se procede a la generación de escenarios sintéticos. Para ello, se emplea la arquitectura adversarial de las Redes Generativas Antagónicas. En este enfoque, se introduce un marco de entrenamiento adversario en el que dos redes neuronales compiten entre sí, el Generador (G) y el Discriminador (D). El Generador se encarga de generar escenarios sintéticos que sean indistinguibles de los datos reales, mientras que el Discriminador se encarga de distinguir entre los datos reales y los sintéticos. El Generador se entrena para maximizar la probabilidad de error del Discriminador, mientras que este último se entrena para maximizar la probabilidad de distinguir entre los datos reales y los sintéticos.

El Discriminador sustituye pues en el enfoque moderno a lo que (Markowitz, 1952) denominaba como el juicio del hombre práctico. El Generador entrena para buscar esce-

narios que sean indistinguibles de la realidad, utilizando la estructura latente previamente establecida así como ruido aleatorio introducido en la entrada.

Por lo tanto, tenemos un juego minimax de suma cero donde el objetivo es alcanzar un equilibrio de Nash. En este escenario, el Generador (G) busca maximizar la probabilidad de error del Discriminador (D), mientras que este último se optimiza para distinguir con precisión entre la distribución de datos reales p_{data} y la distribución sintética p_g .

3.5. Elección de Datos y Preprocesamiento

Los datos empleados para el entrenamiento proceden de los retornos históricos de las empresas integrantes del índice S&P 500, obtenidos a través de la API de Yahoo Finance. La selección de este universo se justifica por la representatividad del mercado estadounidense y su alta capitalización, lo que ofrece un entorno con suficiente liquidez y profundidad estadística para el entrenamiento de arquitecturas generativas, en línea con estudios recientes de la industria (Rasekhschaffe, 2026).

Para el preprocesado, se ha aplicado una normalización Min-Max tras un tratamiento de valores atípicos (*outliers*). Este escalado al rango $[0, 1]$ es crítico para asegurar la estabilidad numérica de las funciones de activación de las redes neuronales y evitar la explosión del gradiente durante el entrenamiento del VAE y la GAN.

4. Marco Normativo y Protección de Datos

Se analiza el entorno legal y ético aplicable, con especial énfasis en el Reglamento General de Protección de Datos (RGPD) para el uso de datos masivos y las directrices éticas sobre el uso de la Inteligencia Artificial en el sector financiero.

4.1. Identificación del Tratamiento de Datos

En el desarrollo del presente Trabajo de Fin de Máster, el tratamiento de datos se limita estrictamente a series temporales de precios de activos financieros públicos procedentes del índice S&P 500. Se hace constar que no se han utilizado, procesado ni almacenado datos de carácter personal de terceros identificados o identificables, cumpliendo con el principio de minimización de datos.

4.2. Cumplimiento del RGPD y la Ley Orgánica 3/2018 (LOPDGDD)

A pesar de la naturaleza pública de los datos financieros, el proyecto se alinea con el Reglamento General de Protección de Datos (RGPD) y la Ley Orgánica 3/2018 en los siguientes términos:

- **Finalidad:** Los datos son tratados con el fin exclusivo de investigación académica y desarrollo de modelos de aprendizaje profundo.
- **Seguridad:** El procesamiento de los datos se realiza en un entorno local, garantizando la integridad de los mismos y evitando cualquier fuga de información que pudiera afectar a la infraestructura del sistema.
- **Análisis de Riesgo:** Dado que no existe tratamiento de datos de personas físicas, el riesgo para los derechos y libertades de las personas es nulo.

4.3. Consideraciones Éticas y Propiedad Intelectual

El acceso a los datos se ha realizado mediante la API de Yahoo Finance, respetando los términos y condiciones de uso para fines educativos y de investigación. El código fuente desarrollado y los escenarios sintéticos generados por la arquitectura VAE-GAN son de autoría propia, garantizando la transparencia en el proceso de generación de información.

5. Desarrollo Específico de la Contribución

- 5.1. Implementación de la Arquitectura Híbrida
- 5.2. Proceso de Entrenamiento y Estabilización
- 5.3. Generación de Escenarios y Optimización de Cartera

6. Código Fuente y Datos Analizados

7. Conclusiones

8. Limitaciones y Prospectiva

Referencias

- Cover, T. M., y Thomas, J. A. (2006). *Elements of information theory* (2nd ed.). John Wiley & Sons.
- Kingma, D. P., y Welling, M. (2013). Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*.
- Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91.
- Rasekhschaffe, K. C. (2026). Generative ai for stock selection. *arXiv preprint arXiv:2602.00196*. (Discute la automatización del descubrimiento de características mediante LLMs y modelos generativos en renta variable.)
- Salimans, T., Goodfellow, I., Zaremba, W., Cheung, V., Radford, A., Chen, X., y Chen, X. (2016). Improved techniques for training gans. En D. Lee, M. Sugiyama, U. Luxburg, I. Guyon, y R. Garnett (Eds.), *Advances in neural information processing systems* (Vol. 29). Curran Associates, Inc. Descargado de https://proceedings.neurips.cc/paper_files/paper/2016/file/8a3363abe792db2d8761d6403605aeb7-Paper.pdf