



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y
Tecnología

Máster Universitario en Análisis y Visualización de
Datos Masivos

Generación de Escenarios Sintéticos
para Optimización de Carteras del S&P 500
mediante Arquitecturas VAE-GAN

Trabajo Fin de Estudios

presentado por: Daniel Machín González

Dirigido por: Jesús Cigales Canga

Ciudad: San Bartolomé

Fecha: 23 de agosto de 2026

Índice general

Resumen	VII
Abstract	VIII
1. Introducción	1
1.1. Motivación	2
1.2. Planteamiento del trabajo	2
1.3. Estructura del trabajo	3
2. Contexto y estado del arte	4
2.1. Contexto del problema	4
2.1.1. Teoría moderna de carteras	4
2.1.2. Modelo de media-varianza de Markowitz	5
2.1.3. Riesgo financiero y hechos estilizados	6
2.1.4. Limitaciones de la varianza como medida de riesgo	7
2.1.5. Teoría de la información	8
2.1.6. Entropía, divergencia KL e información mutua	8
2.1.7. Inteligencia artificial, aprendizaje automático y aprendizaje profundo	9
2.1.8. Modelos generativos profundos	10
2.1.9. Autoencoders Variacionales	10
2.1.10. Redes Generativas Adversarias y Wasserstein GAN	12
2.1.11. Modelos de difusión	13
2.2. Estado del arte	13
2.2.1. Optimización clásica de carteras	14
2.2.2. Aprendizaje automático y deep learning en gestión de carteras	14
2.2.3. Modelos generativos para series financieras	15
2.2.4. Modelos de difusión para selección dinámica de carteras	16
2.3. Conclusiones	17
2.3.1. Síntesis crítica y hueco de investigación	17
3. Objetivos concretos y metodología de trabajo	19
3.1. Objetivo general	19
3.2. Objetivos específicos	19

3.3. Metodología del trabajo	20
3.3.1. Alcance y delimitación del trabajo	20
3.3.2. Justificación de la metodología CRISP-DM	21
3.3.3. Adaptación de CRISP-DM al presente trabajo	22
3.3.4. Visión general y secuencia experimental	24
3.3.5. Diseño general del experimento	25
3.3.6. Adquisición de datos	25
3.3.7. Preprocesamiento de los datos	25
3.3.8. Arquitectura VAE-GAN considerada en el diseño inicial	26
3.3.9. Generación de escenarios sintéticos	27
3.3.10. Función de pérdida y criterios de optimización	28
3.3.11. Optimización y selección de pesos	30
3.3.12. Benchmarks de comparación	31
4. Marco normativo	33
4.1. Identificación del tratamiento de datos	33
4.2. RGPD y Ley Orgánica 3/2018	33
4.3. Fuente financiera y propiedad intelectual	33
4.4. Uso responsable de inteligencia artificial	34
4.5. Carácter académico y no recomendación financiera	34
4.6. Reproducibilidad y transparencia	34
5. Desarrollo específico de la contribución	35
5.1. Análisis exploratorio de datos	35
5.1.1. Descripción del dataset	35
5.1.2. Variables utilizadas	35
5.1.3. Valores perdidos y calidad de los datos	35
5.1.4. Estadísticos descriptivos	36
5.1.5. Distribución de los retornos	37
5.1.6. Evolución temporal	37
5.1.7. Análisis de volatilidad	38
5.1.8. Análisis de correlaciones	38
5.1.9. Conclusiones del análisis exploratorio	39
5.2. Diseño del pipeline experimental	41

5.3.	Selección del universo de activos	42
5.4.	Adquisición de datos financieros	42
5.5.	Construcción del conjunto de retornos	43
5.6.	Implementación de modelos de referencia	44
5.6.1.	Cartera equiponderada	46
5.6.2.	Cartera de Markowitz clásica	46
5.6.3.	Cartera de Markowitz restringida	47
5.6.4.	Evaluación común de las estrategias	48
5.7.	Implementación del Autoencoder Variacional	48
5.8.	Generación de escenarios sintéticos	50
5.9.	Optimización de cartera a partir de escenarios sintéticos	51
5.10.	Síntesis del pipeline experimental	52
5.11.	Entrenamiento y comparación de modelos	52
5.11.1.	Modelos candidatos	52
5.11.2.	Configuración experimental	53
5.11.3.	Métricas de comparación	53
5.11.4.	Resultados de entrenamiento	53
5.11.5.	Selección del modelo final	54
5.12.	Resultados experimentales	54
5.12.1.	Métricas de evaluación	55
5.12.2.	Resultados empíricos	55
5.12.3.	Lectura por estrategia	56
5.12.4.	Por qué el resultado VAE puede ser elevado	57
5.12.5.	Relación con la calidad generativa	57
5.12.6.	Evaluación comparativa y validez	57
5.12.7.	Síntesis de resultados	58
6.	Código fuente y datos analizados	59
6.1.	Código fuente	59
6.1.1.	Herramientas y tecnologías	59
6.1.2.	Scripts principales	59
6.1.3.	Flujo de ejecución	60
6.1.4.	Dependencias y entorno	60

6.1.5. Artefactos y trazabilidad	61
6.2. Datos analizados	61
6.2.1. Datos brutos y procesados	61
6.2.2. Datos generados	61
6.2.3. Pesos, retornos y métricas	61
6.2.4. Figuras y productos del EDA	62
6.2.5. Limitaciones de los datos	62
7. Conclusiones	63
7.1. Cumplimiento de objetivos	63
7.2. Principales resultados obtenidos	63
7.3. Valoración final de la metodología	64
7.4. Aportaciones del trabajo	64
7.5. Conclusión general	65
8. Limitaciones y prospectiva	66
8.1. Limitaciones	66
8.1.1. Universo y periodo	66
8.1.2. Fuente de datos	66
8.1.3. No estacionariedad y validación temporal	66
8.1.4. Modelos generativos	66
8.1.5. Optimización y condiciones de mercado	67
8.1.6. Alcance de las conclusiones	67
8.2. Trabajo futuro	67
8.2.1. Comparación y robustez de modelos	67
8.2.2. Validación temporal y operación	68
8.2.3. Ampliación financiera	68
8.2.4. Variables condicionantes y herramienta reproducible	68
Referencias bibliográficas	69

Índice de figuras

2.1. Representación conceptual de la frontera eficiente de Markowitz. Fuente: elaboración propia.	6
2.2. Esquema conceptual del Autoencoder Variacional implementado. Fuente: elaboración propia.	12
3.1. Arquitectura híbrida VAE-GAN considerada inicialmente y no implementada de forma completa. Fuente: elaboración propia.	27
5.1. Valores perdidos por activo en la matriz final de retornos. Fuente: elaboración propia a partir de los datos procesados.	36
5.2. Distribución agregada de los log-retornos diarios. Fuente: elaboración propia a partir de los datos procesados.	37
5.3. Evolución de los rendimientos acumulados en una muestra de activos. Fuente: elaboración propia.	38
5.4. Volatilidad móvil anualizada en una muestra de activos. Fuente: elaboración propia.	39
5.5. Matriz de correlaciones de los retornos. Fuente: elaboración propia a partir de los datos procesados.	40
5.6. Evolución acumulada de las estrategias durante el periodo de test. Fuente: elaboración propia a partir de los retornos generados por el pipeline.	56

Índice de tablas

3.1. Adaptación de CRISP-DM al desarrollo experimental del trabajo. Fuente: elaboración propia.	24
5.1. Selección de estadísticos descriptivos de log-retornos diarios. Fuente: elaboración propia a partir de <code>eda_descriptive_statistics.csv</code>	36
5.2. Comparación reproducible de autoencoders en escala normalizada. Fuente: elaboración propia a partir de <code>autoencoder_model_comparison.csv</code>	54
5.3. Comparación de estrategias de inversión fuera de muestra. Fuente: elaboración propia a partir de <code>benchmark_comparison.csv</code>	55
6.1. Principales archivos de código fuente. Fuente: elaboración propia.	60

Resumen

La optimización media-varianza es sensible a los errores de estimación de retornos esperados y covarianzas, especialmente cuando los retornos financieros presentan colas pesadas, volatilidad cambiante y dependencias que no quedan plenamente descritas por supuestos gaussianos. Este Trabajo de Fin de Máster estudia si escenarios sintéticos pueden proporcionar una base alternativa para estimar dichos parámetros. Se utilizan precios ajustados diarios de 30 activos del S&P 500 entre 2014 y 2024, transformados en 2.766 observaciones de log-retornos. El proceso sigue una adaptación de CRISP-DM e incluye análisis exploratorio, partición cronológica 80/20, escalado sin fuga de información, entrenamiento de modelos y evaluación fuera de muestra.

El núcleo generativo implementado es un Autoencoder Variacional (VAE) con ocho dimensiones latentes. A partir de su *decoder* se generan 5.000 escenarios conjuntos, cuyas medias y covarianzas alimentan una optimización de máximo ratio de Sharpe. La cartera resultante se compara con equiponderación, Markowitz clásico y Markowitz restringido sobre 554 sesiones no utilizadas para entrenar. En ese periodo, la estrategia VAE obtiene un retorno acumulado del 242,32 %, volatilidad anualizada del 25,08 %, Sharpe de 2,99 y máximo *drawdown* del -13,96 %. Estos resultados son favorables en rentabilidad y Sharpe, pero también implican mayor volatilidad y no acreditan superioridad general. Una comparación adicional AE/VAE muestra que la calidad de reconstrucción no equivale necesariamente a calidad generativa. Aunque el título conserva la inspiración VAE-GAN, GAN/WGAN no forman parte de la implementación validada. El estudio es académico, sin costes, rebalanceo ni validación *walk-forward*.

Palabras clave: Autoencoder Variacional, escenarios sintéticos, optimización de carteras, Markowitz, S&P 500.

Abstract

Mean–variance optimisation is sensitive to estimation errors in expected returns and covariances, particularly when financial returns exhibit heavy tails, changing volatility, and dependencies that are not fully described by Gaussian assumptions. This Master’s Thesis investigates whether synthetic scenarios can provide an alternative basis for parameter estimation. Daily adjusted prices for 30 S&P 500 constituents from 2014 to 2024 are transformed into 2,766 log-return observations. The process follows an adaptation of CRISP-DM and comprises exploratory analysis, an 80/20 chronological split, leakage-free scaling, model training, and out-of-sample evaluation.

The implemented generative core is a Variational Autoencoder (VAE) with eight latent dimensions. Its decoder generates 5,000 joint scenarios whose means and covariances feed a maximum-Sharpe optimisation. The resulting portfolio is compared with equal weighting, classical Markowitz, and constrained Markowitz strategies over 554 sessions excluded from training. During this period, the VAE strategy achieves a 242.32% cumulative return, 25.08% annualised volatility, a 2.99 Sharpe ratio, and a -13.96% maximum drawdown. These figures are favourable in terms of return and Sharpe, but they also entail greater volatility and do not establish general superiority. An additional AE/VAE comparison shows that reconstruction quality is not equivalent to generative quality. Although the title retains its VAE-GAN inspiration, GAN/WGAN models are not part of the validated implementation. The study is academic and excludes transaction costs, rebalancing, and walk-forward validation.

Keywords: Variational Autoencoder, synthetic scenarios, portfolio optimisation, Markowitz, S&P 500.

1. Introducción

El mercado financiero, que se define como el espacio en el cual se compran y venden activos financieros (acciones, bonos, divisas, materias primas y criptomonedas principalmente), demanda el procesamiento de flujos masivos de datos que superan las capacidades de las herramientas analíticas tradicionales. La enorme cantidad de relaciones e interdependencias que se suceden entre los diferentes activos lo convierte en un sistema caótico, donde el empleo de nuevos enfoques modernos puede suponer un avance significativo en la comprensión de su comportamiento y en la toma de decisiones de inversión.

Desde los comienzos de la teoría económica moderna, se ha considerado el mercado financiero como un sistema caótico. A diferencia de un sistema puramente aleatorio, un sistema caótico presenta patrones y reglas subyacentes que permiten realizar determinadas predicciones sobre su comportamiento. El caos se caracteriza por la complejidad. En un sistema caótico, las variables presentan relaciones no lineales, a menudo difíciles de detectar a simple vista. Esto deriva en la impredecibilidad del sistema, puesto que pequeñas variaciones en las condiciones iniciales pueden llevar a resultados completamente diferentes.

Además, el mercado financiero puede entenderse como un sistema de segundo orden, dado que las propias predicciones que se realizan sobre él pueden influir en los resultados que se obtienen. Esto es, en el propio intento de predecir el comportamiento del mercado, se puede alterar su dinámica, fenómeno habitualmente observado en virajes que se suelen producir en precios de determinados activos cuando personas o entidades relevantes hacen declaraciones acerca de su futuro comportamiento.

En el presente trabajo se propone abordar el problema de confeccionar una cartera de inversión, esto es, un subconjunto de los activos financieros disponibles, de forma eficiente. (Markowitz, 1952) introduce el modelo de media-varianza como una de las aproximaciones clásicas para la gestión de carteras de inversión. Este modelo se fundamenta en el principio riesgo-rendimiento, buscando maximizar el rendimiento esperado para un determinado nivel de riesgo asumido por el inversor.

Con el uso de tecnologías Big Data y, en particular, con el uso de modelos generativos como los **Autoencoders Variacionales (VAEs)** y las **Redes Generativas Adversarias (GANs)**, se propone una aproximación a la confección de carteras desde una perspectiva no lineal.

1.1. Motivación

La gestión de carteras de inversión ha estado dominada durante décadas por la Teoría de Cartera Moderna (MPT), introducida por (Markowitz, 1952). Este marco teórico se fundamenta en la optimización media-varianza, bajo el supuesto de que los retornos de los activos financieros siguen una distribución normal. Sin embargo, la evidencia empírica en el análisis de datos masivos financieros demuestra que los mercados reales presentan características que este modelo no logra capturar: la curtosis excesiva (colas pesadas), la asimetría y la volatilidad estocástica.

En el contexto actual de Big Data, la incapacidad de los modelos lineales para gestionar la complejidad representa una limitación relevante. Los eventos extremos ocurren con una frecuencia mayor en la realidad de la que predeciría un modelo normal, lo que hace que la varianza sea una métrica de riesgo insuficiente. El uso de modelos generativos como las GANs (Salimans y cols., 2016) y los VAEs (Kingma y Welling, 2013) ofrece un nuevo paradigma para aprender la distribución subyacente de los datos sin imponer una forma paramétrica rígida.

Frente a otras aproximaciones, como el uso de modelos de Machine Learning o sistemas de ecuaciones diferenciales, los modelos generativos permiten trabajar desde una perspectiva probabilística. Estos modelos se adaptan a los datos y ofrecen flexibilidad frente a cambios drásticos.

1.2. Planteamiento del trabajo

La elección de esta arquitectura, como se exponía previamente, no busca predecir el precio futuro de los activos, sino generar diversos escenarios posibles para comprender el riesgo subyacente de los mismos.

El presente Trabajo de Fin de Máster propone una metodología híbrida que integra el modelado generativo y la teoría de la información. El núcleo de la investigación se divide en cuatro fases:

Conviene delimitar desde el inicio el alcance alcanzado. Aunque el título y el marco conceptual se inspiran en arquitecturas generativas híbridas, el desarrollo experimental validado se centra en el Autoencoder Variacional. GAN y WGAN se revisan por su relevancia teórica y se mantienen como ampliación futura, pero no se presentan como modelos

entrenados. Asimismo, la divergencia de Kullback–Leibler interviene en la regularización del espacio latente del VAE y no como función objetivo de la cartera. El trabajo no pretende predecir precios puntuales: genera vectores plausibles de retornos y evalúa los pesos resultantes sobre observaciones posteriores no utilizadas en el entrenamiento.

1. Extracción de datos de series históricas del S&P 500. Se propone la creación de un pipeline de datos que permita la implementación de la arquitectura propuesta.
2. Uso de **Autoencoders Variacionales (VAEs)** para la reducción de dimensionalidad no lineal.
3. Generación de escenarios sintéticos mediante muestreo en el espacio latente y deco-dificación con el VAE entrenado.
4. Estimación de medias y covarianzas sintéticas y optimización de máximo Sharpe, seguida de evaluación fuera de muestra.

La contribución posee carácter académico. Las cifras obtenidas permiten comparar métodos bajo un protocolo común, pero no constituyen recomendación financiera ni garantía de rendimiento. Esta cautela resulta particularmente importante porque el experimento utiliza un único universo, un único corte temporal y pesos estáticos sin costes de transacción.

1.3. Estructura del trabajo

La memoria se organiza de la siguiente manera: el Capítulo 2 reúne el contexto del problema, los fundamentos teóricos y el estado del arte. El Capítulo 3 presenta los objetivos general y específicos, el alcance y la metodología del trabajo. El Capítulo 4 expone el marco normativo. El Capítulo 5 desarrolla la contribución específica e integra los resultados experimentales. El Capítulo 6 describe el código fuente, las herramientas empleadas y los datos analizados. El Capítulo 7 recoge las conclusiones. Finalmente, el Capítulo 8 presenta las principales limitaciones y posibles líneas de trabajo futuro.

2. Contexto y estado del arte

2.1. Contexto del problema

En este capítulo se presentan los fundamentos conceptuales sobre los que se apoya el presente Trabajo de Fin de Máster. En primer lugar, se introducen los principios básicos de la teoría moderna de carteras y el modelo de media-varianza de Markowitz. A continuación, se analizan algunas de sus principales limitaciones, especialmente en lo relativo al uso de la varianza como medida de riesgo. Posteriormente, se presentan conceptos fundamentales de la teoría de la información, así como su utilidad para comparar distribuciones y medir incertidumbre. Finalmente, se introducen los modelos generativos profundos, con especial atención a los Autoencoders Variacionales, las Redes Generativas Adversarias y los modelos de difusión.

2.1.1. Teoría moderna de carteras

La teoría moderna de carteras constituye uno de los marcos fundamentales para la gestión cuantitativa de inversiones. Su aportación principal consiste en formalizar la relación entre rentabilidad esperada y riesgo, mostrando que la selección de activos no debe basarse únicamente en maximizar el rendimiento esperado, sino también en considerar la variabilidad de dichos rendimientos y la relación entre los distintos activos que componen la cartera.

Desde esta perspectiva, una cartera de inversión puede entenderse como una combinación ponderada de activos financieros. Cada activo aporta una rentabilidad esperada y un nivel de riesgo, pero el riesgo total de la cartera no depende únicamente del riesgo individual de cada activo, sino también de la forma en que sus retornos se relacionan entre sí. Esta idea introduce el papel central de la diversificación: combinar activos imperfectamente correlacionados puede reducir el riesgo global de la cartera sin renunciar necesariamente a rentabilidad esperada.

La teoría moderna de carteras establece, por tanto, que el inversor debe buscar combinaciones eficientes de activos. Estas combinaciones son aquellas que, para un determinado nivel de riesgo, maximizan la rentabilidad esperada o, de forma equivalente, que para una rentabilidad esperada dada minimizan el riesgo asumido. El conjunto de estas carteras recibe el nombre de frontera eficiente.

2.1.2. Modelo de media-varianza de Markowitz

(Markowitz, 1952) introduce el modelo de media-varianza para la optimización de carteras. Este modelo supuso un cambio relevante frente a enfoques previos basados únicamente en la búsqueda del máximo retorno esperado, ya que incorpora explícitamente el riesgo asociado a los activos seleccionados y la correlación entre sus retornos.

En el modelo de Markowitz, cada activo financiero se representa como una variable aleatoria caracterizada por su retorno esperado y por la variabilidad de dicho retorno. La cartera se define mediante un vector de pesos, donde cada componente representa la proporción del capital invertida en cada activo. La rentabilidad esperada de la cartera se obtiene como una combinación lineal ponderada de los retornos esperados de los activos, mientras que el riesgo se mide a través de la varianza de la cartera.

Matemáticamente, el problema de optimización puede formularse como la maximización de una función objetivo que pondera la rentabilidad esperada frente al riesgo:

$$\max_w \left\{ w^\top \mu - \frac{\lambda}{2} w^\top \Sigma w \right\} \quad \text{s.a.} \quad \mathbf{1}^\top w = 1 \quad (2.1)$$

donde $\mu \in \mathbb{R}^n$ es el vector de retornos esperados de los activos, $w \in \mathbb{R}^n$ representa el vector de pesos de la cartera, $\Sigma \in \mathbb{R}^{n \times n}$ es la matriz de varianzas-covarianzas de los retornos y $\lambda > 0$ es el coeficiente de aversión al riesgo del inversor.

El primer término, $w^\top \mu$, representa la rentabilidad esperada de la cartera. Matemáticamente, se trata del producto escalar entre el vector de pesos y el vector de retornos esperados, lo que equivale a calcular la rentabilidad esperada total como suma ponderada de las rentabilidades individuales de los activos.

El segundo término, $\frac{\lambda}{2} w^\top \Sigma w$, introduce una penalización por riesgo. La expresión cuadrática $w^\top \Sigma w$ representa la varianza de la cartera, incorporando tanto la volatilidad individual de cada activo como las covarianzas entre activos. El parámetro λ controla el equilibrio entre rentabilidad y riesgo: cuanto mayor es su valor, mayor es la penalización asociada al riesgo y, por tanto, más conservadora será la cartera resultante.

La restricción $\mathbf{1}^\top w = 1$ garantiza que la suma de los pesos sea igual a uno, es decir, que se invierta la totalidad del capital disponible. En conjunto, este problema establece el compromiso fundamental de la teoría moderna de carteras: maximizar la rentabilidad esperada y, al mismo tiempo, controlar el riesgo asumido.

La relación entre retorno y volatilidad puede representarse mediante la frontera eficiente

de la Figura 2.1. Los puntos situados por debajo son dominados por combinaciones que ofrecen más retorno para igual riesgo. La figura es conceptual: no representa pesos ni resultados calculados para el dataset del trabajo.

La caracterización analítica de la frontera eficiente fue desarrollada posteriormente por (Merton, 1972), reforzando la interpretación geométrica del problema media-varianza y su papel como referencia clásica en la selección cuantitativa de carteras.




Figura 2.1: Representación conceptual de la frontera eficiente de Markowitz. Fuente: elaboración propia.

2.1.3. Riesgo financiero y hechos estilizados

El riesgo financiero puede entenderse como la incertidumbre asociada a la evolución futura del valor de los activos financieros. En el marco clásico de Markowitz, este riesgo se identifica principalmente con la varianza de los retornos. Sin embargo, los mercados financieros reales presentan propiedades estadísticas que no siempre pueden describirse adecuadamente mediante una distribución normal ni mediante relaciones lineales entre activos.

Entre estas propiedades destacan las colas pesadas, la asimetría, la volatilidad estocástica y los cambios en las correlaciones entre activos a lo largo del tiempo (Takahashi, Chen, y Tanaka-Ishii, 2019). Las colas pesadas indican que los eventos extremos ocurren con mayor frecuencia de la que predeciría una distribución normal. La asimetría refleja que las pérdidas y ganancias no necesariamente se distribuyen de forma simétrica. La volatilidad estocástica y el agrupamiento de volatilidad muestran que los periodos de alta volatilidad tienden a concentrarse en el tiempo.

La variación temporal de la volatilidad y su agrupamiento han sido estudiados am-

pliamente en la literatura econométrica, especialmente a partir de los modelos ARCH propuestos por (Engle, 1982).

Estas características son especialmente relevantes en la gestión de carteras, ya que afectan directamente a la estimación del riesgo. En periodos de estrés financiero, las correlaciones entre activos pueden aumentar de forma significativa, reduciendo los beneficios esperados de la diversificación. Por ello, una aproximación basada únicamente en medias, varianzas y covarianzas puede resultar insuficiente para capturar la complejidad de los mercados financieros.

2.1.4. Limitaciones de la varianza como medida de riesgo

Aunque el modelo de Markowitz fue pionero y sigue constituyendo una referencia fundamental en la optimización de carteras, presenta limitaciones importantes. Una de las principales es la identificación del riesgo con la varianza de los retornos. Esta elección implica asumir que las desviaciones positivas y negativas respecto a la media son tratadas de la misma forma, aunque desde el punto de vista del inversor las pérdidas suelen ser más relevantes que las ganancias inesperadas.

Además, el uso de la varianza como medida de riesgo es muy restrictivo cuando los retornos financieros no siguen una distribución normal. En presencia de colas pesadas, asimetrías o eventos extremos, la varianza puede infraestimar el riesgo real de la cartera. Del mismo modo, la matriz de covarianzas solo captura relaciones lineales entre activos, por lo que puede no ser suficiente para representar dependencias no lineales o cambios estructurales en el mercado.

Otra limitación relevante es la sensibilidad del modelo a la estimación de sus parámetros. Pequeñas variaciones en los retornos esperados o en la matriz de covarianzas pueden generar diferencias significativas en los pesos óptimos de la cartera. Esto resulta especialmente problemático en mercados financieros, donde los parámetros estimados a partir de datos históricos pueden no mantenerse estables en el futuro.

Estas limitaciones motivan la búsqueda de enfoques alternativos capaces de capturar una descripción más rica de la distribución de retornos. En lugar de resumir el comportamiento de los activos únicamente mediante media y varianza, resulta necesario considerar herramientas que permitan aproximar la distribución completa y modelar relaciones no lineales entre activos.

2.1.5. Teoría de la información

La teoría de la información proporciona un marco matemático para estudiar la incertidumbre, la dependencia y la transmisión de información en sistemas aleatorios (Cover y Thomas, 2006). En el contexto de este trabajo, resulta especialmente relevante porque permite analizar distribuciones de probabilidad y cuantificar diferencias entre ellas.

Mientras que el enfoque clásico de media-varianza resume el comportamiento de los retornos mediante momentos de primer y segundo orden, la teoría de la información permite introducir medidas más generales de incertidumbre y discrepancia distribucional. Esto resulta útil cuando se trabaja con modelos generativos, ya que dichos modelos no buscan únicamente estimar una media o una matriz de covarianzas, sino aproximar la distribución subyacente de los datos.

Desde esta perspectiva, conceptos como la entropía, la divergencia de Kullback-Leibler y la información mutua permiten estudiar aspectos distintos del comportamiento de los activos financieros. La entropía mide el grado de incertidumbre de una variable aleatoria; la divergencia KL permite comparar dos distribuciones de probabilidad; y la información mutua permite cuantificar dependencias entre variables, incluyendo relaciones no lineales.

2.1.6. Entropía, divergencia KL e información mutua

Seguindo a Cover y Thomas (Cover y Thomas, 2006), la entropía de Shannon mide la incertidumbre asociada a una variable aleatoria discreta. Si se entiende el retorno de un activo como una variable aleatoria X , su entropía puede definirse como:

$$H(X) = - \sum_{i=1}^n p(x_i) \log(p(x_i)) \quad (2.2)$$

donde $H(X)$ representa la entropía de la variable aleatoria X y $p(x_i)$ es la probabilidad asociada al valor x_i . En términos intuitivos, una entropía elevada indica que la distribución está más dispersa y, por tanto, que existe mayor incertidumbre sobre el resultado de la variable. Por el contrario, una entropía baja indica que la probabilidad está más concentrada en ciertos valores, lo que implica menor incertidumbre.

El término $\log p(x_i)$ refleja la información asociada a cada evento. Dado que las probabilidades toman valores entre cero y uno, su logaritmo es negativo; por ello, la expresión incorpora un signo negativo para que la entropía sea una cantidad no negativa. Los eventos menos probables aportan una mayor cantidad de información cuando ocurren, lo que

permite interpretar la entropía como una medida agregada de incertidumbre.

Para medir la discrepancia entre dos distribuciones de probabilidad se emplea la divergencia de Kullback-Leibler, definida como:

$$D_{KL}(P \parallel Q) = \sum_{i=1}^n p(x_i) \log \left(\frac{p(x_i)}{q(x_i)} \right) \quad (2.3)$$

donde P y Q son dos distribuciones de probabilidad, $p(x_i)$ representa la probabilidad del valor x_i bajo la distribución P , y $q(x_i)$ representa la probabilidad del mismo valor bajo la distribución Q . La divergencia KL mide cuánta información se pierde cuando se utiliza la distribución Q para aproximar la distribución P .

En el contexto de este trabajo, esta medida resulta especialmente útil para comparar la distribución empírica de los retornos financieros con la distribución generada por un modelo generativo. Si la divergencia entre ambas distribuciones es reducida, puede interpretarse que los escenarios sintéticos generados reproducen de forma más fiel las propiedades estadísticas de los datos reales.

Otro concepto relevante es la información mutua, que permite medir la dependencia entre dos variables aleatorias. Se define como:

$$I(X; Y) = H(X) + H(Y) - H(X, Y) \quad (2.4)$$

donde $H(X)$ y $H(Y)$ representan las entropías marginales de las variables X e Y , y $H(X, Y)$ representa su entropía conjunta. La información mutua mide la reducción de incertidumbre sobre una variable al conocer la otra.

En el análisis financiero, la información mutua puede interpretarse como una medida de dependencia entre los retornos de distintos activos. A diferencia de la correlación, que mide únicamente relaciones lineales, la información mutua capta dependencias más generales, incluyendo relaciones no lineales. Por este motivo, puede resultar útil para complementar el análisis tradicional basado en matrices de covarianzas.

2.1.7. Inteligencia artificial, aprendizaje automático y aprendizaje profundo

La inteligencia artificial engloba un conjunto amplio de técnicas orientadas a desarrollar sistemas capaces de realizar tareas que requieren algún tipo de aprendizaje, razonamiento o adaptación. Dentro de este campo, el aprendizaje automático se centra en métodos que

permiten a los modelos aprender patrones a partir de datos, sin necesidad de programar explícitamente todas las reglas de decisión.

El aprendizaje profundo constituye una rama del aprendizaje automático basada en redes neuronales con múltiples capas. Su principal ventaja reside en la capacidad de aprender representaciones complejas y no lineales a partir de grandes volúmenes de datos. Esta característica resulta especialmente relevante en finanzas, donde los mercados presentan alta dimensionalidad, ruido, relaciones no lineales y cambios de régimen.

En este trabajo, el interés principal no se encuentra en utilizar modelos de aprendizaje profundo para predecir directamente el precio futuro de los activos, sino en emplearlos para modelar distribuciones de retornos y generar escenarios sintéticos. Esta diferencia es relevante: mientras que un modelo predictivo busca estimar un valor futuro concreto, un modelo generativo busca aprender la estructura estadística de los datos para producir nuevas muestras coherentes con la distribución observada.

2.1.8. Modelos generativos profundos

Los modelos generativos profundos son modelos de aprendizaje automático cuyo objetivo es aprender la distribución subyacente de los datos para generar nuevas observaciones con propiedades similares a las reales. En lugar de limitarse a predecir una etiqueta o un valor, estos modelos buscan capturar la estructura probabilística de los datos.

Este enfoque resulta especialmente útil en el análisis financiero, ya que permite trabajar con distribuciones complejas sin imponer de forma explícita supuestos paramétricos rígidos. En particular, los modelos generativos pueden ser útiles para representar colas pesadas, asimetrías, dependencias no lineales y escenarios de mercado que no aparecen de forma idéntica en el conjunto histórico, pero que son estadísticamente plausibles.

En el contexto de la optimización de carteras, los modelos generativos permiten desplazar el foco desde la estimación de parámetros concretos, como la media y la matriz de covarianzas, hacia la aproximación de la distribución completa de retornos. Una vez aprendida dicha distribución, es posible generar escenarios sintéticos sobre los que evaluar la robustez de distintas asignaciones de cartera.

2.1.9. Autoencoders Variacionales

Los Autoencoders Variacionales, introducidos por Kingma y Welling (Kingma y Welling, 2013), representan una extensión probabilística de los autoencoders tradicionales.

Mientras que un autoencoder convencional aprende una representación determinista de los datos en un espacio latente, un VAE aprende una distribución de probabilidad sobre dicho espacio latente, habitualmente parametrizada mediante una distribución normal multivariante.

La arquitectura de un VAE se compone de dos elementos principales: un codificador o encoder y un decodificador o decoder. El codificador transforma la entrada en los parámetros de una distribución latente, normalmente una media μ y una desviación típica σ . A partir de estos parámetros se obtiene una muestra latente z , que posteriormente es utilizada por el decodificador para reconstruir la entrada original.

Para permitir el entrenamiento mediante retropropagación, se emplea el truco de reparametrización. En lugar de muestrear directamente desde la distribución latente, el vector z se expresa como una transformación determinista de una variable aleatoria auxiliar:

$$z = \mu + \sigma \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I) \quad (2.5)$$

Desde una perspectiva financiera, esta estructura puede interpretarse como una forma de obtener una representación latente de los retornos, reduciendo la dimensionalidad del problema y tratando de capturar factores no observables que influyen en el comportamiento conjunto de los activos.

La función objetivo del VAE se conoce como ELBO, Evidence Lower Bound, y combina dos términos principales: un término de reconstrucción y un término de regularización basado en la divergencia de Kullback-Leibler. Puede expresarse como:

$$\mathcal{L}(\theta, \phi; x) = \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x | z)] - D_{KL}(q_\phi(z | x) \| p(z)) \quad (2.6)$$

El primer término mide la capacidad del modelo para reconstruir los datos observados a partir de las variables latentes. En el contexto de este trabajo, representa la capacidad del decodificador para reproducir la estructura esencial de los retornos financieros. El segundo término actúa como regularizador, forzando a que la distribución latente aprendida se mantenga próxima a una distribución prior, generalmente una normal estándar. Esto favorece un espacio latente continuo y estructurado, facilitando la generación de nuevos escenarios coherentes.

En conjunto, el VAE permite aprender una representación comprimida y probabilística de los datos financieros. Esta representación puede ser útil para filtrar parte del ruido

presente en las series de retornos y conservar patrones latentes relevantes para la posterior generación de escenarios.

La Figura 2.2 resume el flujo del VAE. El codificador no produce un código único, sino los parámetros de una distribución; la reparametrización permite entrenar mediante gradientes y el decodificador devuelve una reconstrucción o, cuando se muestrea el prior, un escenario nuevo. El término KL aproxima el posterior al prior y hace viable ese muestreo.




Figura 2.2: Esquema conceptual del Autoencoder Variacional implementado. Fuente: elaboración propia.

2.1.10. Redes Generativas Adversarias y Wasserstein GAN

Las Redes Generativas Adversarias, introducidas por (Goodfellow y cols., 2014), introducen un marco de aprendizaje generativo basado en la interacción entre dos redes neuronales: un generador y un discriminador. El generador transforma un vector de ruido en una muestra sintética, mientras que el discriminador intenta distinguir entre muestras reales y muestras generadas.

El entrenamiento se formula como un juego adversarial. El generador trata de producir muestras cada vez más realistas, mientras que el discriminador mejora su capacidad para identificar si una observación procede de los datos reales o del modelo generativo. Esta interacción se expresa mediante una función objetivo minimax:

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log (1 - D(G(z)))] \quad (2.7)$$

En el contexto financiero, el generador puede interpretarse como un modelo capaz de producir escenarios sintéticos de retornos, mientras que el discriminador evalúa si dichos escenarios son estadísticamente distinguibles de los retornos históricos. La principal ventaja de este enfoque es que no requiere especificar explícitamente una distribución paramétrica para los datos, sino que aprende directamente a partir de las observaciones.

Las GANs resultan atractivas para la optimización de carteras porque pueden capturar características de la distribución que no quedan recogidas por la media y la covarianza, como asimetrías, curtosis o dependencias no lineales. Sin embargo, su entrenamiento puede

ser inestable y presentar problemas como el *mode collapse*, situación en la que el generador produce una variedad limitada de muestras.

Como respuesta a estas limitaciones, las Wasserstein GAN introducen una formulación alternativa basada en la distancia de Wasserstein entre distribuciones (Arjovsky, Chintala, y Bottou, 2017). Esta aproximación mejora la estabilidad del entrenamiento y proporciona una señal de optimización más informativa cuando la distribución generada todavía se encuentra lejos de la distribución real. Por este motivo, las WGAN constituyen una extensión relevante dentro del modelado generativo aplicado a datos financieros.

2.1.11. Modelos de difusión

Los modelos de difusión constituyen una familia reciente de modelos generativos basados en la idea de añadir ruido de forma progresiva a los datos hasta transformar la distribución original en una distribución simple, habitualmente ruido gaussiano. Posteriormente, el modelo aprende el proceso inverso, es decir, cómo eliminar gradualmente el ruido para reconstruir muestras coherentes con la distribución original.

En términos generales, el proceso se divide en dos fases. En la fase directa, los datos se degradan progresivamente mediante la adición de ruido. En la fase inversa, una red neuronal aprende a revertir ese proceso, generando nuevas observaciones a partir de ruido inicial. Esta formulación permite obtener muestras diversas y estables, lo que ha hecho que los modelos de difusión se hayan convertido en una línea destacada dentro del modelado generativo.

Aplicados al ámbito financiero, estos modelos pueden utilizarse para generar trayectorias sintéticas. En este trabajo se incluyen por su relevancia reciente, mientras la arquitectura experimental se limita al VAE. La referencia VAE-GAN corresponde a la inspiración conceptual y no a un modelo adversario entrenado.

2.2. Estado del arte

En este capítulo se revisan los principales trabajos y líneas de investigación relacionados con la optimización de carteras y el uso de modelos de aprendizaje automático y modelado generativo en finanzas. A diferencia del marco teórico, cuyo objetivo es presentar los conceptos fundamentales, el estado del arte se centra en identificar qué enfoques han sido propuestos previamente, qué limitaciones presentan y en qué punto se sitúa la

contribución planteada en este trabajo.

2.2.1. Optimización clásica de carteras

La optimización clásica de carteras tiene como punto de partida el trabajo de Markowitz, quien introduce el modelo de media-varianza como una formulación matemática para la selección de carteras de inversión (Markowitz, 1952). La aportación fundamental de este enfoque consiste en establecer que la elección de activos no debe basarse únicamente en la maximización del retorno esperado, sino también en el control del riesgo asociado a la cartera.

El modelo de Markowitz permite obtener combinaciones eficientes de activos a partir de la relación entre rentabilidad esperada y varianza. En este marco, una cartera será preferible si, para un determinado nivel de riesgo, ofrece una mayor rentabilidad esperada, o si, para una rentabilidad esperada dada, presenta una menor varianza. Esta idea da lugar al concepto de frontera eficiente, que constituye uno de los fundamentos de la teoría moderna de carteras.

No obstante, aunque el modelo de media-varianza continúa siendo una referencia esencial en la literatura financiera, presenta limitaciones relevantes. En particular, resume el comportamiento de los activos mediante momentos de primer y segundo orden, es decir, medias, varianzas y covarianzas. Esta simplificación puede resultar insuficiente cuando los retornos financieros presentan colas pesadas, asimetrías, volatilidad cambiante o dependencias no lineales.

Estas limitaciones han motivado el desarrollo de enfoques alternativos, tanto desde la estadística financiera tradicional como desde el aprendizaje automático. En este trabajo, el modelo de Markowitz se considera como referencia clásica frente a la cual comparar la metodología basada en escenarios sintéticos generados mediante modelos profundos.

2.2.2. Aprendizaje automático y deep learning en gestión de carteras

El aprendizaje automático ha introducido nuevas aproximaciones para el análisis de datos financieros, especialmente en contextos donde las relaciones entre variables son complejas, no lineales y difíciles de modelar mediante técnicas paramétricas tradicionales. En el ámbito de la gestión de carteras, estas técnicas se han aplicado principalmente a la predicción de precios, la estimación de retornos, la clasificación de activos y la construcción de señales de inversión.

Sin embargo, una parte importante de estos enfoques se centra en predecir directamente la evolución futura de los precios o retornos. Esta estrategia presenta dificultades importantes, ya que los mercados financieros son sistemas altamente ruidosos y sensibles a cambios de régimen. Además, una predicción puntual de precios no equivale directamente a una decisión de inversión, sino que requiere una capa adicional de lógica para convertir dicha predicción en pesos de cartera.

En este contexto, el aprendizaje profundo aporta la capacidad de modelar relaciones no lineales y trabajar con datos de alta dimensionalidad. Las redes neuronales profundas permiten aprender representaciones complejas de los datos, lo que resulta especialmente relevante en finanzas, donde los activos pueden presentar relaciones dinámicas, dependencias no lineales y comportamientos distintos en función del régimen de mercado.

A pesar de ello, el enfoque de este trabajo no consiste en utilizar aprendizaje profundo para predecir directamente precios futuros, sino en emplearlo para modelar distribuciones de retornos y generar escenarios sintéticos. Esta distinción es relevante, ya que desplaza el problema desde la predicción puntual hacia la generación de posibles trayectorias o escenarios de mercado sobre los que evaluar la robustez de una cartera.

2.2.3. Modelos generativos para series financieras

Los modelos generativos han ganado relevancia en el análisis de series financieras debido a su capacidad para aprender distribuciones complejas directamente a partir de los datos. A diferencia de los modelos clásicos, que requieren especificar de forma explícita una distribución o una estructura paramétrica, los modelos generativos permiten aproximar la distribución subyacente y producir nuevas muestras con propiedades similares a las observadas.

En el caso de las series financieras, esta capacidad resulta especialmente útil porque los retornos de los activos presentan propiedades que no siempre quedan recogidas por modelos gaussianos o lineales. Entre estas propiedades se encuentran las colas pesadas, la asimetría, la dependencia temporal, el agrupamiento de volatilidad y los cambios en las correlaciones entre activos. Por este motivo, el modelado generativo constituye una línea de investigación relevante para la generación de escenarios financieros sintéticos.

Dentro de esta familia de modelos, las Redes Generativas Adversarias, propuestas originalmente por (Goodfellow y cols., 2014), han sido utilizadas para sintetizar series temporales financieras y reproducir propiedades estadísticas observadas en los mercados. En este

enfoque, el generador aprende a producir muestras sintéticas, mientras que el discriminador evalúa si dichas muestras proceden de la distribución real o de la distribución generada. Este procedimiento permite construir escenarios que no aparecen de forma idéntica en el conjunto histórico, pero que pueden resultar estadísticamente plausibles.

Los Autoencoders Variacionales también resultan relevantes en este contexto, ya que permiten aprender una representación latente y probabilística de los datos. En el caso de los retornos financieros, el espacio latente puede interpretarse como una representación comprimida de factores no observables que influyen en el comportamiento conjunto de los activos. Esta característica justifica su uso como componente previo o complementario en arquitecturas híbridas de generación de escenarios.

A partir de estas ideas, el planteamiento inicial se inspiró en una arquitectura VAE-GAN. Sin embargo, el desarrollo empírico alcanzado implementa el VAE y genera escenarios con su *decoder*. La combinación adversaria se mantiene como referencia para interpretar el título y como ampliación futura, no como resultado experimental.

2.2.4. Modelos de difusión para selección dinámica de carteras

En los últimos años, los modelos de difusión han adquirido una relevancia creciente dentro del modelado generativo. Estos modelos se basan en aprender un proceso inverso de eliminación de ruido, permitiendo generar nuevas observaciones a partir de una distribución inicial simple, normalmente ruido gaussiano. Su principal atractivo reside en la estabilidad del proceso generativo y en su capacidad para producir muestras diversas.

En el ámbito financiero, los modelos de difusión han comenzado a explorarse como herramientas para la generación de escenarios y la selección dinámica de carteras. En particular, Aghapour, Bayraktar y Yuan proponen el uso de modelos de difusión para abordar problemas de selección dinámica de carteras (Aghapour, Bayraktar, y Yuan, 2025). Este enfoque resulta relevante para el presente trabajo porque comparte la idea de utilizar modelos generativos para simular posibles escenarios de mercado y tomar decisiones de asignación de activos.

Según los resultados reportados por estos autores, los modelos de difusión pueden ofrecer resultados competitivos frente a índices de referencia como el S&P 500 y frente a carteras construidas mediante enfoques tradicionales de Markowitz. Esta línea de investigación es todavía reciente, pero muestra el potencial del modelado generativo para superar algunas de las limitaciones de los modelos clásicos, especialmente cuando se trabaja con

mercados dinámicos, dependencia temporal y cambios en la volatilidad.

Aunque el presente trabajo no implementa modelos de difusión, su inclusión permite situar el VAE ejecutado y la inspiración híbrida dentro de una tendencia más amplia de generación de escenarios.

2.3. Conclusiones

La revisión local se complementa con trabajos sobre aprendizaje profundo aplicado a carteras (Jiang, Xu, y Liang, 2017; Huang, Zhou, y Song, 2020; Zhang, Zohren, y Roberts, 2020), representación latente y generación (Opitz, 2017; Voronina, Romanko, Cao, Kwon, y Mendoza-Arriaga, 2025), y validación cuantitativa (Lopez de Prado, 2018; López de Prado, 2018; Rasekhschaffe, 2026). Estas referencias ayudan a situar decisiones del pipeline, pero no sustituyen la comparación empírica realizada sobre los datos del TFM.

2.3.1. Síntesis crítica y hueco de investigación

La revisión anterior permite identificar una evolución clara en las técnicas aplicadas a la optimización de carteras. En primer lugar, la teoría clásica de Markowitz establece una formulación matemática sólida basada en el equilibrio entre rentabilidad esperada y riesgo. Sin embargo, su dependencia de la media, la varianza y la matriz de covarianzas limita su capacidad para capturar distribuciones no gaussianas, colas pesadas y relaciones no lineales entre activos.

En segundo lugar, las técnicas de aprendizaje automático y aprendizaje profundo han ampliado las posibilidades de análisis financiero, permitiendo modelar relaciones más complejas a partir de datos históricos. No obstante, muchos de estos enfoques se han centrado en la predicción puntual de precios o retornos, lo que no resuelve directamente el problema de la construcción de carteras robustas bajo incertidumbre.

En tercer lugar, los modelos generativos ofrecen una alternativa especialmente adecuada para este contexto, ya que permiten aprender distribuciones de datos y generar escenarios sintéticos. Esta capacidad resulta útil para analizar la robustez de una cartera no solo bajo el escenario histórico observado, sino también bajo posibles escenarios generados que preserven propiedades estadísticas relevantes del mercado.

El hueco abordado se sitúa en la conexión entre generación de escenarios y optimización de carteras. La contribución empírica estudia un VAE aplicado a retornos del S&P 500 y

compara la cartera resultante con Markowitz y equiponderación. La extensión adversaria permitiría investigar posteriormente si mejora la fidelidad de colas y dependencias.

3. Objetivos concretos y metodología de trabajo

3.1. Objetivo general

El objetivo principal del trabajo es diseñar una metodología para la optimización de carteras basada en la generación de escenarios sintéticos mediante técnicas de inteligencia artificial.

En concreto, la metodología se orienta al análisis de retornos de 30 activos pertenecientes al S&P 500 y emplea un Autoencoder Variacional como modelo generativo ejecutado. El propósito es estudiar si los escenarios obtenidos desde su espacio latente pueden proporcionar una base alternativa para estimar los parámetros de una cartera. Las arquitecturas VAE-GAN y WGAN pertenecen al marco conceptual y a la prospectiva, no al experimento validado.

Para ello, se plantea comparar los resultados obtenidos mediante la metodología propuesta con carteras construidas a partir del modelo de media-varianza de Markowitz y con una cartera equiponderada. De este modo, se busca evaluar si el uso de modelos generativos puede aportar información adicional en el proceso de asignación de pesos, especialmente en contextos donde los retornos financieros presentan colas pesadas, asimetrías y dependencias no lineales.

3.2. Objetivos específicos

A continuación, se detallan los objetivos específicos que guiarán el desarrollo del trabajo:

- Revisar la teoría moderna de carteras y el modelo de media-varianza de Markowitz como base clásica de la optimización de carteras.
- Analizar las limitaciones de la varianza y de la matriz de covarianzas como medidas suficientes para representar el riesgo financiero.
- Estudiar conceptos relevantes de la teoría de la información, como la entropía, la divergencia de Kullback-Leibler y la información mutua, en relación con el análisis de distribuciones de retornos.

- Revisar los fundamentos de los modelos generativos profundos, especialmente VAE, GAN, WGAN y modelos de difusión.
- Construir un pipeline de adquisición de datos financieros de activos pertenecientes al S&P 500.
- Preprocesar los datos financieros para su uso posterior, incluyendo el tratamiento de precios ajustados, cálculo de log-retornos, limpieza de datos y normalización.
- Diseñar una arquitectura VAE para obtener una representación latente de la distribución de retornos financieros.
- Situar GAN, WGAN y modelos de difusión en el estado del arte, identificando su posible incorporación en futuras ampliaciones.
- Evaluar la calidad de los escenarios generados mediante métricas estadísticas e informacionales.
- Comparar las carteras obtenidas mediante la metodología propuesta con carteras construidas mediante el modelo de Markowitz, una cartera equiponderada y el índice S&P 500 como benchmark.

3.3. Metodología del trabajo

3.3.1. Alcance y delimitación del trabajo

Este trabajo tiene un carácter académico y experimental. No pretende ofrecer una recomendación de inversión ni una propuesta de asignación de capital a valores concretos. Tampoco busca predecir de forma puntual los precios futuros de determinados activos financieros. Su objetivo se centra en estudiar la generación de escenarios sintéticos de retornos y su posible utilización dentro de un proceso de optimización de carteras.

El ámbito de aplicación se limita a un conjunto de activos financieros pertenecientes al S&P 500. La selección final de activos dependerá de la disponibilidad, calidad y completitud de los datos históricos, así como de la capacidad de procesamiento disponible para entrenar los modelos propuestos.

Asimismo, el trabajo estará condicionado por la frecuencia temporal de los datos utilizados y por las decisiones adoptadas en el preprocesamiento, tales como el cálculo de

retornos, el tratamiento de valores ausentes, la normalización y la división entre conjuntos de entrenamiento y evaluación.

Los resultados obtenidos deberán interpretarse como evidencia experimental dentro del marco definido en este trabajo. En ningún caso deben entenderse como garantía de rendimiento futuro ni como recomendación financiera aplicable directamente a decisiones reales de inversión.

3.3.2. Justificación de la metodología CRISP-DM

CRISP-DM se adopta porque proporciona una estructura iterativa que conecta la pregunta de investigación con la evidencia producida en cada etapa. En un problema financiero no basta con entrenar una red neuronal: las conclusiones dependen de cómo se seleccionan los activos, cómo se alinean las fechas, qué transformaciones se aplican y de qué manera se separa la información disponible de la evaluación futura. La metodología obliga a hacer explícitas estas decisiones y facilita volver a fases anteriores cuando el EDA o la evaluación revelan limitaciones.

Esta adopción sigue el modelo de proceso independiente del sector y de la tecnología descrito por (Wirth y Hipp, 2000).

Su carácter independiente de una herramienta concreta también resulta adecuado para este trabajo. La adquisición se realiza con `yfinance`, la preparación con `pandas` y `scikit-learn`, el modelado con `PyTorch` y la optimización con `SciPy`; CRISP-DM permite describir el proceso por objetivos y evidencias, no por librerías. Las fases se materializan en scripts, CSV, figuras y un modelo guardado, de modo que la memoria puede vincular cada afirmación empírica con un artefacto verificable.

Aunque CRISP-DM suele representarse de forma secuencial, aquí se entiende como ciclo. El análisis de los escenarios, por ejemplo, puede conducir a revisar el peso de la regularización o la dimensión latente; del mismo modo, una cartera excesivamente concentrada puede motivar nuevas restricciones. Esta posibilidad de retroalimentación es coherente con el carácter experimental del TFM.

3.3.3. Adaptación de CRISP-DM al presente trabajo

Comprensión del problema

La primera fase delimita la decisión que se quiere apoyar. El objetivo no es adivinar el precio de cada acción, sino construir una distribución de posibles retornos conjuntos que permita estimar medias y covarianzas alternativas. El punto de comparación es la sensibilidad de Markowitz a dichos parámetros. Por ello se definen tres referencias: equiponderación, Markowitz con posiciones largas y Markowitz con límite del 20 % por activo.

Esta fase también fija los criterios de éxito y de prudencia. Una estrategia se evalúa mediante retorno acumulado y anualizado, volatilidad, Sharpe y máximo *drawdown*; ninguna métrica aislada basta para afirmar superioridad. Además, se establece que los pesos deben obtenerse sin consultar el conjunto de test y que el resultado no tiene finalidad de asesoramiento financiero. El Capítulo 5 traduce estas decisiones en funciones de optimización y un protocolo común.

Comprensión de los datos

La segunda fase examina la cobertura y la estructura estadística antes de modelar. El conjunto final contiene 2.766 sesiones por 30 activos entre enero de 2014 y diciembre de 2024. Se analizan valores ausentes, duplicados, estadísticos descriptivos, asimetría, curtosis, volatilidad móvil y correlaciones. Los cinco CSV y siete figuras generados por `generate_eda_outputs.py` constituyen la evidencia reproducible de esta fase.

El EDA permite comprobar que la matriz final no contiene ausencias y que los retornos presentan valores extremos, curtosis positiva y dependencia transversal. Estos hallazgos justifican estudiar un modelo multivariante flexible, pero no anticipan que vaya a mejorar la cartera. La interpretación detallada se reserva para la Sección 5.1.

Preparación de los datos

Los cierres ajustados se ordenan cronológicamente y se filtran con un umbral máximo de ausencias del 5 %. Los huecos puntuales se propagan hacia delante y después se calculan log-retornos. La transformación elimina la primera fila indefinida y produce una matriz fecha-activo alineada. Se trabaja con retornos, en lugar de precios, para reducir la dependencia del nivel nominal y comparar movimientos relativos.

La división es temporal: las primeras 2.212 observaciones forman entrenamiento y

las 554 finales, test. El escalador Min–Max se ajusta exclusivamente con entrenamiento y transforma ambos subconjuntos a $[-1, 1]$. Guardar el escalador permite deshacer la transformación de los escenarios. Este orden evita que mínimos, máximos o retornos del periodo de evaluación influyan en el entrenamiento.

Modelado

La implementación principal es un VAE con entrada de 30 variables, dos capas ocultas de 64 unidades, espacio latente de dimensión ocho y salida Tanh. Se entrena con Adam durante 150 épocas, lotes de 64 y una pérdida formada por MSE más 0,001 veces la divergencia KL. La semilla 42 favorece la repetibilidad.

Para responder al requisito de comparación se ejecuta además un experimento homogéneo de 120 épocas: autoencoder determinista con latente ocho, VAE base con latente ocho y VAE con latente cuatro. Los tres usan el mismo *split*, capas ocultas, tasa de aprendizaje y semilla. La comparación distingue reconstrucción y calidad estadística de las muestras; no confunde estas métricas con el rendimiento de cartera.

Evaluación

La evaluación se organiza en tres niveles. En reconstrucción se calculan MSE y MAE para entrenamiento y test. En generación se comparan errores absolutos de medias y volatilidades, y el error medio de las matrices de correlación. Finalmente, las estrategias se comparan sobre los mismos retornos reales de test mediante las cinco métricas financieras definidas previamente.

La separación de niveles es necesaria porque un autoencoder puede reconstruir bien sin generar muestras útiles, mientras un modelo más regularizado puede perder precisión puntual y producir un espacio latente más muestreable. Del mismo modo, una mayor rentabilidad puede venir acompañada de volatilidad y caída superiores. La discusión del Capítulo 5 conserva estas tensiones.

Despliegue y reproducibilidad

En este trabajo el despliegue no consiste en publicar un servicio de inversión, sino en dejar un pipeline repetible. Los scripts se organizan por datos, análisis, modelos, optimización y evaluación. Las entradas y salidas se almacenan en rutas explícitas; los resultados

numéricos quedan en CSV y las visualizaciones en PNG. `requirements.txt` documenta las dependencias y las semillas se fijan cuando existe aleatoriedad.

La trazabilidad permite reconstruir la cadena desde `sp500_prices_adj_close.csv` hasta `benchmark_comparison.csv`. También se conservan el *checkpoint* del VAE, el escalador, las reconstrucciones y los escenarios. El Capítulo 6 describe el orden de ejecución y las limitaciones para reproducir exactamente una descarga futura de un proveedor externo.

Fase CRISP-DM	Aplicación en el TFM	Evidencia generada
Comprensión del problema	Pregunta, benchmarks y métricas	Formulación y restricciones
Comprensión de los datos	Cobertura, calidad y EDA	Cinco CSV y siete figuras
Preparación de datos	Retornos, corte temporal y escalado	Ficheros train/test y escalador
Modelado	AE, VAE y escenarios	Modelos, pérdidas y CSV comparativo
Evaluación	Calidad estadística y carteras	Métricas y gráficos
Reproducibilidad	Encadenamiento de scripts	Repositorio y artefactos

Tabla 3.1: Adaptación de CRISP-DM al desarrollo experimental del trabajo. Fuente: elaboración propia.

3.3.4. Visión general y secuencia experimental

El diseño completo encadena adquisición, retornos, EDA, partición, escalado, entrenamiento, generación, estimación sintética, optimización y evaluación. Las decisiones de cartera se toman con entrenamiento histórico o escenarios derivados de él; test solo se utiliza al final. Este diseño ofrece una comparación fuera de muestra coherente, aunque un único corte no sustituye una validación *walk-forward*.

Esta sección conserva y documenta el diseño metodológico amplio considerado al inicio del trabajo. Es importante distinguir ese diseño de la ejecución finalmente validada: la componente implementada es el VAE y los escenarios se obtienen muestreando su espacio latente y aplicando el *decoder*. La integración GAN/WGAN descrita en algunos apartados siguientes representa la arquitectura inicialmente estudiada y una extensión futura; no se entrenó un generador ni un discriminador en los resultados de esta memoria. La divergencia KL se utiliza en la pérdida del VAE, no como objetivo del optimizador de cartera.

3.3.5. Diseño general del experimento

Se pretende construir un flujo completo, desde la adquisición de datos hasta la validación de los resultados de los modelos, pasando por la generación de escenarios sintéticos.

En primer lugar, se realizará la adquisición de datos históricos de retornos de activos del S&P 500 mediante la herramienta *yfinance*. Empleando Python, se llevará a cabo el preprocesamiento de los datos para alimentar el entrenamiento del modelo VAE, con el objetivo de extraer una representación latente subyacente a la distribución de los retornos observados.

A continuación, el diseño original contemplaba entrenar una GAN/WGAN. Esa fase quedó fuera de la ejecución: el pipeline real muestrea $z \sim \mathcal{N}(0, I)$ y decodifica 5.000 observaciones con el VAE. Con esos escenarios se asignan los pesos y se comparan con Markowitz, Markowitz restringido y equiponderación sobre un test real común.

3.3.6. Adquisición de datos

Una parte fundamental del experimento propuesto es la adquisición de datos reales que permitan llevar a cabo un estudio relevante.

Empleando la herramienta *yfinance*, se creará un pipeline de datos para adquirir series históricas de los últimos 10 años de los principales activos del S&P 500.

Se emplearán estos datos por su relevancia. El mercado estadounidense es uno de los más importantes en cuanto a capitalización de mercado. Este índice agrupa a las 500 mayores empresas de Estados Unidos por capitalización bursátil y constituye una referencia ampliamente utilizada en el análisis financiero. Por su diversificación y representatividad, se ha considerado como el mejor escenario para poner en práctica la metodología planteada para la optimización de carteras.

Asimismo, se procurará establecer la trazabilidad de los datos, con el fin de asegurar que proceden de fuentes confiables y que el proceso de adquisición sea reproducible.

3.3.7. Preprocesamiento de los datos

Tras la adquisición de los datos, se llevarán a cabo las transformaciones necesarias para poder desarrollar los objetivos del trabajo. Este preprocesamiento permitirá adaptar las series históricas al formato requerido por los modelos generativos y por el proceso posterior de optimización.

En primer lugar, se trabajará con precios ajustados, de forma que se tengan en cuenta eventos corporativos como dividendos o desdoblamientos de acciones. A partir de estas series se calcularán los retornos financieros, que constituirán la entrada principal del modelo. Se llevará a cabo un tratamiento de valores ausentes, eliminando activos que presenten demasiados nulos, alineando fechas comunes y realizando interpolación únicamente cuando esté justificado.

Para el preprocesado se aplicó normalización Min-Max al rango $[-1, 1]$, ajustada únicamente con entrenamiento. No se aplicó un recorte general de valores extremos, porque estos contienen información financiera relevante. Los parámetros se guardaron para desnormalizar los escenarios generados por el VAE.

Asimismo, se realizarán las transformaciones adicionales que sean necesarias para garantizar que los datos puedan ser utilizados de forma adecuada dentro del pipeline experimental. A priori, se pretende realizar una división temporal de los datos, separando los conjuntos de entrenamiento y validación.

3.3.8. Arquitectura VAE-GAN considerada en el diseño inicial

Una vez extraídos y preprocesados los datos, se elaborará una estructura en línea con lo expuesto en los apartados previos.

La arquitectura propuesta para el modelo se articula en tres módulos principales:

- Extracción de características con Autoencoders Variacionales (VAEs) para la reducción de la dimensionalidad de forma no lineal. El VAE proyecta los datos históricos hacia un espacio latente de menor dimensión. Este proceso permite reducir parte del ruido, reteniendo las características persistentes de los datos.
- Generación adversaria considerada como extensión. Una GAN podría entrenarse sobre el espacio latente, pero esta etapa no forma parte del experimento ejecutado.
- Optimización de la cartera mediante el uso de medidas informacionales, como la Divergencia de Kullback-Leibler, como criterio complementario al análisis clásico del riesgo. De este modo, se plantea evaluar la robustez de la cartera frente a escenarios generados por el modelo.

De manera intuitiva, el diseño híbrido buscaba usar el VAE para estructurar el latente y una GAN para refinar muestras. En la implementación disponible, el primer componente

se conserva y la generación se realiza directamente con el *decoder*; la utilidad de añadir una GAN permanece como hipótesis futura.

El mercado financiero presenta una gran cantidad de variables interconectadas de formas que van más allá de la linealidad. Por ello, el VAE se utiliza para aproximar un espacio latente en el que se representen relaciones subyacentes entre los activos. Este planteamiento resulta adecuado frente a métodos estrictamente lineales como el PCA, dado que los mercados financieros no presentan necesariamente una estructura lineal.

El espacio latente Z representa, por tanto, una codificación comprimida de la información relevante contenida en los datos de entrada.




Figura 3.1: Arquitectura híbrida VAE-GAN considerada inicialmente y no implementada de forma completa. Fuente: elaboración propia.

Fuente: elaboración propia.

La Figura 3.1 representa el diseño conceptual original: VAE, generador y discriminador. Se incluye para mostrar la evolución del planteamiento, no como diagrama del software ejecutado. El pipeline validado termina en el *decoder* del VAE antes de pasar a la estimación estadística y la optimización.

3.3.9. Generación de escenarios sintéticos

Una vez entrenado el VAE se obtiene un espacio latente Z . En la ejecución real se muestrea directamente la normal estándar y se decodifica. El uso posterior de GAN/WGAN sobre dicho espacio es una posible ampliación y no se le atribuyen métricas en esta memoria.

Cada una de estas muestras sintéticas representa un escenario plausible de mercado. Estos escenarios no deben interpretarse como predicciones exactas del futuro, sino como simulaciones generadas a partir de la distribución aprendida por el modelo. De este modo, se amplía el conjunto de situaciones bajo las cuales puede evaluarse la cartera construida.

La utilidad de estos escenarios depende de su capacidad para preservar propiedades estadísticas relevantes de los datos reales. Por ello, se evaluará si los escenarios generados conservan, de forma aproximada, características como la media de los retornos, la volatilidad, la estructura de correlaciones, la presencia de colas pesadas, posibles asimetrías y dependencias no lineales entre activos.

Esta evaluación resulta necesaria para evitar que la optimización posterior se base en escenarios artificiales que no representen adecuadamente el comportamiento observado en los mercados financieros. En consecuencia, la generación de escenarios sintéticos no constituye un fin en sí mismo, sino una etapa intermedia orientada a mejorar la evaluación y selección de carteras bajo incertidumbre.

3.3.10. Función de pérdida y criterios de optimización

La metodología ejecutada combina dos niveles: entrenamiento variacional del VAE y optimización financiera sobre parámetros sintéticos. Un tercer nivel adversario estaba previsto en el diseño, pero no fue implementado. Esta separación evita confundir la pérdida de la red con la función de máximo Sharpe empleada para los pesos.

Siguiendo el enfoque propuesto por (Kingma y Welling, 2013), el objetivo del modelo VAE es maximizar la verosimilitud marginal de los datos observados. Dado un conjunto de datos $\{x^{(i)}\}_{i=1}^N$, la verosimilitud marginal se descompone como la suma sobre las observaciones individuales:

$$\log p_{\theta}(x^{(1)}, \dots, x^{(N)}) = \sum_{i=1}^N \log p_{\theta}(x^{(i)}) \quad (3.1)$$

Sin embargo, el cálculo directo de $\log p_{\theta}(x^{(i)})$ resulta intratable debido a la integración sobre las variables latentes. Para abordar este problema, se introduce una distribución aproximada $q_{\phi}(z|x)$, lo que permite descomponer la log-verosimilitud como:

$$\log p_{\theta}(x^{(i)}) = D_{KL} \left(q_{\phi}(z|x^{(i)}) \parallel p_{\theta}(z|x^{(i)}) \right) + \mathcal{L}(\theta, \phi; x^{(i)}) \quad (3.2)$$

Dado que la divergencia de Kullback–Leibler es siempre no negativa, la función variacional constituye una cota inferior, conocida como ELBO (*Evidence Lower Bound*):

$$\log p_{\theta}(x^{(i)}) \geq \mathcal{L}(\theta, \phi; x^{(i)}) \quad (3.3)$$

Esta cota puede expresarse como:

$$\mathcal{L}(\theta, \phi; x^{(i)}) = \mathbb{E}_{q_\phi(z|x^{(i)})} \left[\log p_\theta(x^{(i)}, z) - \log q_\phi(z|x^{(i)}) \right] \quad (3.4)$$

o, de forma equivalente, separando sus componentes principales:

$$\mathcal{L}(\theta, \phi; x^{(i)}) = -D_{KL} \left(q_\phi(z|x^{(i)}) \parallel p(z) \right) + \mathbb{E}_{q_\phi(z|x^{(i)})} \left[\log p_\theta(x^{(i)}|z) \right] \quad (3.5)$$

Esta formulación revela dos términos fundamentales:

- Un término de regularización, que fuerza la distribución latente aproximada $q_\phi(z|x)$ a mantenerse cercana a la probabilidad a priori $p(z)$.
- Un término de reconstrucción, que mide la capacidad del modelo generativo para reproducir los datos observados a partir de las variables latentes.

El proceso de entrenamiento consiste en maximizar esta cota inferior respecto a los parámetros del modelo generativo θ y los parámetros variacionales ϕ .

No obstante, la optimización presenta dificultades prácticas. En particular, el cálculo del gradiente respecto a ϕ mediante estimadores Monte Carlo directos presenta alta varianza, lo que dificulta la convergencia. Para superar esta limitación, se introduce el truco de reparametrización, que permite expresar la variable latente como una transformación determinista de una variable aleatoria auxiliar:

$$z = \mu_\phi(x) + \sigma_\phi(x)\epsilon, \quad \epsilon \sim \mathcal{N}(0, I) \quad (3.6)$$

Esta reformulación permite trasladar la fuente de aleatoriedad fuera de la red neuronal, haciendo posible aplicar técnicas estándar de optimización basadas en gradiente (*backpropagation*) con estimadores de baja varianza.

Como fundamento de la ampliación futura, una componente GAN/WGAN se entrenaría mediante un criterio adversarial. En una GAN estándar se entrenarían simultáneamente un generador G y un discriminador D . Esta formulación se conserva como marco metodológico teórico y no describe una ejecución realizada:

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}} [\log D(x)] + \mathbb{E}_{z \sim p_z} [\log (1 - D(G(z)))] \quad (3.7)$$

En el caso de utilizar una WGAN, el criterio adversarial se reformula en términos de distancia de Wasserstein entre la distribución real y la distribución generada. Esta modificación permite obtener una señal de entrenamiento más estable, especialmente cuando

ambas distribuciones se encuentran inicialmente alejadas. Por este motivo, la variante WGAN resulta especialmente relevante en contextos financieros, donde la distribución de retornos puede presentar colas pesadas, asimetrías y elevada variabilidad.

Finalmente, los escenarios sintéticos generados se emplean como entrada para el proceso de optimización de carteras. A partir de dichos escenarios se estimarán magnitudes como el retorno esperado generado $\hat{\mu}_{gen}$ y la matriz de covarianzas generada $\hat{\Sigma}_{gen}$. Una posible formulación del problema de optimización es:

$$\max_w \left\{ w^\top \hat{\mu}_{gen} - \frac{\lambda}{2} w^\top \hat{\Sigma}_{gen} w \right\} \quad \text{s.a.} \quad \mathbf{1}^\top w = 1 \quad (3.8)$$

donde w representa el vector de pesos de la cartera, $\hat{\mu}_{gen}$ el vector de retornos esperados estimado a partir de los escenarios generados, $\hat{\Sigma}_{gen}$ la matriz de varianzas-covarianzas estimada a partir de dichos escenarios y λ el parámetro de aversión al riesgo.

Esta formulación permite conectar la generación de escenarios sintéticos con la optimización de carteras. En lugar de estimar los parámetros únicamente a partir de la muestra histórica observada, se plantea utilizar la distribución generada por el modelo como base adicional para evaluar la robustez de distintas asignaciones de pesos.

3.3.11. Optimización y selección de pesos

En este apartado se describe cómo se obtiene la cartera resultante a partir de los escenarios sintéticos generados. Tras la generación de dichos escenarios, se procede a la fase de optimización y selección de pesos de la cartera.

A partir de los escenarios sintéticos se obtiene una matriz de retornos simulados. Empleando esta matriz, se podrán estimar magnitudes relevantes para la construcción de la cartera, como el retorno esperado, la matriz de covarianzas, la volatilidad y la distribución de pérdidas y ganancias.

La variable principal a optimizar es el vector de pesos:

$$w = (w_1, w_2, \dots, w_n) \quad (3.9)$$

donde w_i representa la proporción de la cartera asignada al activo i . Para simplificar la selección de pesos y mantener una interpretación conservadora del problema, se impondrán las siguientes condiciones:

- No se permiten posiciones cortas, por lo que $w_i \geq 0$ para todo i .

- La suma de los pesos debe ser igual a 1, es decir, $\sum_{i=1}^n w_i = 1$. Esto garantiza que la cartera esté completamente invertida y no se utilice apalancamiento.

El criterio empleado parte de la formulación de Markowitz, pero estimada sobre los escenarios generados:

$$\max_w w^\top \hat{\mu}_{gen} - \frac{\lambda}{2} w^\top \hat{\Sigma}_{gen} w \quad \text{s.a.} \quad \sum_{i=1}^n w_i = 1, \quad w_i \geq 0 \quad (3.10)$$

La principal diferencia con el método clásico radica en la fuente de los parámetros, no en la estructura general del criterio de selección de pesos. En el modelo clásico, la media y la matriz de covarianzas se estiman directamente a partir de los datos históricos observados. En la metodología propuesta, en cambio, dichas magnitudes se estiman a partir de los escenarios sintéticos generados por el modelo.

De este modo, la asignación de pesos obtenida no depende exclusivamente de la muestra histórica original, sino también de una distribución generada que busca preservar ciertas propiedades estadísticas relevantes del mercado. La cartera resultante debe interpretarse, por tanto, como la asignación obtenida bajo el criterio de optimización definido y no como una cartera óptima en términos absolutos.

3.3.12. Benchmarks de comparación

Para evaluar la metodología propuesta, los resultados obtenidos se compararán con estrategias de referencia ampliamente utilizadas en optimización de carteras.

En primer lugar, se comparan los resultados con el modelo de Markowitz. La diferencia radica en el origen de los parámetros: el modelo clásico usa entrenamiento histórico y la propuesta usa escenarios generados por el VAE implementado.

En segundo lugar, se considerará una cartera equiponderada, en la que todos los activos reciben el mismo peso. Esta estrategia simplifica el problema de selección de pesos y no requiere estimar retornos esperados ni matrices de covarianzas. Frente a ella, se evaluará si el empleo de una metodología más compleja aporta valor adicional en términos de rentabilidad y riesgo.

Finalmente, se utilizará el índice S&P 500 como referencia de mercado. Esto permitirá evaluar si la cartera construida mediante la metodología propuesta mejora o complementa el comportamiento agregado del mercado durante el periodo de evaluación.

En cuanto a las métricas de evaluación, se considerarán las siguientes:

- Retorno acumulado: se utilizará para evaluar el rendimiento total durante el periodo de evaluación.
- Retorno anualizado: permitirá comparar rentabilidades en términos homogéneos.
- Volatilidad anualizada: servirá como medida de riesgo, evaluando la variabilidad de los retornos.
- Ratio de Sharpe: medirá la rentabilidad ajustada por riesgo.
- Máximo drawdown: medirá la mayor caída desde un máximo hasta un mínimo posterior, evaluando el riesgo extremo.
- Divergencia de Kullback-Leibler: se empleará para evaluar la distancia entre la distribución de retornos generada por el modelo y la distribución de retornos observada en los datos históricos.

La comparación permitirá evaluar dos aspectos principales: por un lado, si los escenarios generados son razonables a nivel estadístico; por otro, si la cartera resultante es capaz de mejorar o complementar los enfoques clásicos de optimización de carteras.

4. Marco normativo

El proyecto utiliza datos financieros públicos y modelos de inteligencia artificial con finalidad académica. El marco relevante comprende protección de datos, condiciones de uso de la fuente, propiedad intelectual, transparencia y comunicación responsable. La ausencia de una aplicación comercial no elimina la necesidad de documentar procedencia y limitaciones.

4.1. Identificación del tratamiento de datos

Los archivos contienen fechas, símbolos bursátiles, precios y retornos. No se tratan nombres, identificadores, perfiles ni decisiones de personas físicas identificadas o identificables. En consecuencia, el núcleo empírico no constituye un tratamiento de datos personales en el sentido habitual del RGPD. Esta afirmación se limita a los datasets del repositorio y no debe extenderse a credenciales, logs o datos de colaboradores que pudieran incorporarse en un despliegue futuro.

4.2. RGPD y Ley Orgánica 3/2018

El Reglamento General de Protección de Datos y la LOPDGDD establecen principios como minimización, limitación de finalidad y seguridad. Aunque los retornos corporativos utilizados no son datos personales, el proyecto adopta esos principios como buenas prácticas: solo almacena variables necesarias, separa credenciales del código y limita la finalidad a investigación y docencia.

El riesgo para derechos de personas es bajo porque no se procesan datos personales identificables. Se evita calificarlo como absolutamente nulo: repositorios, servicios externos o metadatos operativos pueden introducir información diferente si el sistema se amplía. Cualquier futura incorporación de perfiles de inversores exigiría una evaluación jurídica específica.

4.3. Fuente financiera y propiedad intelectual

Los precios se obtienen mediante `yfinance` desde Yahoo Finance. La reproducibilidad técnica de la consulta no equivale a otorgar derechos de redistribución ilimitada. El au-

tor debe revisar los términos vigentes del proveedor antes de publicar datasets brutos y distinguir los datos de terceros de los retornos y análisis derivados.

El código desarrollado puede identificarse como creación propia salvo librerías y fragmentos con licencias respectivas. El repositorio debe incluir licencia, atribuciones y referencias. Las figuras generadas a partir de datos propios se indican como elaboración propia; esta fórmula no elimina la obligación de reconocer la fuente de los precios.

4.4. Uso responsable de inteligencia artificial

Los modelos pueden producir resultados numéricamente precisos con una apariencia de objetividad que excede su validez. Por ello se documentan arquitectura, hiperparámetros, corte temporal y métricas, y se evita presentar una VAE-GAN que no fue entrenada. La transparencia sobre resultados negativos o limitaciones forma parte del uso responsable.

La selección de pesos procede de una función matemática y de parámetros estimados, no de una explicación causal de las empresas. La interpretabilidad es parcial: se pueden auditar escenarios y restricciones, pero no atribuir cada peso a una razón económica fundamental. Cualquier uso en decisión real requeriría supervisión experta y controles adicionales.

4.5. Carácter académico y no recomendación financiera

Las carteras se muestran para comparar métodos bajo datos históricos. No consideran la situación, objetivos o tolerancia al riesgo de una persona, ni costes y condiciones completas de negociación. En consecuencia, no constituyen asesoramiento, oferta o recomendación financiera. La memoria debe comunicar esta limitación junto a las cifras de rentabilidad, evitando que un resultado retrospectivo se interprete como expectativa garantizada.

4.6. Reproducibilidad y transparencia

El repositorio conserva scripts y artefactos que permiten auditar la cadena de cálculo. Se registran semillas y dependencias, y las tablas proceden de CSV. Esta trazabilidad favorece la revisión científica y reduce el riesgo de seleccionar únicamente resultados favorables. Aun así, reproducibilidad no equivale a validez externa: otra fuente, periodo o mercado puede producir conclusiones distintas.

5. Desarrollo específico de la contribución

5.1. Análisis exploratorio de datos

5.1.1. Descripción del dataset

El análisis parte de precios de cierre ajustados descargados de Yahoo Finance mediante `yfinance`. El universo contiene 30 acciones incluidas en el S&P 500 y abarca desde el 3 de enero de 2014 hasta el 30 de diciembre de 2024 una vez calculados los retornos. La matriz procesada contiene 2.766 filas y 30 columnas. Cada fila representa una sesión bursátil y cada columna el movimiento de un activo; por tanto, una observación del modelo es un vector conjunto de 30 retornos, no un dato aislado por empresa.

La frecuencia diaria ofrece un compromiso entre número de observaciones y ruido. Una frecuencia mensual reduciría mucho el tamaño muestral, mientras datos intradía exigirían tratar microestructura, horarios y volúmenes fuera del alcance. El periodo incluye fases de volatilidad y tendencias diferentes, pero sigue siendo una única realización histórica y no garantiza cobertura de todos los regímenes posibles.

5.1.2. Variables utilizadas

La variable original es el precio de cierre ajustado, que refleja los ajustes provistos por la fuente para dividendos y desdoblamientos. A partir de ella se calcula el log-retorno diario $r_{i,t} = \log(P_{i,t}/P_{i,t-1})$. Las variables derivadas del EDA incluyen media, desviación, cuantiles, extremos, asimetría, curtosis, correlaciones, rendimiento acumulado y volatilidad móvil anualizada.

La fecha actúa como índice y preserva el orden temporal; no se introduce como característica numérica del VAE. Tampoco se incorporan sectores, capitalización, volumen ni variables macroeconómicas, porque no forman parte de los archivos utilizados. Esta delimitación evita atribuir al modelo información que no recibió.

5.1.3. Valores perdidos y calidad de los datos

El preprocesamiento descarta activos cuya proporción de ausencias supere el 5% y aplica propagación hacia delante antes de calcular retornos. Después de alinear las series y eliminar la primera fila indefinida, los 30 activos conservados presentan cero valores ausen-

tes en las 2.766 observaciones. La Figura 5.1 muestra este resultado para cada columna.




Figura 5.1: Valores perdidos por activo en la matriz final de retornos. Fuente: elaboración propia a partir de los datos procesados.

La ausencia de huecos simplifica el entrenamiento por lotes, pero no implica ausencia de errores de proveedor ni sesgo de selección. Exigir series homogéneas favorece activos con cobertura completa. La fecha se conserva ordenada y los CSV no muestran filas parciales; además, las dimensiones se contrastan mediante `eda_dataset_shape.csv`.

5.1.4. Estadísticos descriptivos

La Tabla 5.1 resume cinco activos representativos; el detalle completo de los 30 queda en `eda_descriptive_statistics.csv`. Las medias diarias son pequeñas frente a las desviaciones, de modo que su estimación resulta ruidosa. NVDA presenta simultáneamente la mayor media y volatilidad de la selección, mientras XOM registra una media menor. Los extremos diarios superan ampliamente una desviación típica y anticipan colas relevantes.

Activo	Media	Desv. típica	Mínimo	Máximo
AAPL	0,000970	0,017584	-0,137708	0,113157
JPM	0,000618	0,016757	-0,162106	0,165620
MSFT	0,000946	0,016689	-0,159453	0,132929
NVDA	0,002136	0,029352	-0,207712	0,260877
XOM	0,000189	0,016983	-0,130391	0,119442

Tabla 5.1: Selección de estadísticos descriptivos de log-retornos diarios. Fuente: elaboración propia a partir de `eda_descriptive_statistics.csv`.

Estas diferencias importan para Markowitz porque la media y la covarianza determi-

nan la solución. También importan para el VAE: el escalado impide que los activos de mayor amplitud dominen automáticamente la pérdida, mientras la transformación inversa devuelve las muestras a sus unidades financieras.

5.1.5. Distribución de los retornos

La Figura 5.2 agrega los retornos y evidencia una concentración acusada alrededor de cero junto con colas más largas que las de una aproximación normal simple. La asimetría no tiene el mismo signo en todos los activos: AAPL registra $-0,212$, MSFT $-0,175$ y NVDA $0,225$. La curtosis es positiva y elevada: $5,72$ en AAPL, $8,18$ en MSFT y $13,78$ en JPM. Estos valores confirman que los episodios extremos no son marginales en la muestra.




Figura 5.2: Distribución agregada de los log-retornos diarios. Fuente: elaboración propia a partir de los datos procesados.

La distribución agregada debe leerse con cautela porque mezcla activos con escalas distintas. No obstante, junto con los estadísticos por columna muestra por qué MSE de reconstrucción no basta para evaluar escenarios: un modelo puede aproximar la zona central y suavizar las colas, reduciendo el error medio pero infravalorando eventos de riesgo.

5.1.6. Evolución temporal

La Figura 5.3 representa rendimientos acumulados de una muestra. Las trayectorias se separan de forma notable y alternan fases de crecimiento, corrección y recuperación. Esto subraya que la media del periodo completo oculta heterogeneidad temporal y que

una estrategia evaluada en el tramo final puede beneficiarse de un régimen concreto.




Figura 5.3: Evolución de los rendimientos acumulados en una muestra de activos. Fuente: elaboración propia.

El experimento respeta este orden: no aleatoriza filas antes del corte train/test. La decisión evita una fuga especialmente grave en series financieras, aunque no elimina cambios de régimen entre ambos subconjuntos.

5.1.7. Análisis de volatilidad

La volatilidad móvil anualizada de la Figura 5.4 cambia con el tiempo y presenta agrupamientos. Periodos tranquilos alternan con incrementos simultáneos en varios activos. La ventana móvil suaviza el ruido diario y permite observar persistencia, pero no se utiliza como entrada del VAE: sirve como diagnóstico de no estacionariedad.

Para Markowitz, la variación implica que una covarianza estimada sobre todo el entrenamiento puede no describir el test. Para el VAE, significa que una distribución latente global mezcla regímenes. Una extensión condicionada o entrenada con ventanas móviles podría abordar esta limitación.

5.1.8. Análisis de correlaciones

La matriz de la Figura 5.5 muestra dependencia positiva general, con intensidad desigual. Las correlaciones más altas registradas son MA-V (0,886), BAC-JPM (0,885), KO-PEP (0,730) y GOOGL-MSFT (0,703). Estos pares son coherentes con exposiciones




Figura 5.4: Volatilidad móvil anualizada en una muestra de activos. Fuente: elaboración propia.

económicas compartidas, aunque el trabajo no utiliza etiquetas sectoriales y no atribuye causalidad.

Preservar la correlación es esencial: si los escenarios rompen dependencias, la covarianza sintética puede exagerar la diversificación. Por ello la comparación multmodelo incorpora error medio absoluto de correlación y la evaluación VAE incluye matrices reales y sintéticas.

5.1.9. Conclusiones del análisis exploratorio

El EDA confirma una matriz completa y suficientemente amplia para un experimento multivariante, pero también exhibe colas, extremos, volatilidad cambiante y correlaciones relevantes. Estas propiedades justifican explorar un VAE porque no impone directamente normalidad multivariante en el espacio observado. Sin embargo, no garantizan que las muestras latentes preserven todos los hechos estilizados.

La consecuencia metodológica es doble. Primero, deben separarse reconstrucción y calidad generativa. Segundo, la utilidad final debe medirse fuera de muestra y compararse con referencias simples. El análisis exploratorio establece así las preguntas que guían las secciones posteriores, sin presentar todavía una conclusión sobre la estrategia de cartera.

En este capítulo se describe el desarrollo técnico de la contribución propuesta. En particular, se expone el diseño e implementación de un pipeline experimental orientado a generar escenarios sintéticos de retornos financieros y utilizarlos posteriormente como entrada para un proceso de optimización de carteras. El objetivo no es sustituir los modelos




Figura 5.5: Matriz de correlaciones de los retornos. Fuente: elaboración propia a partir de los datos procesados.

clásicos de optimización, sino analizar si la incorporación de escenarios generados mediante modelos de aprendizaje profundo puede aportar información adicional respecto al uso exclusivo de datos históricos.

5.2. Diseño del pipeline experimental

La fase de optimización se apoya en los fundamentos de la teoría moderna de carteras introducida por (Markowitz, 1952). Por tanto, la innovación principal del trabajo no se sitúa en la sustitución del marco media-varianza, sino en la etapa previa de generación de escenarios. En lugar de estimar únicamente medias y covarianzas a partir de los retornos históricos observados, se introduce un modelo generativo capaz de aprender una representación latente de dichos retornos y producir escenarios sintéticos que posteriormente alimentan la optimización.

Con este propósito, se ha diseñado un pipeline experimental modular y reproducible. El flujo parte de la adquisición de precios históricos diarios para un subconjunto de activos del S&P 500 durante el periodo 2014–2024. A partir de estos precios ajustados se calculan retornos logarítmicos, se realiza una división temporal entre datos de entrenamiento y datos de test, y se aplican transformaciones de escalado necesarias para el entrenamiento del modelo generativo.

En una primera fase, se implementan varios modelos de referencia con los que comparar la propuesta: una cartera equiponderada, una cartera de Markowitz clásica y una variante de Markowitz con restricción de peso máximo por activo. Esta última restricción se introduce para evitar concentraciones excesivas y favorecer una mayor diversificación de la cartera.

Posteriormente, se entrena un Autoencoder Variacional sobre los retornos escalados de entrenamiento. El modelo aprende una representación latente de la distribución histórica de retornos y permite generar nuevos escenarios mediante muestreo en dicho espacio latente y posterior decodificación. Estos escenarios sintéticos se transforman de nuevo a la escala original de retornos y se utilizan para estimar medias y covarianzas sintéticas.

Finalmente, se optimiza una cartera a partir de los escenarios generados y se evalúa su rendimiento sobre el conjunto de test real. Esta evaluación fuera de muestra permite comparar la estrategia propuesta frente a los benchmarks clásicos utilizando métricas homogéneas, como retorno acumulado, retorno anualizado, volatilidad anualizada, ratio

de Sharpe y máximo drawdown.

5.3. Selección del universo de activos

Dado el alcance del trabajo, se ha seleccionado un subconjunto inicial de 30 activos pertenecientes al S&P 500. Esta decisión experimental permite trabajar con un universo de inversión suficientemente amplio para observar efectos de diversificación, pero acotado en términos de dimensionalidad y coste computacional. De este modo, la primera implementación del pipeline se plantea como una aproximación controlada y reproducible, susceptible de ampliarse en trabajos posteriores a un universo de activos más extenso.

La utilización completa del conjunto de activos del S&P 500 incrementaría de forma significativa la dimensionalidad del problema, el coste de entrenamiento de los modelos generativos y la complejidad de la estimación de matrices de covarianza. Por ello, se ha optado por un subconjunto representativo de compañías líquidas y ampliamente negociadas. Esta decisión es coherente con otros trabajos aplicados de aprendizaje automático en optimización de carteras, donde el universo de activos suele acotarse para hacer viable la evaluación experimental (Zhang y cols., 2020).

5.4. Adquisición de datos financieros

El subconjunto de activos seleccionado está compuesto por 30 compañías pertenecientes al S&P 500: AAPL, MSFT, AMZN, GOOGL, META, NVDA, JPM, V, PG, UNH, HD, MA, DIS, BAC, XOM, KO, PEP, CSCO, PFE, MRK, WMT, ADBE, NFLX, CRM, INTC, T, VZ, CMCSA, NKE y ORCL.

Para obtener los datos de precios ajustados diarios correspondientes al periodo 2014–2024 se ha utilizado la librería `yfinance`, que permite descargar información financiera histórica desde Yahoo Finance. En concreto, se emplean precios ajustados de cierre (*Adjusted Close*), ya que incorporan el efecto de eventos corporativos como dividendos y desdoblamientos de acciones, proporcionando una base más adecuada para el cálculo de retornos.

La adquisición se implementa mediante `download_data.py`, disponible en el repositorio del proyecto¹. El script define universo, intervalo y salida. El resultado se almacena como CSV de precios ajustados, entrada de la preparación.

¹Repositorio del proyecto: <https://github.com/dmaching/tfm>.

5.5. Construcción del conjunto de retornos

Para comparar activos financieros, el modelo no trabaja directamente con los precios, ya que estos no son comparables entre sí en términos absolutos. Un activo puede cotizar a cientos de dólares y otro a unas pocas unidades monetarias, sin que esa diferencia implique necesariamente mayor rentabilidad o menor riesgo. Por este motivo, el análisis se realiza sobre retornos, que permiten medir la variación relativa del precio de cada activo entre dos instantes consecutivos.

En este trabajo se emplean retornos logarítmicos diarios, definidos como:

$$r_t = \log \left(\frac{P_t}{P_{t-1}} \right) \quad (5.1)$$

donde P_t representa el precio ajustado de cierre del activo en el día t , y P_{t-1} el precio ajustado de cierre del día anterior. El uso de precios ajustados permite incorporar el efecto de eventos corporativos como dividendos o desdoblamientos de acciones, evitando que dichos eventos distorsionen el cálculo de los retornos.

Los retornos logarítmicos presentan varias ventajas en este contexto. En primer lugar, expresan los cambios de precio en una escala relativa, lo que permite comparar activos con niveles de precio diferentes. En segundo lugar, tienen una interpretación conveniente desde el punto de vista temporal, ya que son aditivos en el tiempo. Además, constituyen una transformación habitual en el análisis de series financieras, puesto que permiten trabajar con variaciones de precio en lugar de precios absolutos.

La construcción del conjunto de retornos se implementa mediante `preprocess.py`. Este script carga los precios, ordena las observaciones, filtra activos por ausencias y calcula log-retornos. Ante valores no disponibles, propaga hacia delante antes del cálculo para mantener la alineación temporal.

Una vez calculados los retornos, el conjunto se divide temporalmente en datos de entrenamiento y datos de test. Esta división se realiza respetando el orden cronológico de las observaciones, de modo que la información futura no intervenga en el entrenamiento de los modelos. En concreto, el 80 % inicial de las observaciones se utiliza como conjunto de entrenamiento, mientras que el 20 % final se reserva para la evaluación fuera de muestra.

El conjunto de entrenamiento se emplea para estimar los parámetros de los modelos de referencia y para entrenar el Autoencoder Variacional. El conjunto de test se reserva exclusivamente para evaluar el rendimiento final de las carteras construidas. Esta separa-

ción resulta especialmente relevante en problemas financieros, ya que permite analizar si las estrategias obtenidas mantienen su comportamiento sobre datos no utilizados durante la fase de entrenamiento u optimización.

Adicionalmente, para el entrenamiento del VAE se genera una versión escalada de los retornos mediante normalización Min-Max en el intervalo $([-1,1])$. Este escalado se ajusta únicamente sobre el conjunto de entrenamiento y posteriormente se aplica al conjunto de test. De este modo, se evita introducir información del periodo de evaluación en la fase de entrenamiento. La versión escalada se utiliza como entrada del modelo generativo, mientras que las métricas financieras y la optimización de carteras se calculan sobre los retornos en su escala original.

Como resultado de este proceso, se obtiene una matriz de retornos diarios formada por 2766 observaciones y 30 activos. La división temporal genera 2212 observaciones para entrenamiento y 554 observaciones para test. Los resultados se almacenan en los archivos `returns.csv`, `returns_train.csv`, `returns_test.csv`, `returns_train_scaled.csv` y `returns_test_scaled.csv`. Asimismo, los parámetros del escalado se conservan en el archivo `minmax_scaler.pkl`, lo que permite aplicar posteriormente la transformación inversa a los escenarios sintéticos generados.

5.6. Implementación de modelos de referencia

Para evaluar la cartera construida mediante la metodología propuesta, se han implementado varias estrategias de referencia que permiten comparar los resultados obtenidos. La inclusión de estos modelos resulta necesaria para determinar si la generación de escenarios sintéticos aporta alguna mejora respecto a métodos más simples o respecto a una optimización basada exclusivamente en los retornos históricos. Esta forma de evaluación es habitual en los trabajos de aprendizaje automático aplicado a la gestión de carteras, en los que el modelo propuesto se compara con diferentes algoritmos base bajo un mismo marco experimental (Zhang y cols., 2020).

Markowitz divide el proceso de selección de una cartera en dos etapas. La primera consiste en formar expectativas sobre el comportamiento futuro de los activos, mientras que la segunda utiliza dichas expectativas para elegir la composición de la cartera (Markowitz, 1952). El valor principal de este planteamiento se encuentra en rechazar la maximización del retorno esperado como único criterio de selección. El riesgo asociado a la cartera pasa

a ocupar un papel fundamental en la toma de decisiones, por lo que el objetivo no consiste únicamente en buscar la combinación con mayor retorno esperado, sino en considerar conjuntamente su rentabilidad y su exposición al riesgo.

El retorno esperado de una cartera puede expresarse como la suma ponderada de los retornos esperados de los activos que la componen:

$$\mu_p = \sum_{i=1}^n w_i \mu_i, \quad (5.2)$$

donde w_i representa el peso asignado al activo i , μ_i su retorno esperado y n el número total de activos. Sin embargo, el riesgo de la cartera no depende únicamente de la varianza individual de cada activo. También intervienen las covarianzas entre los diferentes retornos, que reflejan en qué medida los activos tienden a variar conjuntamente. La varianza de la cartera se expresa como:

$$\sigma_p^2 = \mathbf{w}^T \mathbf{\Sigma} \mathbf{w}, \quad (5.3)$$

donde $\mathbf{w}$ es el vector de pesos y $\mathbf{\Sigma}$ la matriz de covarianzas. Por tanto, la diversificación no depende exclusivamente del número de activos incluidos, sino también de la relación existente entre ellos (Markowitz, 1952).

Como se ha expuesto a lo largo del trabajo, la metodología propuesta no pretende sustituir el marco clásico de selección de carteras ni desarrollar una nueva función de optimización. Su aportación se sitúa en la etapa anterior a la optimización: el aprendizaje de una representación latente de los retornos históricos y la generación de escenarios sintéticos a partir de dicha representación. Estos escenarios se utilizan posteriormente para estimar medias y covarianzas alternativas, manteniendo una fase final de optimización financiera interpretable.

Para establecer una comparación progresiva, se han implementado tres modelos de referencia: una cartera equiponderada, una cartera de Markowitz sin límite máximo específico por activo y una cartera de Markowitz restringida. Todas las estrategias se construyen utilizando únicamente la información disponible en el conjunto de entrenamiento y se evalúan posteriormente sobre el mismo conjunto de test.

5.6.1. Cartera equiponderada

La primera estrategia de referencia es una cartera equiponderada, en la que el capital se distribuye por igual entre todos los activos disponibles. El peso de cada activo se calcula como:

$$w_i = \frac{1}{n}. \quad (5.4)$$

Dado que el universo considerado está formado por 30 activos, cada uno recibe inicialmente un peso aproximado del 3,33 %. Esta estrategia se implementa mediante el script `src/optimization/equal_weight.py`.

La cartera equiponderada no requiere estimar retornos esperados ni matrices de covarianzas. Su inclusión proporciona una referencia sencilla, transparente y con un riesgo reducido de sobreajuste. Además, permite comprobar si la complejidad adicional introducida por los modelos de optimización y por la generación de escenarios se traduce en una mejora observable sobre los datos de test.

5.6.2. Cartera de Markowitz clásica

La segunda estrategia implementada se basa en la optimización media-varianza propuesta por Markowitz. Para construirla se utilizan los retornos del conjunto de entrenamiento, a partir de los cuales se estiman el vector de retornos medios y la matriz de covarianzas histórica.

Los pesos de la cartera actúan como variables de decisión del problema. Como restricciones básicas, se exige que todo el capital quede invertido y que no existan posiciones cortas:

$$\sum_{i=1}^n w_i = 1, \quad (5.5)$$

$$w_i \geq 0 \quad \forall i. \quad (5.6)$$

Estas condiciones definen una cartera *long-only*, en la que ningún activo puede recibir un peso negativo. La formulación mediante una función objetivo y un conjunto de restricciones permite representar el problema de selección de carteras dentro del marco general de la optimización matemática (Boyd y Vandenberghe, 2004).

En la implementación realizada, la función objetivo busca una combinación de activos con una relación favorable entre retorno esperado y volatilidad. La estrategia se encuentra desarrollada en el script `src/optimization/markowitz.py`. Una vez obtenidos los pesos mediante los datos de entrenamiento, estos se mantienen constantes y se aplican a los retornos del conjunto de test para evaluar el comportamiento fuera de muestra.

La solución obtenida presenta una concentración elevada en un número reducido de activos. En particular, el activo UNH recibe un peso cercano al 48,89 %, seguido por NVDA, AAPL y MSFT. Este resultado muestra una de las dificultades prácticas de la optimización media-varianza: pequeñas diferencias en las estimaciones de medias y covarianzas pueden producir asignaciones muy concentradas.

5.6.3. Cartera de Markowitz restringida

Con el objetivo de reducir la concentración observada en la solución anterior, se ha implementado una segunda variante de Markowitz que incorpora un límite máximo del (20 %) por activo. En este caso, las restricciones sobre los pesos quedan definidas como:

$$0 \leq w_i \leq 0,20 \quad \forall i, \quad (5.7)$$

manteniendo igualmente la condición de inversión completa:

$$\sum_{i=1}^n w_i = 1. \quad (5.8)$$

La incorporación de límites inferiores y superiores sobre las variables de decisión permite adaptar la solución matemática a condiciones de inversión concretas (Boyd y Vandenberghe, 2004). En este trabajo, el límite máximo se introduce para evitar que un único activo domine el comportamiento global de la cartera y para favorecer una distribución menos concentrada del capital.

Esta variante se implementa en `markowitz_constrained.py`. El límite de una quinta parte del capital por activo no garantiza por sí mismo una diversificación completa, ya que una cartera puede concentrarse en cinco activos situados en el máximo. Sin embargo, impide las asignaciones extremas de la variante sin límite y establece un marco común para compararla con la cartera sintética.

En la solución obtenida, UNH y NVDA alcanzan el límite del 20 %, mientras que AAPL, MSFT, MRK y PEP reciben también pesos relevantes. La distribución resultante

es menos concentrada que la de Markowitz sin límite máximo.

5.6.4. Evaluación común de las estrategias

Las tres estrategias se evalúan sobre el mismo conjunto de test y utilizando las mismas métricas financieras. En particular, se calculan el retorno acumulado, el retorno anualizado, la volatilidad anualizada, el ratio de Sharpe y el máximo *drawdown*. La utilización de un procedimiento común permite que las diferencias observadas se atribuyan a la construcción de las carteras y no a cambios en el periodo de evaluación o en las métricas empleadas.

Los resultados obtenidos muestran que la cartera equiponderada alcanza un retorno acumulado del 64,93 %, con un ratio de Sharpe de 1,88 y un máximo *drawdown* del -7,96 %. La cartera de Markowitz clásica obtiene un retorno acumulado del 95,60 %, un ratio de Sharpe de 1,89 y un máximo *drawdown* del -12,78 %. Por su parte, la variante restringida alcanza un retorno acumulado del 101,38 %, un ratio de Sharpe de 2,20 y un máximo *drawdown* del -11,26 %.

En el periodo de test analizado, la cartera restringida presenta un mejor equilibrio entre rentabilidad y riesgo que la solución de Markowitz sin límite máximo. No obstante, estos resultados deben interpretarse dentro del periodo temporal estudiado y no implican que una estrategia sea universalmente superior. Su función principal en este trabajo es establecer referencias homogéneas frente a las que evaluar posteriormente la cartera optimizada mediante escenarios generados por el VAE.

5.7. Implementación del Autoencoder Variacional

El Autoencoder Variacional *VAE*, **Variational Autoencoder** es un modelo generativo basado en variables latentes continuas que permite aprender una representación comprimida y estructurada de los datos. En el contexto de este trabajo, se asume que los vectores de retornos diarios normalizados de los treinta activos seleccionados pueden explicarse a través de una distribución latente de menor dimensionalidad que captura factores subyacentes comunes del mercado.

De forma operativa, el modelo no genera directamente una variable latente determinista, sino que el encoder aprende a parametrizar una distribución probabilística condicional. En particular, dado un vector de entrada x , el encoder produce dos vectores: la media $\mu(x)$ y el logaritmo de la varianza $\log \sigma^2(x)$. Estos parámetros definen una distribución

gaussiana multivariante diagonal de la forma:

$$q_\phi(z|x) = \mathcal{N}(\mu(x), \sigma^2(x)I)$$

A partir de esta distribución no se selecciona directamente un valor determinista, sino que se realiza un muestreo estocástico del espacio latente. Este muestreo se implementa mediante el truco de reparametrización, que permite mantener la diferenciabilidad del modelo:

$$z = \mu(x) + \sigma(x) \cdot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

El decoder toma como entrada este vector latente z y genera una reconstrucción $\hat{x}$ del vector original de retornos. En este caso, la salida del modelo tiene la misma dimensionalidad que la entrada (30 activos), por lo que el decoder actúa como una transformación inversa del espacio latente hacia el espacio original de observaciones financieras.

El objetivo del entrenamiento es que la reconstrucción sea lo más fiel posible a la entrada original, al mismo tiempo que el espacio latente mantiene una estructura regular. Para ello, el modelo se entrena maximizando la Evidence Lower Bound (ELBO), que en la práctica se implementa como la minimización de una función de pérdida compuesta por dos términos:

- un término de reconstrucción, medido mediante error cuadrático medio (MSE) entre x y $\hat{x}$,
- un término de regularización basado en la divergencia de Kullback-Leibler entre la distribución latente aprendida y una distribución normal estándar.

En este trabajo, la función de pérdida se define como:

$$\mathcal{L} = \mathcal{L}_{rec} + \beta \mathcal{L}_{KL}$$

donde el parámetro $\beta = 0,001$ controla el peso de la regularización del espacio latente.

El encoder está compuesto por una red neuronal feedforward con una capa oculta de 64 neuronas, mientras que el espacio latente tiene dimensión 8. El decoder simétrico reconstruye el vector de retornos a partir de esta representación comprimida.

El modelo se entrena durante 150 épocas utilizando el optimizador Adam. La función de pérdida se calcula sobre los retornos escalados en el intervalo $[-1, 1]$, utilizando únicamente

el conjunto de entrenamiento para evitar fuga de información. El aprendizaje converge de forma estable, observándose una reducción progresiva tanto del error de reconstrucción como del término de regularización KL.

En términos empíricos, el modelo alcanza una pérdida total en torno a 0.0095 al final del entrenamiento, con un error de reconstrucción en torno a 0.0077 en el conjunto de entrenamiento y aproximadamente 0.0105 en test, lo que indica una capacidad de generalización razonable del modelo. Asimismo, el error medio absoluto de reconstrucción se sitúa en torno a 0.060 en train y 0.069 en test, lo que confirma que el modelo preserva adecuadamente la estructura estadística de los retornos financieros sin sobreajustar significativamente los datos de entrenamiento.

5.8. Generación de escenarios sintéticos

Una vez entrenado el Autoencoder Variacional, el siguiente paso del pipeline consiste en la generación de escenarios sintéticos de retornos financieros. Estos escenarios se construyen a partir del espacio latente aprendido por el modelo, el cual representa una versión comprimida y regularizada de la distribución de retornos observada en los datos históricos.

El proceso de generación se basa en el muestreo de la distribución latente estándar utilizada como prior, es decir:

$$z \sim \mathcal{N}(0, I) \tag{5.9}$$

A partir de estas muestras aleatorias del espacio latente, el decoder del modelo genera observaciones sintéticas en el espacio original de los datos. En este caso, cada muestra generada corresponde a un vector de retornos de dimensión 30, asociado al conjunto de activos considerados en el estudio.

Este procedimiento permite obtener múltiples trayectorias sintéticas de retornos que preservan, en cierta medida, las dependencias aprendidas durante el entrenamiento del modelo. De este modo, no se generan simples perturbaciones de los datos históricos, sino nuevas realizaciones coherentes con la estructura estadística capturada por el VAE.

Los escenarios sintéticos generados se almacenan en forma de matriz, donde cada fila representa un escenario de retornos diarios y cada columna corresponde a uno de los activos del universo de inversión.

Posteriormente, estos escenarios se utilizan para estimar estadísticas agregadas, como

el vector de retornos esperados y la matriz de covarianzas sintética, que serán empleadas en la etapa de optimización de carteras.

5.9. Optimización de cartera a partir de escenarios sintéticos

A partir de los escenarios generados mediante el Autoencoder Variacional, se procede a la construcción de una cartera optimizada utilizando la misma formulación de media-varianza empleada en los modelos de referencia.

En este caso, la diferencia fundamental radica en que los parámetros de entrada del problema de optimización no se estiman directamente a partir de los retornos históricos, sino a partir de los escenarios sintéticos generados por el modelo.

De este modo, se obtienen un vector de retornos esperados sintético y una matriz de covarianzas sintética, definidos como:

$$\mu^{synt} = \frac{1}{T} \sum_{t=1}^T r_t^{synt} \quad (5.10)$$

$$\Sigma^{synt} = \text{Cov}(r^{synt}) \quad (5.11)$$

donde r_t^{synt} representa los retornos generados por el modelo en cada instante temporal.

El problema de optimización mantiene las mismas restricciones que en el caso de Markowitz restringido:

$$\sum_{i=1}^n w_i = 1 \quad (5.12)$$

$$0 \leq w_i \leq 0,20 \quad (5.13)$$

La optimización se realiza utilizando exclusivamente la información sintética generada por el modelo, evitando el uso directo de los datos históricos en esta fase. Esto permite evaluar si la estructura aprendida por el VAE es capaz de capturar información relevante para la construcción de carteras eficientes.

Una vez obtenidos los pesos óptimos, estos se aplican al conjunto de test real, lo que permite evaluar el rendimiento fuera de muestra bajo condiciones de mercado no observadas durante el proceso de generación de escenarios.

Este enfoque permite comparar de manera directa la utilidad de los escenarios sintéticos frente a los métodos clásicos de estimación basados en datos históricos.

5.10. Síntesis del pipeline experimental

El pipeline completo propuesto en este trabajo integra tres etapas principales: la preparación de datos, la generación de escenarios sintéticos y la optimización de carteras.

En primer lugar, se parte de precios ajustados diarios de activos financieros, a partir de los cuales se calculan retornos logarítmicos. Estos retornos se dividen en conjuntos de entrenamiento y test respetando el orden temporal de los datos.

En segundo lugar, se entrena un Autoencoder Variacional sobre los retornos escalados del conjunto de entrenamiento. Este modelo aprende una representación latente de la distribución de retornos y permite generar nuevos escenarios mediante muestreo en el espacio latente.

Finalmente, estos escenarios sintéticos se utilizan para estimar parámetros estadísticos que alimentan un proceso de optimización de carteras basado en teoría media-varianza. La cartera resultante se evalúa sobre datos reales no observados durante el entrenamiento.

Este diseño experimental permite analizar si la incorporación de modelos generativos mejora la calidad de las decisiones de inversión frente a enfoques clásicos basados exclusivamente en datos históricos.

5.11. Entrenamiento y comparación de modelos

5.11.1. Modelos candidatos

Para separar la comparación de redes de la comparación de carteras se implementaron tres candidatos. El primero es un autoencoder determinista (AE) con espacio latente de dimensión ocho. Su codificador produce un único vector y se entrena solo con MSE. Para generar escenarios se aproxima la distribución empírica de los códigos de entrenamiento mediante su media y covarianza, se muestrea en ese espacio y se decodifica.

El segundo es el VAE base con dimensión latente ocho y $\beta = 0,001$. El tercero mantiene arquitectura y regularización, pero reduce el latente a cuatro dimensiones. Esta variante permite estudiar si una compresión más intensa mejora la regularidad generativa o pierde información. No se incluye una GAN: requeriría definir y validar un entrenamiento

adversario diferente, y sus resultados no pueden inferirse de los VAE.

5.11.2. Configuración experimental

Los tres modelos utilizan los mismos retornos escalados, las primeras 2.212 filas como entrenamiento y las 554 finales como test. Se fijan semilla 42, 120 épocas, lotes de 64, Adam con tasa 10^{-3} y dos capas ocultas de 64 unidades. Cada candidato genera 5.000 escenarios. La ejecución en CPU usa `compare_autoencoders.py` y guarda un CSV comparativo.

Esta comparación adicional no reemplaza el VAE principal de 150 épocas utilizado para construir la cartera publicada. Su finalidad es responder de forma controlada a la elección de familia y dimensión latente. Mantener ambos experimentos diferenciados evita reescribir retrospectivamente los resultados financieros con un modelo distinto.

5.11.3. Métricas de comparación

La reconstrucción se mide mediante MSE y MAE en train y test. Para las 5.000 muestras se calculan tres discrepancias respecto al entrenamiento: error absoluto medio de las medias por activo, error absoluto medio de las desviaciones y error absoluto medio entre matrices de correlación. Todas las métricas se calculan en escala normalizada para garantizar comparabilidad entre modelos.

Estas medidas no forman una clasificación única. MSE y MAE premian la recuperación de observaciones, mientras los errores estadísticos evalúan el conjunto generado. Un AE puede reconstruir con precisión y carecer de un prior simple; el VAE sacrifica ajuste puntual para regularizar el latente. El criterio final debe considerar el propósito de generar escenarios, no solo el mínimo error de test.

5.11.4. Resultados de entrenamiento

La Tabla 5.2 recoge la ejecución real. El AE obtiene los menores errores de reconstrucción y el menor error de volatilidad y correlación con el procedimiento empírico de muestreo. El VAE base obtiene el menor error de medias sintéticas, pero presenta mayor discrepancia de volatilidad. Reducir el latente de ocho a cuatro empeora ligeramente test MSE, test MAE, medias y correlaciones, aunque su error de volatilidad es algo menor que el VAE-8.

La comparación revela una limitación relevante del VAE ejecutado: su prior normal facilita el muestreo, pero las muestras suavizan la dispersión y alteran correlaciones en

Modelo	MSE tr.	MSE te.	MAE tr.	MAE te.	Err. media	Err. vol.	Err. corr.
AE-8	0,003607	0,006308	0,041745	0,052878	0,006636	0,009668	0,220834
VAE-8	0,007815	0,010425	0,060368	0,068347	0,003852	0,048714	0,411596
VAE-4	0,007902	0,010561	0,060884	0,069296	0,004708	0,046912	0,418329

Tabla 5.2: Comparación reproducible de autoencoders en escala normalizada. Fuente: elaboración propia a partir de `autoencoder_model_comparison.csv`.

mayor medida que el AE con aproximación empírica del latente. A su vez, el AE no ofrece el mismo modelo probabilístico explícito y su muestreo gaussiano posterior es una decisión añadida. Por tanto, los números describen compromisos diferentes y no justifican proclamar un ganador universal.

5.11.5. Selección del modelo final

Se mantiene el VAE-8 como modelo principal por tres razones: es el modelo que originó los 5.000 escenarios y los resultados financieros auditados; ofrece menor error de medias que los otros candidatos; y dispone de un mecanismo probabilístico explícito para muestrear $z \sim \mathcal{N}(0, I)$. La variante de cuatro dimensiones no aporta una mejora global que justifique sustituirlo.

La ventaja reconstructiva del AE sugiere, no obstante, que futuras evaluaciones deberían construir también una cartera con sus escenarios y repetir ambos modelos con varias semillas. La selección del VAE es coherente con el objetivo y la trazabilidad del experimento, pero queda condicionada por la limitada búsqueda de hiperparámetros y no equivale a demostrar que sea la mejor arquitectura posible.

5.12. Resultados experimentales

Esta sección reúne los resultados empíricos de las estrategias de cartera. Todas las series se evaluaron sobre las mismas 554 sesiones del conjunto de test y las métricas fueron calculadas por `src/evaluation/metrics.py`. Los valores sin formato se conservan en `benchmark_comparison.csv`; esta trazabilidad evita transcribir resultados desde una figura o redondearlos de forma diferente según la estrategia.

El contraste no enfrenta una «cartera neuronal» con carteras clásicas. En todos los casos los pesos producen una combinación lineal de activos. La diferencia es la fuente de los parámetros: equiponderación no estima parámetros; Markowitz usa el entrenamiento

histórico; la variante restringida añade límites; y VAE Synthetic Markowitz estima media y covarianza sobre 5.000 escenarios decodificados.

5.12.1. Métricas de evaluación

El retorno acumulado se calcula componiendo los retornos diarios y expresa el crecimiento total durante el test. El retorno anualizado convierte ese crecimiento a una tasa comparable bajo 252 sesiones por año. La volatilidad anualizada es la desviación diaria multiplicada por $\sqrt{252}$. El ratio de Sharpe divide el retorno anualizado por la volatilidad con tipo libre de riesgo cero, siguiendo la medida de rendimiento ajustado por riesgo introducida por (Sharpe, 1966). Finalmente, el máximo *drawdown* mide la peor caída desde un máximo acumulado hasta el mínimo posterior.

Estas métricas son complementarias. El retorno ignora el camino seguido; la volatilidad penaliza tanto movimientos negativos como positivos; Sharpe resume una relación media-riesgo, pero es sensible a la anualización y a distribuciones no normales; y el *drawdown* depende de la secuencia concreta. No se utiliza ninguna de ellas como prueba aislada de validez financiera.

5.12.2. Resultados empíricos

La Tabla 5.3 reproduce los cinco campos disponibles para las cuatro estrategias. A diferencia de la versión preliminar, se incorpora la volatilidad anualizada y el retorno anualizado de la equiponderada, evitando celdas sin explicación.

Estrategia	Acumulado	Anualizado	Volatilidad	Sharpe	Máx. caída
Equiponderada	64,93 %	25,56 %	13,58 %	1,88	-7,96 %
Markowitz	95,60 %	35,69 %	18,86 %	1,89	-12,78 %
Markowitz restringido	101,38 %	37,50 %	17,01 %	2,20	-11,26 %
VAE sintético	242,32 %	75,02 %	25,08 %	2,99	-13,96 %

Tabla 5.3: Comparación de estrategias de inversión fuera de muestra. Fuente: elaboración propia a partir de `benchmark_comparison.csv`.

La Figura 5.6 permite observar el recorrido temporal que queda oculto en el retorno final. Las curvas no deben interpretarse como una simulación con rebalances: los pesos se fijan antes del test y permanecen constantes.




Figura 5.6: Evolución acumulada de las estrategias durante el periodo de test. Fuente: elaboración propia a partir de los retornos generados por el pipeline.

5.12.3. Lectura por estrategia

La equiponderada es el resultado más conservador de la tabla. Obtiene el menor retorno, pero también la menor volatilidad y el *drawdown* menos profundo. Su Sharpe de 1,88 queda muy próximo al 1,89 de Markowitz clásico. Esto recuerda que una regla simple puede ser competitiva cuando la incertidumbre de estimación es elevada.

Markowitz clásico eleva el retorno anualizado hasta 35,69 %, pero su volatilidad sube a 18,86 % y la caída máxima a -12,78 %. La mejora casi nula de Sharpe respecto a equiponderación indica que el retorno adicional viene acompañado de riesgo proporcional. La concentración observada en sus pesos es coherente con la conocida sensibilidad de las soluciones media-varianza.

La restricción del 20 % produce un compromiso más favorable en este test: aumenta el retorno frente a Markowitz, reduce volatilidad y *drawdown*, y eleva Sharpe a 2,20. Este resultado no implica que el límite del 20 % sea óptimo, pero muestra que una restricción interpretable puede actuar como regularización de la cartera.

La estrategia VAE alcanza los mayores retorno y Sharpe. Simultáneamente presenta la mayor volatilidad y la caída más profunda. Su perfil es, por tanto, más agresivo. La diferencia no puede atribuirse simplemente a «inteligencia artificial»: surge de medias

y covarianzas estimadas sobre escenarios que asignan pesos distintos y pueden favorecer activos con buen comportamiento posterior.

5.12.4. Por qué el resultado VAE puede ser elevado

Existen varias explicaciones compatibles. En primer lugar, el test cubre un periodo concreto y algunos activos seleccionados experimentaron fuertes revalorizaciones. Una cartera concentrada en ellos amplifica el retorno. En segundo lugar, el VAE suaviza volatilidades en parte de sus muestras, como muestra `vae_synthetic_summary.csv`; una covarianza sintética reducida puede hacer atractivos ciertos pesos. En tercer lugar, pequeños errores en medias diarias se amplifican al anualizar y optimizar Sharpe.

También existe selección experimental: la memoria presenta una configuración principal, no una distribución de resultados sobre numerosas semillas y ventanas. Aunque el test no se usó para entrenar el VAE ni calcular pesos, haber analizado el mismo periodo durante el desarrollo puede generar decisiones indirectamente adaptadas a él. La comparación multamodelo mejora la transparencia, pero no reemplaza una validación anidada.

5.12.5. Relación con la calidad generativa

La cartera VAE obtiene buen Sharpe aun cuando la comparación de modelos detecta errores apreciables de volatilidad y correlación sintéticas. No hay contradicción matemática: la utilidad para una cartera depende de cómo esas diferencias alteren el óptimo y del comportamiento posterior de los activos. Sin embargo, sí existe una advertencia: un buen resultado financiero en un único test no prueba que la distribución generada sea fiel.

Por esta razón se mantienen separados tres planos: reconstrucción, similitud estadística y rendimiento. El VAE base logra el menor error de medias sintéticas entre los tres modelos comparados, pero el AE reproduce mejor volatilidades y correlaciones con el procedimiento ensayado. Una ampliación debería construir carteras desde ambos y repetir el proceso en múltiples ventanas.

5.12.6. Evaluación comparativa y validez

Bajo el periodo analizado, los resultados sugieren que modificar la estimación de parámetros mediante escenarios puede producir asignaciones con mejores métricas de rentabilidad y Sharpe. También confirman el valor práctico de restricciones de concentración.

La evidencia no permite afirmar que el VAE supere en general a Markowitz o equiponderación, ni que prediga el mercado.

No se modelan comisiones, horquillas, impuestos ni impacto de mercado. Tampoco hay rebalanceo, por lo que no se evalúa rotación. El tipo libre de riesgo se fija en cero y las métricas no incluyen VaR o CVaR. Finalmente, un solo test carece de la diversidad de una validación *walk-forward*. Estas condiciones hacen que la tabla deba interpretarse como resultado académico reproducible, no como expectativa de inversión.

5.12.7. Síntesis de resultados

La equiponderación minimiza riesgo observado; Markowitz aumenta retorno sin mejorar apenas Sharpe; la restricción del 20 % mejora el equilibrio; y la estimación VAE produce el mayor retorno y Sharpe con mayor riesgo. El hallazgo central no es una garantía de rentabilidad, sino que la fuente de escenarios altera materialmente los parámetros, los pesos y el resultado fuera de muestra. Esa sensibilidad justifica profundizar en validación temporal, estabilidad y calidad de colas antes de cualquier uso práctico.

6. Código fuente y datos analizados

6.1. Código fuente

El código se organiza de manera modular para separar responsabilidades y hacer visible la procedencia de cada resultado. La carpeta `src/data` contiene adquisición y preparación; `src/analysis`, el EDA; `src/models`, las arquitecturas y el muestreo; `src/optimization`, las estrategias; y `src/evaluation`, las métricas y visualizaciones. Esta estructura evita concentrar decisiones heterogéneas en un único cuaderno y facilita ejecutar de nuevo una fase sin repetir las anteriores.

6.1.1. Herramientas y tecnologías

A continuación, se describen las principales herramientas y tecnologías empleadas en el desarrollo del presente trabajo de investigación. Se detallan los lenguajes de programación, las librerías y *frameworks* utilizados, así como los recursos computacionales necesarios.

En primer lugar, se destaca el uso de LaTeX para la redacción del presente documento, dado que permite estructurar adecuadamente la memoria, gestionar referencias bibliográficas y representar expresiones matemáticas de forma precisa.

Para la adquisición de datos se ha empleado la herramienta *yfinance*, que permite acceder a series históricas de precios de activos financieros y construir el conjunto de datos necesario para el desarrollo experimental del trabajo.

Python es el lenguaje utilizado para el análisis y la implementación. La manipulación y transformación se realizó con *pandas* y *NumPy*; el escalado, con *scikit-learn*; el VAE y los autoencoders, con *PyTorch*; la optimización SLSQP, con *SciPy*; y la visualización, con *matplotlib*. TensorFlow no forma parte de la ejecución documentada.

Para el control de versiones se ha empleado Git, utilizando la plataforma GitHub para el almacenamiento remoto del código, la documentación asociada y el seguimiento de los cambios realizados durante el desarrollo del trabajo.

6.1.2. Scripts principales

La Tabla 6.1 resume los archivos que intervienen en el flujo. Los nombres corresponden a rutas reales del repositorio.

Archivo	Función
<code>download.data.py</code>	Descarga cierres ajustados de 30 símbolos.
<code>preprocess.py</code>	Calcula retornos, corte temporal y escalado.
<code>generate.eda.outputs.py</code>	Genera cinco CSV y siete figuras EDA.
<code>vae.py</code>	Define, entrena y evalúa el VAE principal.
<code>generate.vae.scenarios.py</code>	Muestrea, decodifica y desnormaliza escenarios.
<code>compare.autoencoders.py</code>	Compara AE, VAE-8 y VAE-4.
<code>optimization/</code>	Contiene las cuatro estrategias.
<code>evaluation/</code>	Calcula métricas y figuras comparativas.

Tabla 6.1: Principales archivos de código fuente. Fuente: elaboración propia.

6.1.3. Flujo de ejecución

La reproducción comienza con la descarga y continúa con `preprocess.py`. Después puede ejecutarse el EDA, que solo lee `returns.csv`. El VAE lee los ficheros escalados, guarda `models/vae.pt`, reconstrucciones, historial y métricas. El generador carga el modelo y el escalador, crea 5.000 filas y devuelve la escala financiera.

Las estrategias históricas leen entrenamiento y test. La estrategia sintética lee los escenarios para optimizar y el test para evaluar. Por último, `compare_benchmarks.py` reúne los CSV de métricas. El experimento multamodelo adicional es independiente del artefacto principal y escribe `autoencoder_model_comparison.csv`; de este modo no sobrescribe resultados publicados.

6.1.4. Dependencias y entorno

`requirements.txt` fija las versiones de NumPy, pandas, scikit-learn, SciPy, PyTorch, Matplotlib, joblib y yfinance, entre otras dependencias. PyTorch implementa las redes y diferenciación; SciPy resuelve SLSQP; scikit-learn ajusta Min-Max; joblib conserva el escalador; y pandas mantiene índices y CSV.

La semilla 42 se fija en NumPy y PyTorch. Esto reduce variabilidad, aunque la reproducibilidad bit a bit puede depender de versión, hardware y operaciones internas. En la comparación adicional se utilizó PyTorch 2.13.0 en CPU. Conviene registrar también sistema operativo y versión de Python en una entrega definitiva.

6.1.5. Artefactos y trazabilidad

Cada etapa materializa resultados: CSV brutos y procesados, escalador, checkpoint, reconstrucciones, escenarios, pesos, retornos, métricas y figuras. Esta decisión permite revisar una cifra sin reentrenar. El repositorio se referencia en (Machín González, 2026); antes de entregar debe verificarse que la URL bibliográfica sea la definitiva y que los permisos permitan la revisión académica.

6.2. Datos analizados

6.2.1. Datos brutos y procesados

`data/raw/sp500_prices_adj_close.csv` contiene 2.767 fechas de precios ajustados. La transformación produce `returns.csv`, con 2.766 fechas y 30 activos. Los conjuntos `returns_train.csv` y `returns_test.csv` contienen 2.212 y 554 observaciones. Sus versiones escaladas son entradas del modelo y el objeto `minmax_scaler.pkl` conserva los parámetros aprendidos solo con train.

6.2.2. Datos generados

`vae_synthetic_returns_scaled.csv` y `vae_synthetic_returns.csv` contienen 5.000 escenarios por 30 columnas antes y después de desnormalizar. No poseen fecha porque no representan una trayectoria cronológica específica: cada fila es una realización conjunta empleada para estimar una distribución transversal diaria.

Las reconstrucciones permiten calcular MSE y MAE. El resumen sintético contrasta momentos por activo; el archivo de evaluación y las figuras comparan distribuciones, volatilidades y correlaciones. El CSV multmodelo registra siete métricas por configuración.

6.2.3. Pesos, retornos y métricas

Para cada estrategia se conservan pesos y retornos diarios. Los archivos con sufijo `metrics.csv` almacenan cinco métricas homogéneas y `benchmark_comparison.csv` las reúne. Esta separación permite comprobar que la tabla de la memoria no contiene números calculados manualmente.

6.2.4. Figuras y productos del EDA

Los cinco CSV EDA documentan dimensiones, ausencias, estadísticos descriptivos, asimetría, curtosis y pares correlacionados. Las siete figuras se encuentran en la carpeta EDA de LaTeX. El Capítulo 5 utiliza una selección de cinco para evitar redundancia; el resto permanece disponible para auditoría.

6.2.5. Limitaciones de los datos

Los archivos dependen de la cobertura y correcciones de Yahoo Finance. El universo no reproduce la ponderación completa del S&P 500 ni corrige sesgo de supervivencia. Tampoco contiene costes, volumen, liquidez, sectores o variables macroeconómicas. Estas ausencias limitan las interpretaciones que pueden extraerse y explican por qué el repositorio se presenta como experimento académico.

7. Conclusiones

7.1. Cumplimiento de objetivos

El objetivo general consistía en diseñar y evaluar una metodología para generar escenarios sintéticos de retornos y utilizarlos en una optimización de carteras. Este objetivo se ha materializado en un pipeline que comienza con precios ajustados, construye una matriz de 2.766 log-retornos, entrena un VAE, genera 5.000 escenarios, estima parámetros y evalúa pesos sobre 554 observaciones posteriores. La comparación con tres referencias permite situar el resultado frente a reglas simples e históricas.

Los objetivos teóricos se abordaron mediante la revisión de Markowitz, riesgo, hechos estilizados, teoría de la información y modelos generativos. El análisis distingue la función de la divergencia KL en el VAE de la función de máximo Sharpe de la cartera. También diferencia el estado del arte GAN/WGAN de la implementación real, una precisión necesaria para que el alcance sea defendible.

Los objetivos relacionados con datos se cumplieron mediante adquisición reproducible, tratamiento de ausencias, retornos, EDA y partición temporal. La matriz final no contiene nulos y las figuras documentan colas, volatilidad variable y correlaciones. La preparación ajusta el escalador solo con entrenamiento, reduciendo fuga de información.

En modelado, además del VAE principal, se ejecutó una comparación real con AE determinista y VAE de latente reducido. Esta ampliación responde a la necesidad de justificar el modelo y muestra que reconstrucción y generación son problemas relacionados, pero no equivalentes. La evaluación financiera completa el ciclo utilizando métricas comunes.

7.2. Principales resultados obtenidos

El VAE principal obtuvo MSE 0,00777 en entrenamiento y 0,01049 en test; el MAE pasó de 0,06022 a 0,06857. La brecha es moderada, pero confirma que la capacidad de generalización no es perfecta. Los resúmenes sintéticos muestran que parte de la volatilidad se suaviza, un aspecto crítico cuando las muestras se usan para estimar riesgo.

En la comparación de 120 épocas, el AE logró test MSE 0,006308 frente a 0,010425 del VAE-8 y 0,010561 del VAE-4. También presentó menores errores de volatilidad y correlación bajo el esquema empírico de muestreo. El VAE-8, en cambio, obtuvo el menor error de medias sintéticas (0,003852) y ofrece un prior explícito. Reducir el latente a cuatro

dimensiones no mejoró el conjunto de métricas.

La cartera VAE alcanzó retorno acumulado 242,32 %, retorno anualizado 75,02 %, volatilidad 25,08 %, Sharpe 2,99 y máximo *drawdown* -13,96 %. En ese mismo test, Markowitz restringido obtuvo 101,38 %, 17,01 % de volatilidad y Sharpe 2,20; la equiponderada presentó la menor volatilidad y caída. El VAE ofrece, por tanto, la mayor rentabilidad ajustada por volatilidad de la tabla, pero también el mayor riesgo absoluto.

7.3. Valoración final de la metodología

CRISP-DM resultó útil para conectar decisiones que podrían haberse presentado de manera fragmentada. La comprensión del problema fijó benchmarks y cautelas; la comprensión de datos produjo EDA verificable; la preparación evitó mezclar futuro y pasado; el modelado conservó configuraciones; y la evaluación empleó un test común. La reproducibilidad se apoya en scripts, semillas y artefactos intermedios.

La separación temporal es una fortaleza frente a una evaluación sobre entrenamiento. No obstante, un único corte sigue siendo débil para mercados no estacionarios. La selección del modelo y de restricciones debería realizarse dentro de ventanas anteriores, reservando múltiples periodos para evaluación. La metodología actual debe entenderse como primera prueba controlada.

La comparación multmodelo añade una conclusión metodológica: escoger por reconstrucción habría favorecido al AE, mientras el propósito generativo favorece valorar regularidad y momentos. Ninguna métrica resume por sí sola la idoneidad. En futuros trabajos conviene definir un criterio compuesto antes de observar el resultado financiero.

7.4. Aportaciones del trabajo

La primera aportación es un pipeline integral y auditable que conecta generación y optimización sin ocultar la capa clásica final. La segunda es un conjunto de productos reproducibles: EDA, modelos, escenarios, pesos y métricas. La tercera es una lectura crítica que evita presentar GAN/WGAN como ejecutadas y sitúa KL en su función correcta.

La cuarta aportación es empírica: bajo un mismo test, la fuente sintética modifica sustancialmente la cartera y produce métricas diferentes a la estimación histórica. Este hallazgo demuestra sensibilidad al procedimiento de estimación, no superioridad universal.

La quinta es la comparación AE/VAE, que identifica oportunidades concretas para mejorar la preservación de volatilidades y correlaciones.

7.5. Conclusión general

Los resultados sugieren que un VAE puede utilizarse de forma técnicamente viable para generar escenarios multivariantes y alimentar una optimización interpretable. En el periodo analizado, la cartera resultante obtiene métricas favorables de retorno y Sharpe. Sin embargo, la magnitud del resultado, la mayor volatilidad y las discrepancias estadísticas de las muestras exigen cautela.

No puede afirmarse que el modelo prediga el mercado, garantice rendimientos o sustituya una validación financiera completa. El valor del TFM reside en demostrar y documentar el encadenamiento experimental, comparar alternativas y hacer visibles sus supuestos. La contribución constituye una base sólida para ampliar ventanas, modelos y restricciones, pero no una recomendación de inversión.

8. Limitaciones y prospectiva

8.1. Limitaciones

8.1.1. Universo y periodo

El universo contiene 30 acciones y no las aproximadamente 500 del índice. Aunque ofrece variedad y viabilidad computacional, no reproduce su composición ni ponderación. La selección exige cobertura completa y puede introducir sesgo de supervivencia. El periodo 2014–2024 incluye distintos episodios, pero es una sola década de un solo mercado y moneda.

8.1.2. Fuente de datos

Yahoo Finance facilita precios ajustados y reproducibilidad práctica, pero es un proveedor externo que puede corregir históricos, cambiar su interfaz o aplicar ajustes distintos. Una descarga futura no está garantizada como idéntica. No se contrastó cada precio con una fuente institucional y no se incluyen volumen, liquidez ni fundamentales.

8.1.3. No estacionariedad y validación temporal

Los mercados cambian de régimen. Medias, volatilidades y correlaciones estimadas en entrenamiento pueden no persistir. El trabajo utiliza un único corte 80/20 y no realiza *walk-forward*. Por ello las métricas pueden estar condicionadas por un tramo favorable y no describen estabilidad a lo largo de múltiples ventanas.

8.1.4. Modelos generativos

El VAE principal representa una configuración concreta. La comparación AE/VAE se ejecutó con una variante adicional y mejora la evidencia, pero sigue siendo limitada: una semilla, dos dimensiones latentes y un valor de β . El VAE suaviza volatilidades y altera correlaciones en las muestras. No se realizaron pruebas específicas de colas o cobertura de crisis.

GAN, WGAN y la arquitectura híbrida del título no fueron implementadas. Se mantienen en teoría y prospectiva. Esta diferencia entre inspiración y ejecución debe conservarse

explícita. Tampoco se evaluaron difusión, flujos normalizantes o modelos temporales condicionados.

8.1.5. Optimización y condiciones de mercado

Markowitz es sensible a pequeñas variaciones de medias y covarianzas. La restricción long-only y el máximo 20 % contienen algunas soluciones, pero son decisiones académicas y no representan todos los mandatos. Los pesos permanecen fijos: no hay rebalanceo, costes, horquillas, impuestos, impacto de mercado o restricciones de rotación.

El tipo libre de riesgo se fija en cero. La evaluación incluye volatilidad, Sharpe y drawdown, pero no VaR, CVaR, Sortino ni análisis de concentración completo. La cartera VAE con mayor retorno también tiene mayor volatilidad; una función de utilidad diferente podría seleccionar otros pesos.

8.1.6. Alcance de las conclusiones

El resultado es académico y retrospectivo. No constituye recomendación financiera, asesoramiento personalizado ni garantía. La ausencia de datos personales no elimina obligaciones sobre propiedad intelectual, términos del proveedor, transparencia y comunicación responsable.

8.2. Trabajo futuro

8.2.1. Comparación y robustez de modelos

La comparación AE/VAE debería repetirse con varias semillas, dimensiones y valores de β , incorporando intervalos de variabilidad. Conviene construir carteras desde los escenarios de cada candidato para analizar si la fidelidad estadística se traduce en estabilidad de pesos. También sería útil evaluar pérdidas que ponderen colas o correlación.

Una implementación real de WGAN permitiría contrastar el diseño híbrido inicial. Su protocolo debería definir generador, crítico, regularización, estabilidad y criterios de parada antes de observar el test. Los modelos de difusión y flujos normalizantes constituyen alternativas para aproximar distribuciones complejas sin atribuirles ventajas a priori.

8.2.2. Validación temporal y operación

La prioridad empírica es una evaluación *walk-forward*: entrenar en una ventana, seleccionar hiperparámetros en validación anterior, invertir en el tramo siguiente y avanzar el origen. Esto produciría varias observaciones de rendimiento fuera de muestra. Sobre ese marco podrían añadirse rebalanceo mensual o trimestral, costes, rotación y liquidez.

8.2.3. Ampliación financiera

El universo puede ampliarse a más componentes, índices internacionales, bonos o ETF, controlando divisas y sesgo de supervivencia. Métodos como HRP y Black–Litterman aportarían benchmarks que responden de otra forma al error de covarianza. Optimizar CVaR o incorporar límites de riesgo permitiría estudiar colas explícitamente.

8.2.4. Variables condicionantes y herramienta reproducible

Variables macroeconómicas, volatilidad de mercado o estados de régimen podrían condicionar la distribución generativa. Esta ampliación exige sincronizar frecuencias y evitar información futura. Finalmente, un panel reproducible podría mostrar escenarios, pesos, sensibilidad y trazabilidad, siempre acompañado de advertencias y sin presentar los resultados como recomendación.

Referencias bibliográficas

- Aghapour, A., Bayraktar, E., y Yuan, F. (2025). Dynamic data generation and dynamic portfolio selection: An application of a score-based diffusion model. *arXiv preprint arXiv:2507.09916*.
- Arjovsky, M., Chintala, S., y Bottou, L. (2017). Wasserstein gan. *arXiv preprint arXiv:1701.07875*.
- Boyd, S., y Vandenberghe, L. (2004). *Convex optimization*. Cambridge: Cambridge University Press. Descargado de <https://web.stanford.edu/~boyd/cvxbook/>
- Cover, T. M., y Thomas, J. A. (2006). *Elements of information theory* (2nd ed.). John Wiley & Sons.
- Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of united kingdom inflation. *Econometrica*, 50(4), 987–1007.
- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... Bengio, Y. (2014). Generative adversarial nets. En *Advances in neural information processing systems* (Vol. 27).
- Huang, G., Zhou, X., y Song, Q. (2020). Deep reinforcement learning for portfolio management. *arXiv preprint arXiv:2012.13773*. Descargado de <https://arxiv.org/abs/2012.13773>
- Jiang, Z., Xu, D., y Liang, J. (2017). A deep reinforcement learning framework for the stock portfolio management. *arXiv preprint arXiv:1706.10059*.
- Kingma, D. P., y Welling, M. (2013). Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*.
- Lopez de Prado, M. (2018). *Advances in financial machine learning*. John Wiley & Sons.
- López de Prado, M. (2018). *Advances in financial machine learning: Chapter 1*. SSRN.
- Machín González, D. (2026). *Repositorio del trabajo fin de máster: Generación de escenarios sintéticos para optimización de carteras del s&P 500*. <https://github.com/dmaching/tfm>.
- Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91.
- Merton, R. C. (1972). An analytic derivation of the efficient portfolio frontier. *Journal of Financial and Quantitative Analysis*, 7(4), 1851–1872.
- Opitz, T. (2017). Latent gaussian modeling and inla: A review with focus on space-time applications. *Journal de la Société Française de Statistique*, 158(3), 52–85.

- Rasekhschaffe, K. C. (2026). Generative ai for stock selection. *arXiv preprint arXiv:2602.00196*.
- Salimans, T., Goodfellow, I., Zaremba, W., Cheung, V., Radford, A., y Chen, X. (2016). Improved techniques for training gans. En D. Lee, M. Sugiyama, U. Luxburg, I. Guyon, y R. Garnett (Eds.), *Advances in neural information processing systems* (Vol. 29). Curran Associates, Inc. Descargado de https://proceedings.neurips.cc/paper_files/paper/2016/file/8a3363abe792db2d8761d6403605aeb7-Paper.pdf
- Sharpe, W. F. (1966). Mutual fund performance. *The Journal of Business*, 39(1), 119–138. doi: 10.1086/294846
- Takahashi, S., Chen, Y., y Tanaka-Ishii, K. (2019). Modeling financial time series with generative adversarial networks. *Physica A: Statistical Mechanics and its Applications*, 527, 121261.
- Voronina, A., Romanko, O., Cao, R., Kwon, R. H., y Mendoza-Arriaga, R. (2025). Generative ai-enhanced sector-based investment portfolio construction. *arXiv preprint arXiv:2512.24526*.
- Wirth, R., y Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. En *Proceedings of the 4th international conference on the practical applications of knowledge discovery and data mining* (Vol. 1, pp. 29–39). Manchester.
- Zhang, Z., Zohren, S., y Roberts, S. (2020). Deep learning for portfolio optimization. *arXiv preprint arXiv:2005.13665*. Descargado de <https://arxiv.org/abs/2005.13665>